

# **AFI ESCUELA DE FINANZAS**

Máster en Data Science y Big Data en Finanzas

TRABAJO FIN DE MÁSTER

---

## **El futuro de la demanda eléctrica**

---



**Autor:**

Federico Álvarez-Labrador

**Tutor:**

Pilar Barrios Gómez

# ÍNDICE

<b>1. INTRODUCCIÓN</b>	<b>1</b>
1.1. Descripción del problema	1
1.2. Objetivos	2
1.4. Estructura de la memoria	3
<b>2. ESTADO DEL ARTE</b>	<b>5</b>
<b>3. ESTUDIO DEL PROBLEMA</b>	<b>8</b>
3.1. Def. de modelos	8
3.2. Def. de métricas	8
<b>4. ANÁLISIS EXPLORATORIO (DATOS DISPONIBLES)</b>	<b>10</b>
4.1. Descripción de los datos	11
4.2. Obtención de los datos	17
<b>5. PREPROCESADO VARS. CLIMÁTICAS</b>	<b>19</b>
5.1. Estudio de las posibles fuentes de datos climáticos	19
5.2. Análisis de estaciones y datos disponibles	20
5.3. Selección final de estaciones	21
5.4. Geolocalización de estaciones y municipios peninsulares	22
5.5. Asignación de población a cada estación	23
5.6. Análisis de los datos	23
5.7. Tratamiento de 'missing values'	24
5.8. Def. temperaturas climáticas por estación y zonas climática	26
5.9. Comp. vars. climáticas finales del modelo	26
<b>6. PREPARACIÓN Y LIMPIEZA DE LOS DATOS</b>	<b>27</b>
6.1. Carga y comp. del dataset completo	27
6.2. Análisis de los Índices de actividad económica	27
6.4. Encoding de variables cíclicas	28
6.5. Selección de variables finales para el modelo	28
6.6. Análisis del dataset definido para el modelo	30
<b>7. METODOLOGÍA EMPLEADA</b>	<b>42</b>
7.1. Modelos ML (RF-GB-XG)	42
7.2. Modelos RRNN (MLP-LSTM)	43
<b>8. OPTIMIZACIÓN DE MODELOS</b>	<b>45</b>
8.1. Modelos ML (RF-GB-XG)	46
8.2. Modelos RRNN (MLP-LSTM)	49
<b>9. RESULTADOS</b>	<b>52</b>
9.1. Modelos ML (RF-GB-XG)	52
9.2. Modelos RRNN (MLP-LSTM)	55
9.3. Modelo REE (Predicción Demanda D+1)	57
<b>10. VISUALIZACIÓN</b>	<b>57</b>
10.1. Modelos ML (RF-GB-XG)	58
10.2. Modelos RRNN (MLP-LSTM)	61
10.3. Modelo REE (Predicción Demanda D+1)	63
<b>11. CONCLUSIONES</b>	<b>63</b>
<b>12. TRABAJO FUTURO</b>	<b>64</b>
<b>13. BIBLIOGRAFÍA</b>	<b>65</b>
<b>14. ANEXOS</b>	<b>66</b>



## 1. INTRODUCCIÓN

La energía eléctrica es el motor de las economías industrializadas del planeta, es un bien de primera necesidad, se utiliza en una infinidad de aplicaciones de todos los sectores y es un elemento imprescindible para su desarrollo. Hoy en día es imposible imaginar un país avanzado sin una amplia y moderna red de creación y distribución de este recurso tan importante. Esta energía puede provenir de diversas fuentes, tanto de energías renovables (eólica, solar, hidráulica...) como de no renovables (carbón, gas, petróleo...) y sus plantas estar ubicadas en distintas zonas geográficas; por lo que es imprescindible una gran coordinación para garantizar el abastecimiento tanto a la demanda residencial, como a la comercial e industrial. El transporte y distribución de la energía desde los puntos de producción hasta el consumidor final se realiza a través de redes de alta y baja tensión respectivamente, por lo que, para este proceso, es necesario transformar las diversas formas de energía en energía eléctrica.

Sin embargo, uno de los mayores condicionantes de la generación de energía eléctrica en la actualidad es la incapacidad de almacenar grandes cantidades de ésta de una manera eficiente, debiendo balancearse generación y demanda en tiempo real. Esto implica que el operador de sistemas eléctricos de cualquier país debe estar preparado para satisfacer la demanda futura sin saber de antemano cuál será. Por esta razón, las empresas encargadas de generar y distribuir la energía trabajan con márgenes amplios sobre la demanda prevista y planifican centrales de generación en reserva, para poder asegurar un correcto abastecimiento.

### 1.1. Descripción del problema

La previsión de la demanda de energía desempeña un papel esencial en la industria eléctrica, ya que proporciona la base para la toma de decisiones. En cualquier sistema de energía eléctrica, el Operador del Sistema de Transmisión requiere el uso de algoritmos de predicción de carga a corto plazo. Estas predicciones son esenciales para una adecuada planificación de los recursos energéticos y la coordinación óptima de los agentes de generación. Además, disponer de buenas predicciones de la demanda horaria de electricidad en las próximas horas y para los próximos días es crucial para el funcionamiento del sistema eléctrico con unos costes aceptables.

El coste de la electricidad es un factor determinante para la competitividad de un país y la mejora en la previsión de la demanda permite optimizar los recursos de generación utilizados, reduciendo significativamente los precios de la energía. Adicionalmente cabe destacar que estas mejoras en las previsiones no sólo son beneficiosas en términos económicos, sino que también suponen importantes mejoras a nivel medioambiental, ya que permiten una programación más eficiente de la generación de las centrales térmica en reserva en el sistema y la maximización del aprovechamiento de las energías renovables, reduciendo las emisiones y ayudando a satisfacer más eficazmente las necesidades de todos los consumidores.

Otra de las ventajas que supone elaborar un buen sistema de predicción consiste en la capacidad para obtener información acerca de los cambios y tendencias que puedan estar sucediendo en el mercado. Esto puede ser de gran ayuda para realizar una planificación a largo plazo, y afrontar la apertura de nuevas líneas de distribución o la construcción de nuevas plantas de generación y distribución con mayor seguridad.

Debido a las razones mencionadas con anterioridad, todos los grandes implicados en el mercado eléctrico: comercializadores, distribuidores, generadores, el operador del sistema (Red Eléctrica de España, REE) y el operador del mercado buscan continuamente optimizar sus sistemas de previsión de la demanda de energía con el objetivo de hacerlos más precisos y fiables para ajustar de la manera más eficiente la demanda energética de los consumidores con la oferta de producción disponible. Para lograr este objetivo, se deben reconocer las variables que influyen en el comportamiento de los consumidores y tratar de realizar modelos que permitan dar una mayor fiabilidad y flexibilidad a las plantas de producción de energía.

La previsión de la demanda eléctrica ha sido un tema de investigación activo durante mucho tiempo. Las características cambiantes de los consumidores (universalización del aire acondicionado o aparición del vehículo eléctrico) y últimamente también de los productores (diferentes energías renovables y generación distribuida) siguen obligando a la industria a obtener previsiones cada vez más precisas. La previsión a corto plazo incluye tiempos de espera desde una hora hasta varios días y proporciona información relevante a los operadores del sistema para garantizar la fiabilidad del mismo y a los productores para determinar los horarios y la utilización.

Otra aplicación de estos modelos es la optimización de las ofertas del mercado para ambos lados del mismo. La desregulación de los mercados españoles en la última década ha ejercido una gran presión sobre las previsiones para mejorar los beneficios de las operaciones.

En los próximos puntos se abordarán los tipos de modelos que se han empleado a lo largo del tiempo para la realización de estas predicciones, así como los parámetros específicos que más influencia presentan sobre la demanda de energía eléctrica y cuya correcta modelización permite obtener modelos de predicción fiables.

## 1.2. Objetivos

La motivación de este trabajo es la búsqueda y estudio de las variables que influyen en la evolución de la demanda energética en la España peninsular y el análisis comparativo de dos tipos diferentes de modelos para su predicción (modelos de machine learning convencionales frente a redes neuronales definidas para la predicción de series temporales).

Se presenta un análisis de los resultados de la estimación y la precisión de la predicción, comparándolos con los resultados del modelo utilizado por Red Eléctrica de España (REE) para realizar previsiones con un día de antelación de la demanda eléctrica del sistema peninsular.

Para precisar el problema, consideramos una tarea diaria a la que se enfrenta el operador de un sistema eléctrico. Cada día, a las diez de la mañana, el operador debe decidir hora a hora qué capacidad de generación de reserva debe estar disponible al día siguiente para garantizar el suministro de la demanda. Para ello, es necesario tener una buena predicción de la demanda de energía horaria del día siguiente. Esta es una situación habitual a la que se enfrentan todos los sistemas eléctricos con una rutina diaria. Estas predicciones también son útiles para las empresas que realizan ofertas de producción en el mercado diario de electricidad al contado.

Aunque la predicción de la demanda se hace con carácter horario, en este trabajo debido a la imposibilidad de conseguir datos desagregados por hora, nos centraremos en la predicción a corto plazo de la serie diaria de la demanda eléctrica.

Los principales objetivos de este trabajo son:

1. Análisis del problema y definición de los modelos de predicción a utilizar.
2. Obtención de datos y definición de aplicaciones para su actualización a futuro.
3. Análisis de variables relevantes en la predicción de la demanda eléctrica.
4. Definición y aplicación del preprocesado necesario para los datos.
5. Desarrollo y optimización de los modelos de predicción.
6. Análisis y visualización de los resultados obtenidos.
7. Análisis comparativo con el modelo de predicción de REE.
8. Definición de posibles mejoras del presente trabajo a futuro.

#### 1.4. Estructura de la memoria

- ❖ Estado del arte
- ❖ Estudio del problema (def. de modelos y métricas)
- ❖ Análisis exploratorio (datos disponibles)
  - Descripción de los datos
  - Def. métodos de obtención de los datos
- ❖ Comp. vars. climáticas (preprocesado previo)
  - Estudio previo sobre las fuentes de datos climáticos
  - Análisis de estaciones y datos disponibles
  - Selección final de estaciones
  - Geolocalización de estaciones y municipios peninsulares
  - Asignación de población a cada estación
  - Análisis de los datos: "missing values" y "outliers"
  - Tratamiento de "missing values"
  - Definición de temperaturas por estación y zona climática
  - Comp. de las vars. climáticas finales del modelo
- ❖ Preparación y limpieza de los datos
  - Carga y comp. del dataset completo
  - Análisis de los Índices de actividad económico
  - Encoding de variables cíclicas
  - Selección de variables finales para el modelo
  - Análisis del dataset definido para el modelo
    - Revisión de variables (tipos, distribuciones, clases...)
    - Correlaciones (var. target y vars. explicativas)
    - "Missing values" y "outliers"

❖ Modelos ML (Random Forest + Gradient Boosting + XGBoost)

- Carga del dataset
- División de dataset en subconjuntos de “train” y “test”
- Análisis de variables: categóricas y numéricas
- Def. preprocesado de variables
  - Codificación de las vars. categóricas
  - Escalado de las variables numéricas
- Análisis y def. métricas
- Preparación de pipelines
- Optimización inicial de los modelos (librería Optuna)
- Ejecución final de los modelos (librería Scikit Learn)

❖ Modelos RRNN (MultiLayer Perceptron + Long Short-Term Memory)

- Carga del dataset
- División de dataset en subconjuntos de “train” y “test”
- Análisis de variables: categóricas y numéricas
- Def. preprocesado de variables
  - Codificación de las vars. categóricas
  - Normalizado de las variables numéricas
- Transf. dataset preprocesado a estructuras “timeseries” y “3D”
- Análisis y def. métricas
- Def. arquitectura de la RN
- Optimización final del modelo (librería Scikit Learn)
- Ejecución final de los modelos (librería Scikit Learn)

❖ RESULTADOS (MODELOS DESARROLLADOS Y MODELO REE)

- Modelos ML (Random Forest + Gradient Boosting + XGBoost)
- Modelos RRNN (MultiLayer Perceptron + Long Short-Term Memory)

❖ VISUALIZACIÓN (MODELOS DESARROLLADOS Y MODELO REE)

- Modelos ML (Random Forest + Gradient Boosting + XGBoost)
- Modelos RRNN (MultiLayer Perceptron + Long Short-Term Memory)

❖ CONCLUSIONES

❖ TRABAJO FUTURO

❖ BIBLIOGRAFÍA

❖ ANEXOS

## 2. ESTADO DEL ARTE

La previsión de la demanda a corto plazo ha sido un tema de investigación activo durante mucho tiempo, pero la industria de la energía se está viendo obligada a obtener previsiones cada vez más precisas. Las herramientas de previsión han evolucionado desde modelos estadísticos hasta modelos más complejos basados en diferentes tipos de inteligencia artificial.

Una revisión de la literatura sobre el tema permite hacerse una idea de la gran variedad de técnicas utilizadas para resolver el problema de la predicción a corto plazo de la demanda eléctrica. Dentro de los modelos estadísticos clásicos: la regresión múltiple y la regresión cuantílica multivariante, las técnicas de suavizamiento exponencial, las series temporales o los modelos de espacio de estados. Estos métodos ofrecen resultados precisos y su investigación está actualmente en curso.

En los últimos años, han aparecido muchos trabajos que utilizan técnicas de inteligencia artificial y aprendizaje automático como: redes neuronales artificiales, clustering, regresión de vectores de soporte, máquinas de vectores de soporte, aprendizaje por refuerzo, entre otros.

Las herramientas mencionadas se refieren a la entidad matemática que procesa los datos, el motor de previsión. Sin embargo, el motor de previsión no es el único aspecto clave de los modelos de previsión, sino que también son relevantes otros procesos como la normalización de los datos, el filtrado de los valores atípicos, la agrupación de los datos o la descomposición por transformación de los datos.

Aunque ha habido varios intentos de dilucidar qué metodología es más adecuada para resolver el problema de la predicción, se está lejos de alcanzar un consenso. Algunos autores utilizan algoritmos que combinan ambas metodologías, técnicas sofisticadas con modelos más tradicionales y las grandes compañías eléctricas o los operadores de sistemas eléctricos, tras una gran experiencia de ensayo y error con diferentes metodologías, suelen desarrollar sus propios sistemas híbridos adaptados a sus circunstancias particulares.

El problema de la predicción de la demanda con distintos horizontes temporales es objeto de un continuo proceso de mejora. Los dos pilares del progreso en esta área son la aparición de nuevas técnicas de previsión estadística (por ejemplo, el aprendizaje profundo ya mencionado) y la disponibilidad de nuevos datos. La mejora de las comunicaciones permite un acceso rápido y cómodo a una gran cantidad de información que modifica sustancialmente el modelo matemático. Por ejemplo, las nuevas técnicas de previsión proporcionan información actualizada sobre las condiciones meteorológicas de una región para los próximos días a intervalos de una hora y con gran precisión espacial.

La adición de esta información a los modelos de predicción de la demanda de energía mejora notablemente sus resultados. La llegada masiva de datos exige el desarrollo de nuevas técnicas, y la combinación de nuevos datos y nuevas técnicas ha revolucionado los actuales sistemas de predicción de la demanda eléctrica.

Otro aspecto a considerar es la necesidad de adaptar los modelos a las condiciones particulares del sistema eléctrico. La fluctuación de la demanda viene determinada por los efectos meteorológicos y la actividad humana, que está condicionada por los hábitos nacionales y la economía. Variables como la temperatura, la humedad y la radiación solar, por mencionar algunas de las características climáticas que afectan a la demanda, pueden ser muy diferentes de un país o región a otro.

Otro factor que ha sido ampliamente analizado, y que tiene un gran impacto en la demanda de electricidad son los días festivos. Por ejemplo, en España es muy complejo incluir en el modelo de predicción los distintos días festivos, algunos de carácter nacional que afectan al sistema y otros de carácter regional y local que afectan sólo a una parte del mismo. Además, el impacto en la demanda de un día festivo en lunes es muy diferente que cuando el mismo día festivo se celebra un martes o un miércoles.

La consideración de todos estos detalles es esencial y requiere el uso de gran cantidad de parámetros en los modelos de predicción.

### Modelo de predicción de la demanda eléctrica de REE

Dado el objeto de estudio del presente trabajo (demanda eléctrica peninsular española) y que se van a comparar los modelos desarrollados con el mismo, cabe hacer mención en este apartado al modelo de predicción desarrollado y utilizado por Red Eléctrica Española (REE) para la gestión de la red peninsular.

Red Eléctrica de España (REE) es la empresa que opera los diferentes sistemas eléctricos españoles, se encarga de hacer llegar energía eléctrica a toda la población en el momento que la requiere, así como de superar los picos de demanda para evitar la falta de abastecimiento consecuente en estos casos. REE es responsable de operar el principal sistema español, el sistema peninsular (un área de casi 500.000 kilómetros cuadrados, con más de 45 millones de personas y una demanda media diaria de 650 GWh) y otros 20 sistemas más pequeños correspondientes a las Islas Canarias, las Islas Baleares y los sistemas de las dos ciudades españolas del norte de África: Ceuta y Melilla.



Figura 1. Esquema y elementos de un sistema eléctrico

Atendiendo al contexto histórico, las bases del presente modelo se inician por mediación Ministerio de Industria y Energía en el año 1987, al proponer a las grandes empresas eléctricas participar en el proyecto INDEL de investigación de la demanda eléctrica. Este proyecto buscaba conocer puntualmente la demanda mediante la creación de modelos estadísticos para realizar estimaciones lo más exactas posibles y la recogida y el estudio de la información de la demanda en los sectores de consumo más importantes.

El actual es un modelo híbrido de previsión de demanda en tiempo real basado en un modelo autorregresivo y en redes neuronales, proporcionando una previsión horaria para el día actual y los próximos nueve días puntualmente cada hora para el sistema nacional, así como para 18 regiones de España (cabe destacar estos requisitos ya que imponen una gran carga computacional que hay que tener en cuenta durante la fase de diseño).

La falta de precisión para los días especiales es la principal pérdida derivada en su sistema de previsión. Los días especiales muestran una desviación del perfil de carga previsto debido a varias razones: fiestas nacionales o regionales, horario de verano, períodos especiales como Navidad o Semana Santa e incluso temperaturas extremas. El sistema se ha desarrollado para mejorar la precisión de las previsiones, especialmente en estos días.

Para lograr este objetivo, se realiza un análisis profundo de las series de temperatura de 59 estaciones para cada región y las series relevantes se incluyen individualmente en el modelo. También se analizan los días especiales y se propone una clasificación exhaustiva de los días para el sistema nacional y regional español. El modelo se diseña y se prueba con datos de 2005 a 2015.

El actual modelo de previsión que se encuentra en funcionamiento se comporta muy bien, alcanzando un error medio porcentual absoluto de previsión inferior al 2% en un horizonte de un día para el sistema peninsular español.

La figura incluida a continuación se corresponde con los datos de demanda real y prevista por el modelo para el día 4 de noviembre de 2020 y permiten comprobar su buen funcionamiento.

- La curva azul es la demanda real y refleja el valor de la demanda de energía en cada instante.
- La curva verde es la previsión de la demanda elaborada por REE basada en valores de consumo de periodos anteriores corregidos por una serie de factores de los que se tratarán en detalle más adelante, como son la climatología, laboralidad y actividad económica.
- La curva amarilla es la programación horaria operativa, que representa la producción programada a los agentes de generación que se les haya adjudicado el suministro de energía en la casación tanto del mercado diario como del mercado intradiario.

DESDE EL 04-11-2020 A LAS 00:00 HASTA EL 05-11-2020 A LAS 06:00 AGRUPADOS POR 10 MINUTOS

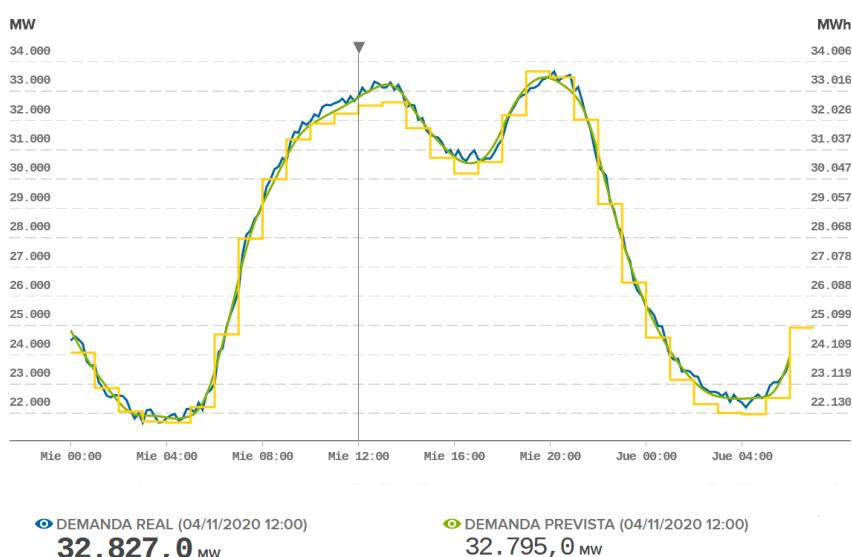


Figura 2. Gráfico de las series temporales de demanda real y demanda prevista (REE)

### 3. ESTUDIO DEL PROBLEMA

#### 3.1. Def. de modelos

El primer paso a realizar antes de empezar a preparar los datos o desarrollar el modelo consiste en analizar el problema al que nos enfrentamos. La demanda eléctrica es una variable continua por lo que está claro que nos encontramos ante un problema de regresión. Además, teniendo en cuenta la definición del problema y toda la información de los apartados anteriores queda claro que va a ser necesario el empleo de un número considerable de variables explicativas para conseguir predicciones lo más correctas posibles.

Dado que en los últimos años han aparecido muchos trabajos que utilizan redes neuronales artificiales para este tipo de problemas, dando buenos resultados, y que el modelo de REE con el que compararemos nuestros resultados es la combinación (entre otros) de un modelo de este tipo, uno de los modelos a desarrollar será una red neuronal.

Por todo lo anterior y con el objeto de comparar el rendimiento de los modelos de “machine learning” más convencionales frente a redes neuronales en este tipo de problemas, se decide elegir los siguientes dos tipos de modelos:

##### Modelos tipo Machine Learning convencionales

Se desarrollarán tres modelos alternativos tipo “ensemble” utilizando los métodos más avanzados y utilizados en la actualidad: Random Forest, Gradient Boosting y XGBoost.

##### Modelos tipo Red Neuronal

Se desarrollarán dos tipos de redes neuronales: una red tipo “MultiLayer Perceptron (MLP)” y otra red tipo “Long Short-Term Memory (LSTM)”, ambas aplicadas a la predicción de la serie temporal de la demanda.

#### 3.2. Def. de métricas

Las métricas a emplear dependen del tipo de problema, así como de ciertos condicionantes del mismo, entre ellos está el análisis de la distribución de la variable target. En el caso que nos ocupa estamos ante un problema de regresión por lo que en términos generales podríamos utilizar métricas para problemas de regresión como: “R2”, “MSE”, “RMSE”, “RMSLE”, “MAE”, “MAPE”...

Considerando las características del presente problema y la interpretabilidad de las métricas, se decide utilizar las siguientes:

##### R2 (Coeficiente de determinación)

La métrica “R2” representa el porcentaje de variabilidad explicada por el modelo y compara el mismo con un modelo “baseline” más simple (media o regr. lineal).

En relación a esta métrica se deberán tener en cuenta los siguientes aspectos:

- Un mayor nº de variables aumenta el R2 por defecto (aunque no esté mejorando el modelo).
- Si el modelo base no funciona bien, podemos obtener valores altos con nuestro modelo desarrollado pese a que no sea bueno.
- No es comparable entre modelos con distintos datasets o en los que la variable target está sujeta a distintas transformaciones.

#### RMSE (Raíz error cuadrático medio - Root Mean Square Error)

La métrica “RMSE” representa la media cuadrática de las diferencias entre los valores predichos y los valores reales observados.

En relación a esta métrica se deberán tener en cuenta los siguientes aspectos:

- La escala de los errores es la misma que la de los valores (ventaja).
- Tiene una mejor interpretabilidad que MSE (Error cuadrático medio - Mean Square Error).
- Mantiene relaciones entre modelos (es una métrica que permite comparar modelos).

#### MAPE (Raíz error cuadrático porcentual medio - Root Mean Square Percentage Error)

La métrica “MAPE” representa en porcentaje, la media cuadrática de las diferencias entre los valores predichos y los valores reales observados.

En relación a esta métrica se deberán tener en cuenta los siguientes aspectos:

- El error está en el contexto de las observaciones (no hay problema de escala, ventaja).
- El modelo puede estar fallando en las observaciones más grandes y estar enmascarado (puede ocurrir de la misma forma en las observaciones más pequeñas).
- Valores muy grandes pueden resultar en % de error pequeños.
- Valores muy pequeños pueden resultar en % de error grandes.

No se eligen métricas como: “MSE”, “MSPE” o “MAE”, ya sea por razones de interpretabilidad (escala de los errores es diferente a la de los valores de la variable target) o debido a la limitación de recursos de procesamiento (funciones no diferenciables).

#### 4. ANÁLISIS EXPLORATORIO (DATOS DISPONIBLES)

Una vez definidos los modelos a desarrollar y las métricas a utilizar el siguiente paso a realizar consiste en un análisis exploratorio de los datos disponibles y relevantes para nuestro modelo.

La demanda eléctrica varía ampliamente según numerosos factores, pero se puede seleccionar algunos de ellos como los más significativos y que tienen una influencia más marcada en el consumo de energía. Estos factores se pueden clasificar en tres grupos principales: laboralidad, climatología y actividad económica. Debido a esto resulta esencial una correcta modelización de cada uno de estos parámetros si se quiere reproducir con la mayor exactitud posible la evolución de la demanda a corto plazo, aunque requiere el uso de gran cantidad de parámetros en los modelos de predicción. Todos estos factores se tienen en cuenta con distintas variables en el modelo de predicción utilizado por Red Eléctrica Española.

Una vez determinados los factores relevantes para el modelo se ha realizado una búsqueda de datos que recojan esa información y permitan introducirla en el modelo. Cabe destacar que, como criterio general, se ha decidido que todas las fuentes de datos utilizadas sean públicas y que permitan su uso a futuro, pudiendo implementar de forma real los modelos desarrollados.

Las bases de datos que se utilizarán serán las obtenidas a través de la API de Red Eléctrica sobre variables relacionadas con el sistema eléctrico peninsular español y la API de AEMET sobre información climatológica. Además, se utilizarán índices de materias primas, así como índices de producción industrial, evolución del sector servicios, poblacionales y macroeconómicos para tener en consideración la influencia de la actividad económica y los respectivos sectores industrial, servicios y residencial en la evolución de la demanda energética.

Atendiendo a los tres grupos de variables, las fuentes de datos utilizadas han sido las siguientes:

##### Demanda eléctrica y Previsión de demanda

- API Esios – Sistema de información del operador del sistema, Red Eléctrica Española

##### Laboralidad

- Calendarios laborales y días inhábiles – Administración del Gobierno de España
- Histórico de calendarios laborales 2013-2021 – Comunidad de Madrid

##### Climatología

- API OpenData – Aplicación de acceso a la información meteorológica y climatológica de AEMET
- Climaemet – Librería de acceso a datos de AEMET (R)

##### Actividad económica

- Instituto Nacional de Estadística (INE) – Índices de sectores Industrial y Servicios
- Ministerios de Trabajo, Fomento e Industria – Índices de sectores Industrial y Servicios
- Banco de España – Índices macroeconómicos

#### 4.1. Descripción de los datos

Los datos empleados para el desarrollo de los modelos corresponden al periodo entre 2014 y 2021, utilizando los años 2014 a 2020 para el entrenamiento de los modelos y el año 2021 para los test.

A continuación, se definen en detalle por grupos los datos utilizados y su influencia en el mismo:

##### Laboralidad

La influencia de la laboralidad está relacionada con la demanda de energía por parte de la población laboral, sobre todo, la industria. De esta forma, influye el hecho de que el día sea laborable o no para el consumo de energía, disminuyendo la demanda los fines de semana y los meses de verano, al igual que las festividades. La modelización de los días festivos es compleja porque dependen del día de la semana en que caen. Además, la demanda de estos días, también influye en los días anteriores y posteriores, lo que la dificulta aún más.

Este factor de laboralidad se puede observar los fines de semana y en especial los domingos, siendo el día de la semana con menor la demanda de energía ya que la mayor parte de la población no trabaja. Además, se puede destacar también la menor cantidad de energía demandada los lunes respecto al resto de días laborables, lo cual se debe al tiempo que lleva arrancar el proceso de producción tras el parón del fin de semana.

Gran parte de los comercios públicos como restaurantes y hoteles siguen funcionando los fines de semana con normalidad, pero no generan un cambio debido a que funcionan igual que el resto de la semana.

DESDE EL 02-11-2020 A LAS 00:00 HASTA EL 08-11-2020 A LAS 06:00 AGRUPADOS POR 10 MINUTOS



Figura 3. Gráfico de la serie temporal de demanda real para una semana (REE)

Este factor muestra la influencia del calendario laboral en una determinada zona sobre el consumo de energía eléctrica. Esto nos permite tener en cuenta que en los días festivos la demanda de energía es mucho menor y así poder hacer una predicción de la demanda más acorde a la realidad. La influencia de la laboralidad va cambiando con el tiempo, pero no tiene una tendencia marcada que nos permita conocer cuál va a ser su evolución en los próximos años. Es decir, al igual que la temperatura, tampoco tiene una tendencia reconocida a lo largo del tiempo.

Dentro de este apartado cabe destacar también la influencia de sucesos y eventos especiales que influyen de manera importante en la demanda de energía como pueden ser grandes eventos deportivos, huelgas generales, etc. Un ejemplo de este factor calendario se puede observar en la diferencia entre la demanda prevista y la demanda real el día 8 de marzo de 2019 por efecto de la huelga del Día Internacional de la Mujer (Figura 4.).

DESDE EL 08-03-2019 A LAS 00:00 HASTA EL 09-03-2019 A LAS 08:00 AGRUPADOS POR 10 MINUTOS

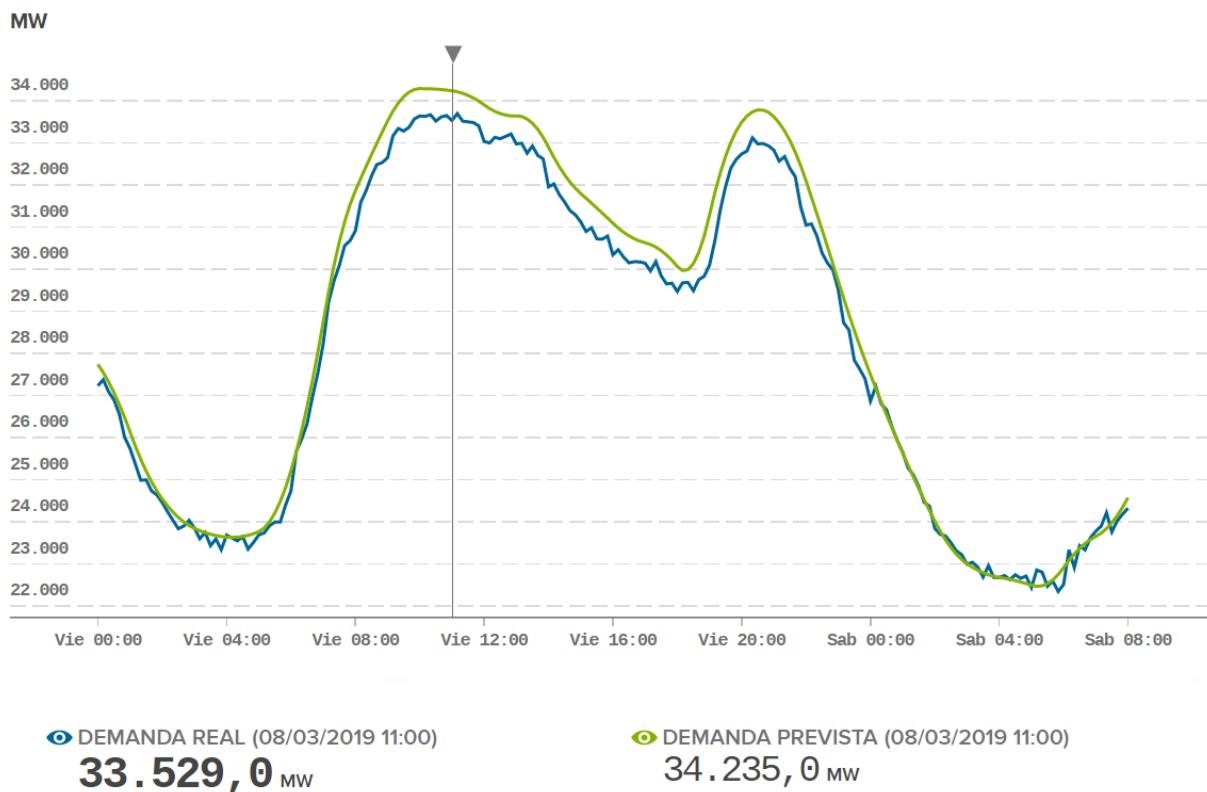


Figura 4. Gráfico de las series temporales de demanda real y prevista - Huelga 08/03/2019 (REE)

El perfil de demanda de los días con huelgas se parece en gran medida a los días festivos por lo que resulta evidente que sabiendo con anterioridad la existencia de estos sucesos se puede evitar la pérdida de energía que se generaría si se consideraran como días normales de trabajo.

De cara a la implementación de este factor en el modelo de predicción cabe destacar algunos inconvenientes propios del país, por ejemplo, en España es muy complejo incluir en el modelo de predicción los distintos días festivos, algunos de carácter nacional que afectan al sistema y otros de carácter regional y local que afectan sólo a una parte del mismo.

Además, algunos de estos días festivos suelen estar asociadas a una fecha concreta (el 1 de mayo, por ejemplo) y se celebran cada año en un día de la semana. El impacto en la demanda de un día festivo en lunes es muy diferente que cuando el mismo día festivo se celebra un martes o un miércoles. La consideración de todos estos detalles es esencial y requiere el uso de una serie de parámetros en el modelo predicción.

En relación a las variables que se han utilizado en los modelos desarrollados para recoger este factor de laboralidad se han considerado:

- Fecha
- Dia de la semana (lunes a domingo)
- Clasificación del día (Laborable, no laborable o festivo nacional)
- Clasif. días laborables previos a festivos nacionales (var. binaria)
- Clasif. días laborables posteriores a festivos nacionales (var. binaria)
- Día de huelga general (var. binaria)

Como se puede observar revisando las variables, no se han considerado los festivos regionales ni eventos especiales aparte de las huelgas generales. Como explicaremos más adelante en el apartado correspondiente, esto podría constituir uno de los puntos de los modelos a completar o perfeccionar. Para el presente trabajo las variables empleadas se consideran correctas.

### Climatología

La temperatura es clásicamente uno de los factores con mayor relevancia en la demanda de energía eléctrica. Ésta no tiene una tendencia reconocida a lo largo del tiempo por lo que es una componente estacionaria y además varía fuertemente a corto plazo. La variación de la temperatura puede hacer variar la demanda de energía de un mes hasta un 12% en sentido positivo o negativo.

Esta influencia es debida al uso de aparatos de climatización: la calefacción en invierno y el aire acondicionado en verano. El consumo de energía por parte de estos equipos es mayor cuanto menor sea la temperatura en invierno y cuánto mayor sea la temperatura en verano. Para estudiar la influencia de la temperatura en la demanda se estudian por separado los meses fríos, de noviembre a abril, de los meses cálidos, que corresponden de junio a septiembre

En los meses más fríos, un aumento de la temperatura llevará a un menor uso de la electricidad, debido al menor uso de la calefacción. Por el contrario, en los meses cálidos, este aumento de temperatura llevará a un aumento del uso del aire acondicionado y por tanto a un aumento en la demanda de energía eléctrica. Los meses que se encuentran fuera de estos dos grupos no tienen un comportamiento definido en este sentido, dependiendo su comportamiento de las condiciones climatológicas que se den.

Un aspecto a destacar respecto a la influencia de la temperatura es que el uso del aire acondicionado está menos implantado en verano que el uso de la calefacción en invierno. Esto es así porque en invierno la tendencia a estar en casa es mayor respecto a verano. Esta tendencia de la población a aguantar mejor manera el calor que el frío se ve reflejada en la demanda, que aumenta hasta un 18% en el mes de diciembre y solo hasta un 6% en el mes de julio.

La sensibilidad de la temperatura a largo plazo tampoco es constante y depende del nivel de renta en cada momento, que hará a los consumidores más o menos ahorradores a la hora de poner la calefacción o aire acondicionado; de la eficiencia energética que permite el avance de soluciones tecnológicas y del cambio en los hábitos de uso de estos aparatos en los consumidores. En los últimos años esta sensibilidad de la población a la temperatura ha aumentado de forma generalizada, en gran medida por la penetración y desarrollo que han tenido los equipos de climatización, que han hecho a los consumidores muy sensibles a las temperaturas extremas.

La temperatura ambiente en los últimos años está aumentando, por lo que los veranos están siendo más calurosos y los inviernos menos fríos. Esto hace que la demanda de energía sea menor de lo que hubiera sido si la temperatura ambiente fuera más parecida a la media histórica. Este cambio climatológico está afectando negativamente a la demanda de energía al ser los consumidores menos sensibles al calor en verano que al frío en invierno.

Además de la temperatura ambiente influyen otras condiciones meteorológicas como son el viento, nubes o precipitaciones, pero al ser la influencia de éstos en la demanda eléctrica mucho menor y al estar todos ellos relacionados con la temperatura, no se han tenido en cuenta como factores influyentes en este estudio de la predicción de demanda de energía.

En relación al desarrollo de los modelos de predicción del presente trabajo, se han partido de las temperaturas máximas y mínimas diarias de 143 estaciones de la Agencia Estatal de Meteorología (AEMET). Éstas se han ponderado de acuerdo a la población del censo más cercana a cada una de las estaciones, para tener en cuenta así la influencia de la población en la demanda eléctrica de cada zona.

Por último, se ha asignado cada una de las estaciones a su correspondiente zona climática de acuerdo al documento relativo al “Ahorro de energía” del Código Técnico de Edificación (CTE – DBHE) que establece la normativa general de cumplimiento para todas las edificaciones en España. Esto permite que el modelo sea capaz de tener más información y más detalle de las fluctuaciones de temperatura en zonas climáticas similares.

De acuerdo a este documento el territorio español se divide en 13 zonas: A3, A4, B3, B4, C1, C2, C3, C4, D1, D2, D3 y E1. La letra inicial correspondiendo al grado de severidad climática del invierno y el número a la del verano, como se puede observar en los mapas siguientes.

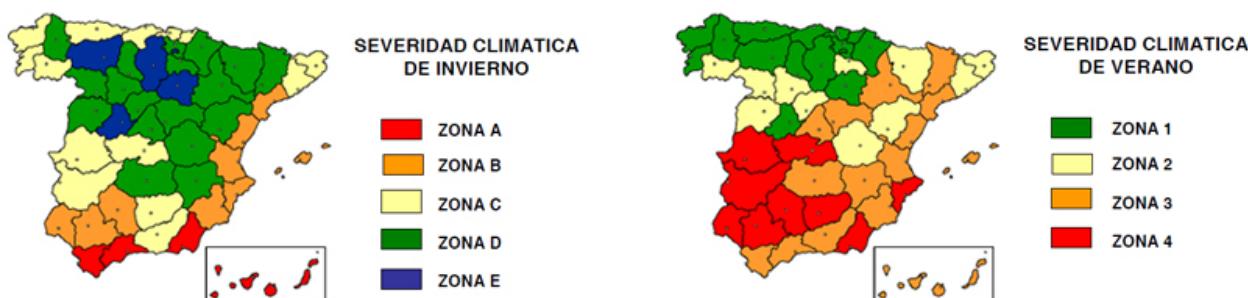


Figura 5. Mapas de severidad climática para todo el territorio nacional (DB-HE, CTE)

En apartados posteriores se explicará en detalle la obtención, análisis y preprocesado de los datos climatológicos, ya que son de los más importantes para el modelo.

### Actividad económica

La demanda de energía eléctrica suele replicar bastante bien el comportamiento de la economía en los países desarrollados. Esta dependencia es debida en gran parte a la vinculación que tiene el sector energético con el tejido industrial y comercial. Conforme mejoren los indicadores económicos de un país, generalmente aumentará el consumo eléctrico ya que las empresas producirán más bienes y servicios consumiendo una mayor cantidad de energía.

En la relación entre la actividad económica y la demanda eléctrica se pueden diferenciar dos componentes: uno debido a la estacionalidad del sistema económico y otro debido a las fluctuaciones generadas por las distintas actividades económicas en el consumo de energía eléctrica. Esta señal económica depende a su vez, por un lado, de una tendencia que refleja el impacto del desarrollo de los sistemas productivos y de los hábitos sociales del país y por otro, de una evolución coyuntural que muestra los cambios en la demanda que derivan de ajustes económicos más a corto plazo. Dependiendo del sector económico en cuestión, el dominio en la demanda eléctrica y en el Producto Interior Bruto son diferentes. Específicamente, el sector industrial tiene mayor peso en la demanda que en el PIB. Es decir, estas dos curvas puedes ser parecidas, pero no tienen por qué coincidir siempre.

A nivel de los indicadores macroeconómicos, esta interdependencia queda bien reflejada para el caso concreto de España. En gráfico del último informe sobre el mercado eléctrico español de REE, se aprecia como el Producto Interior Bruto (PIB) replicó de manera aproximada el comportamiento de la demanda eléctrica desde el año 2014 hasta el 2018. A partir de 2018, la caída del PIB se ha visto reflejada, aunque no de manera tan acusada, en la demanda eléctrica. Desde el año 2018 se observa un descenso del 5% en la demanda eléctrica.

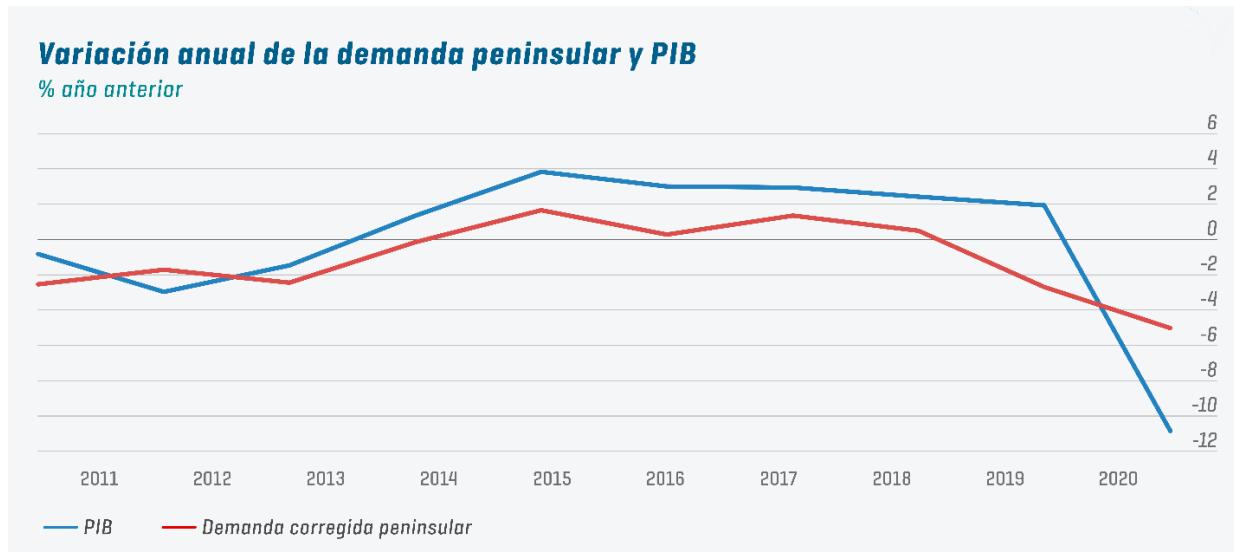


Figura 6. Grafico de variación anual de la demanda peninsular y PIB

Para estudiar la evolución anual de la demanda lo mejor es estudiar la energía demandada por los distintos sectores de la sociedad por separado. Al existir en un año las cuatro estaciones con sus respectivas climatologías, días festivos y en general, todos los factores que influyen en la demanda, la diferencia entre la energía demandada un año y otro está más bien enfocada a la energía que la sociedad necesita para los distintos ámbitos según necesidades temporales o la evolución de la sociedad.

Comparando por ejemplo la demanda anual entre 2014 y 2019, se observan claras diferencias en la cantidad de energía demandada por cada uno de los grupos. El desglose de la demanda nacional de energía eléctrica se puede observar en la siguiente tabla del Instituto para la Diversificación y Ahorro de la Energía (IDAE) dependiente del Ministerio de Transición Ecológica.

(ktep)	CONSUMO FINAL DE ENERGÍA					
	2014	2015	2016	2017	2018	2019
<b>Industria</b>	19852,83	18771,87	18612,59	20179,51	20707,67	20365,46
Extractivas (no energéticas)	447,41	404,17	441,34	502,79	452,32	481,68
Alimentación, bebidas y tabaco	2280,35	2268,15	2385,58	2653,37	2362,09	2367,65
Textil, cuero y calzado	322,86	318,07	368,69	315,55	296,16	380,36
Pasta, papel e impresión	1801,11	1684,64	1645,37	1835,11	1730,03	1701,00
Química (incluyendo petroquímica)	3980,43	2888,67	2695,54	3127,95	3508,44	3592,78
Minerales no metálicos	3278,56	3330,23	3285,62	3510,97	4097,15	4023,71
Siderurgia y fundición	2601,04	2903,74	2833,14	3174,42	2919,36	2562,53
Metalurgia no ferrea	999,60	1088,13	1140,29	1168,82	1299,71	1247,21
Transformados metálicos	830,50	945,87	948,25	771,38	908,49	825,46
Equipo de transporte	461,93	461,06	457,60	599,47	595,40	642,62
Construcción	1280,89	911,33	973,89	1049,71	1217,90	1399,65
Madera, corcho y muebles	466,50	452,19	545,88	645,61	539,39	596,75
Otras industrias	1101,65	1115,62	891,40	824,37	781,23	544,05
<b>Transporte</b>	32158,91	33384,87	34812,35	36312,57	37303,67	37831,05
Carretera	25740,17	26616,64	27441,30	28052,96	28735,46	28982,74
Ferrocarril	391,20	403,80	388,71	393,01	394,47	382,16
Marítimo interior	327,36	447,06	628,34	958,34	991,20	1037,84
Aéreo: aviación interior	1690,56	1828,55	1989,70	2162,44	2249,87	2378,38
Aéreo: aviación internacional	3745,53	3958,30	4196,35	4580,80	4772,50	4890,47
Oleoductos	72,23	63,31	65,89	70,94	75,37	78,76
Otros transporte no especificados	191,86	67,21	102,07	94,08	84,81	80,70
<b>Usos diversos</b>	27259,53	28294,45	28963,59	28268,58	28727,34	27961,69
Agricultura	2652,60	2273,81	2409,75	2412,89	2457,62	2612,25
Pesca	121,15	229,66	244,04	246,06	295,36	297,88
Comercio, Servicios y Admin. Públicas	8827,27	10409,19	10974,47	10827,77	10783,44	10177,10
Residencial	14743,75	14914,29	15105,82	14497,50	14866,94	14580,44
Otros usos diversos no especificados	914,75	467,51	229,51	284,35	323,99	294,02
<b>Consumo de energía final</b>	79271,27	80451,20	82388,53	84760,66	86738,69	86158,20

Figura 7. Tabla de consumo eléctrico por sectores, años 2014-2019 (IDAE)

Como se puede observar la demanda eléctrica total creció hasta el año 2018, tras el cual empezó a caer ligeramente. Dentro de los distintos sectores de la economía, el sector del transporte es el que mayor crecimiento ha sufrido en términos de demanda manteniéndose como el sector más demandante seguido del de usos diversos. Cabe destacar dentro de este último sector la componente residencial debido a su importante peso en la demanda total.

Por otro lado, la relación existente entre los indicadores económicos y la demanda eléctrica no se restringe únicamente a los grandes indicadores macroeconómicos. La importancia de los factores económicos sobre la demanda queda también patente al observar la evolución mensual de la demanda eléctrica en función de la estacionalidad de la actividad económica. Esta distribución de la demanda es importante tenerla en cuenta para entender los días o épocas en los que se notan fuertes aumentos de requerimientos de demanda, como por ejemplo los domingos o el mes de agosto en los que las industrias trabajan menos y necesitan menos electricidad.

Por su parte, el sector industrial en este caso se mantiene prácticamente constante todos los meses excepto en agosto y en enero, cuando los festivos y las vacaciones llevan a una menor necesidad de energía por parte de las compañías, que cierran por vacaciones o tienen menos cantidad de trabajo. Estos meses, en definitiva, sufren una menor laboralidad y un descenso de la demanda eléctrica. Otro ejemplo claro en España es el del sector turístico que influye bastante en la demanda de los meses de verano (julio y agosto).

El principal problema que presentan los indicadores económicos a la hora de utilizarlos en la construcción de los modelos de predicción se debe a la dificultad de modelizarlos. Pese a haber incluido distintos índices industriales y de los sectores del transporte y servicios, se considera como una vía de futura investigación la mejora de la modelización de los índices utilizados y la búsqueda de nuevos que sean relevantes para el modelo.

## 4.2. Obtención de los datos

Se definen inicialmente las variables target y baseline (ésta última para la comparación de modelos), y todas las variables explicativas que se consideran puedan ser relevantes para la predicción del modelo. Posteriormente de entre todas las variables explicativas se hará una selección de las mismas.

Atendiendo a los tres grupos de variables y las fuentes de datos utilizadas, las variables iniciales para el modelo son las siguientes:

### Demanda eléctrica y Previsión de demanda (API Esios)

- **Variable target (1):** DemReal (demanda real)
- **Variable baseline (1):** DemPrevD1 (Demanda prevista D+1)

### Laboralidad (Administración del Gobierno de España y Comunidad de Madrid)

#### **- Variables explicativas (10):**

N\_ano / N\_mes (categ. cíclica) / N\_dia\_mes categ. cíclica) / N\_sem\_mes (categ. cíclica)  
Dia\_sem (lunes a domingo) / Clasif\_día (Laborable, no lab. o festivo nacional)  
Lab\_previo\_festivo (var. binaria) / Lab\_post\_festiv (var. binaria) / Huelga\_General (var. binaria)  
(la variable “Fecha” se incluye ya descompuesta en el dataset)

### Climatología (API OpenData AEMET, Climaemet, INE)

- **Variables explicativas (24):** Censo 2011 (asignación de población)  
A3\_Tmax, A3\_Tmin / A4\_Tmax, A4\_Tmin / B3\_Tmax, B3\_Tmin / B4\_Tmax, B4\_Tmin  
C1\_Tmax, C1\_Tmin / C2\_Tmax, C2\_Tmin / C3\_Tmax, C3\_Tmin / C4\_Tmax, C4\_Tmin  
D1\_Tmax, D1\_Tmin / D2\_Tmax, D2\_Tmin / D3\_Tmax, D3\_Tmin / E1\_Tmax, E1\_Tmin  
(incluyen temperaturas máxima y mínima de 143 estaciones AEMET)

Actividad económica (INE, Ministerio de Trab-Fom-Ind, Banco de España, Bolsa española)**- Sector Industrial, variables explicativas (53):**

Ind\_Indust1 a Ind\_Indust28 / Ind\_Indust30 a Ind\_Indust42 / Ind\_Indust45 a Ind\_Indust56

(incluyen Índices de cifras de negocios en la industria e Índices de Producción Industrial)

**- Sector Servicios, variables explicativas (10):**

Ind\_Serv1 a Ind\_Serv10

(incluyen Índices de cifras de negocios en el sector Servicios)

**- Índices del mercado laboral, variables explicativas (4):**

Ind\_Empleo1 / Ind\_Empleo2 / Ind\_Empleo3 / Ind\_Empleo4

(incluyen estadísticas generales de afiliación a la Seguridad Social y de demanda de empleo)

**- Sector de la construcción, variables explicativas (1):**

Ind\_Cemento

(incluye índice de producción de cemento)

**- Índices de Precios de Consumo, variables explicativas (14):**

Ind\_Precios1 a Ind\_Precios14

(incluyen índices generales de precios de consumo para todos los ámbitos)

**- Índices de fabricación de vehículos, variables explicativas (2):**

Ind\_Fabr1 / Ind\_Fabr2

(incluyen estadísticas generales de la producción nacional de vehículos)

Cabe destacar que el modelo que se va a desarrollar no busca ser un modelo simplemente teórico por lo que, para seleccionar todas las variables consideradas para el modelo, se ha tomado como condiciones indispensables:

Variables con predicciones a futuro

Las variables relativas a "Laboralidad" y "Climatología" permiten la obtención de sus valores a futuro (las variables de calendario son fáciles de definir y se ha definido una conexión con la API de AEMET para la obtención de las predicciones climáticas de hasta 7 días a futuro para todas las estaciones consideradas para las variables de climatológicas del modelo).

### Variables con índices mensuales

Estas variables corresponden a todos los índices de “Actividad económica”. Estos índices son publicados mensualmente (escogidos por este motivo) y no hay posibilidad de obtenerlos a futuro. Para poder emplearlos y cumplir con la condición de implementación real del modelo, se decide comprobar las correlaciones cruzadas de los mismos con la variable target (correlaciones de los sucesivos desfases de cada índice).

El tratamiento de estas variables se analizará en detalle en los apartados de preprocesado de los datos previos al desarrollo del modelo.

## 5. PREPROCESADO VARS. CLIMÁTICAS

Las variables climatológicas tienen un peso muy importante dentro del modelo desarrollado y debido a ello y a la necesidad de componer unas “temperaturas peninsulares”, éstas han sido objeto de un preprocesado previo independiente a la preparación del dataset final del modelo.

Como se ha mencionado con anterioridad, hay numerosos estudios que constatan que sólo la temperatura tiene una influencia relevante en los consumos de gas y electricidad a escala peninsular por lo que para el modelo sólo se van a considerar las variables climáticas: temperatura máxima y temperatura mínima diarias. Esto además constituye una ventaja de cara al modelo, ya que reduce el número de variables climáticas tanto para la obtención a futuro y almacenaje de los datos como para su procesamiento dentro del modelo. Además, se han definido aplicaciones que permiten la obtención tanto de los datos históricos de temperaturas máximas y mínimas de AEMET como de los datos de predicciones para los próximos 7 días.

A continuación, se detalla el procedimiento seguido para la obtención y preparación de los datos de temperaturas, así como los criterios y proceso final para la composición de las “temperaturas peninsulares” a utilizar en el modelo.

### 5.1. Estudio de las posibles fuentes de datos climáticos

Se realizó una búsqueda de posibles fuentes de datos climatológicos de la península, tras la cual se decidió que la opción más idónea y precisa era la de utilizar los datos nacionales abiertos de la Agencia Estatal de Meteorología (AEMET).

En cuanto al procedimiento seguido para la descarga, comprobación y preparación de los datos, se han seguido los siguientes pasos:

- Se definen 2 herramientas (notebooks en Python y R) para la conexión con la API de AEMET y la obtención de los datos. La herramienta de Python mediante consulta directa y la de R utilizando la librería CLIMAEMET (incluye funciones predefinidas).
- Se parte de un listado inicial de 291 estaciones de AEMET, se filtran las estaciones no peninsulares (el modelo de demanda eléctrica peninsular no las va a precisar), quedando 258 estaciones de las cuales se solicitan los datos desde el año 2014 hasta el año 2021.
- De las 258 estaciones de las cuales se solicitan se obtienen datos de 240 (obtenemos errores de solicitud por parte de 18 estaciones, se eliminan del listado).

Los datos iniciales obtenidos de las 240 estaciones con datos accesibles se cargan en un notebook para su análisis. El principal objeto del mismo es comprobar cuáles se pueden emplear en el modelo y prepararlos en su caso.

#### *LISTADO ESTACIONES AEMET (actual del proceso)*

- 291 *estaciones iniciales AEMET*
- 258 *estaciones peninsulares (33 no peninsulares)*
- 240 *estaciones datos (18 errores de solicitud de datos)*

## 5.2. Análisis de estaciones y datos disponibles

Se han obtenido datos climáticos de las estaciones de AEMET mediante dos procedimientos diferentes: una aplicación para AEMET (Python) y la librería Climaemet (R).

Los datos obtenidos no son exactamente iguales, pareciendo más completos los obtenidos mediante la librería Climaemet, aunque ambas bases de datos contienen "missing values". Por ello se procede a cruzar ambas bases de datos para tratar de obtener una conjunta lo más completa posible. Una vez obtenida la base de datos conjunta se estudiará el tratamiento a aplicar a los "missing values" restantes.

Como considerábamos con antelación, el dataset de librería Climaemet (R) es más completo que el de aplicación para AEMET (Python), de todas formas, se comprueba que algunos datos no están contenidos en ambos datasets por lo que es correcta la combinación de ambos para completar el dataset conjunto. De esta forma conseguimos reducir parte de los "missing values" observados, pero tampoco de forma muy relevante por lo que será necesario analizarlos y realizar un tratamiento de los mismos.

Adicionalmente se cargan los datos de todas las estaciones de AEMET para su correcta definición e identificación. Esta tabla contiene información muy relevante como:

- Índice AEMET (único de cada estación)
- Altitud (necesaria para la definición de la zona climática)
- Índice INE (municipio asociado a cada estación)
- Localización (se empleará para la geolocalización de cada estación)

	Ind_AEMET	Altitud	Provincia	Nombre	Ind_INE	Provincia_Loc	Nombre_Loc	No_penins
0	0076	4	BARCELONA	BARCELONA AEROPUERTO	08169	Barcelona	Barcelona Aeropuerto	0
1	0367	143	GIRONA	GIRONA AEROPUERTO	17002	Girona	Girona Aeropuerto	0
2	1014	4	GIPUZKOA	HONDARRIBIA, MALKARROA	20036	Gipuzkoa	Hondarribia	0
3	1082	42	BIZKAIA	BILBAO AEROPUERTO	48904	Bizkaia	Bilbao Aeropuerto	0
4	1109	3	CANTABRIA	SANTANDER AEROPUERTO	39008	Cantabria	Santander Aeropuerto	0
5	1110	64	CANTABRIA	SANTANDER, CIUDAD	39075	Cantabria	Santander	0
...	...	...	...	...	...	...	...	...
285	9771C	185	LLEIDA	LLEIDA	25120	Lleida	Lleida	0
286	9784P	992	HUESCA	BIELSA	22057	Huesca	Bielisa	0
287	9814A	1020	HUESCA	TORLA	22230	Huesca	Torla	0
288	9981A	50	TARRAGONA	ESTACION DE TORTOSA (ROQUETES)	43155	Tarragona	Tortosa Roquetes	0
289	9987P	1	TARRAGONA	SANT JAUME D'ENVEJA	43902	Tarragona	Sant Jaume D'Enveja	0

Figura 8. Tabla de información general sobre estaciones AEMET (tabla completa en anexo)

### 5.3. Selección final de estaciones

En este apartado se analizan los datos obtenidos para cada una de las estaciones revisando los "missing values", de manera que se pueda decidir qué estaciones se pueden emplear y cuáles hay que descartar. Una vez definidas las estaciones finales a utilizar en el modelo se podrán analizar los "missing values" finales del dataset y decidir cuáles son los posibles tratamientos a aplicar.

Para el análisis se prepara una tabla personalizada para el caso de estudio con la información relevante de "missing values", observaciones y periodo de datos (fecha inicial/final de datos accesibles) para cada una de las 240 estaciones de la lista de estaciones con datos.

	Fecha	Ind_AEMET	Ind_INE	Provincia	Nombre	Tmax	Tmin	N_obs	N_miss	%_miss	Fecha_min	Fecha_max
0	0	3168C	0	0	0	2	2	403	2521	0,86277	01/01/2014	02/08/2015
1	0	3298X	0	0	0	620	620	2736	806	0,27584	01/01/2014	31/12/2021
2	0	8368U	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
3	0	1690A	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
4	0	2614	0	0	0	1	1	2922	1	0,34223	01/01/2014	31/12/2021
5	0	8175	0	0	0	1	0	2922	1	0,34223	01/01/2014	31/12/2021
...	...	...	...	...	...	...	...	...	...	...	...	...
235	0	4220X	0	0	0	445	445	2643	724	0,24778	01/01/2014	31/12/2021
236	0	3200	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
237	0	6268X	0	0	0	37	37	198	2761	0,94490	01/01/2014	13/12/2016
238	0	6277B	0	0	0	74	73	2660	336	0,11499	01/01/2014	31/12/2021
239	0	5192	0	0	0	7	7	1661	1268	0,43395	02/01/2014	14/11/2021

Figura 9. Tabla para análisis de "missing values" por estación AEMET (tabla completa en anexo)

Del estudio previo realizado se obtiene:

- Dado el intervalo de tiempo definido (años 2014 a 2021), para considerar una estación con datos completos ésta debería tener unas 2922 observaciones. La completitud de cada estación la podemos analizar mediante las variables de la tabla: "N\_obs", N\_miss, %\_miss, "Fecha\_min" y "Fecha\_max".
- Adicionalmente al número de observaciones es necesario analizar también el número de "missing values" presentes en dichas observaciones. Este apartado lo podemos revisar con las columnas de cada variable del dataset, salvo la variable "Ind\_AEMET" que recoge el código de identificación de la estación, y que se han definido en la tabla para que recojan el número de "missing values" de cada variable para cada estación.

Teniendo en cuenta los aspectos anteriores se analizan todas las estaciones y se aplican una serie de filtrados para obtener finalmente las estaciones definitivas a utilizar para el modelo.

1er filtrado - Seleccionamos las estaciones que proporcionan datos a día de hoy

2ndo filtrado - Seleccionamos las estaciones que proporcionan datos desde el día inicial

3er filtrado - Seleccionamos las estaciones con un % de "missing values" menor al 5%

Tras los 3 filtrados realizados obtenemos un listado con 149 estaciones. Se toman estas estaciones como el posible listado de estaciones a utilizar en el modelo, pero previamente se deberá analizar su idoneidad: revisión de la asignación de población a las mismas y comprobación de su distribución en el territorio peninsular.

## 5.4. Geolocalización de estaciones y municipios peninsulares

Se define una tabla con las coordenadas de las 258 estaciones peninsulares (en caso de ser necesarios estos datos posteriormente).

	Ind_AEMET	Longitude	Latitude
0	0076	2,079047	41,296944
1	0367	2,762426	41,904495
2	1014	-1,797246	43,367157
3	1082	-2,919130	43,301721
4	1109	-3,822845	43,427161
5	1110	-3,809972	43,462041
..	..	..	..
253	9784P	0,218859	42,633555
254	9814A	-0,657212	42,532566
255	9981A	0,508664	40,796329
256	9987P	0,718289	40,706285
257	9990X	0,872070	42,700051

Figura 10. Tabla de coordenadas de estaciones AEMET (tabla completa en anexo)

El sentido de este apartado es comprobar que el listado de 149 estaciones anterior cubre de forma homogénea la totalidad del territorio peninsular español, de manera que se pueda considerar la composición de las mismas como valores representativos de toda la península. Para el presente análisis se utilizarán herramientas de geolocalización y se revisará la distribución de las estaciones, tanto las que se han ido descartando como las estaciones con datos completos.

Mapa 0: Estaciones AEMET (258)



Figura 11. Mapa peninsular de visualización de estaciones AEMET (mapas completos en anexo)

Una vez revisada la distribución de estaciones finalmente seleccionadas para el modelo, ésta se considera suficientemente homogénea y repartida por todo el territorio peninsular. Se mantiene la selección de 149 estaciones definidas en los apartados anteriores.

Adicionalmente y para su uso posterior en caso necesario se cargan las distancias entre sí de las 97 estaciones AEMET seleccionadas para el modelo.

### 5.5. Asignación de población a cada estación

Tomando las estaciones completas del apartado anterior y utilizando herramientas de geolocalización, se procede a asignar la población de los municipios peninsulares a su estación correspondiente (asignación por distancia). Para los datos de población se han tomado los del último Censo nacional de 2011 (fuente INE).

	Ind_AEMET	Altitud	Ind_INE	Provincia_Loc	Nombre_Loc	No_penins	Req_error	Datos_incompl	Pobl_asig	PropPobl_asig	CTE_zona_clima
0	0076	4	08169	Barcelona	Barcelona Aeropuerto	0	0	0	711455	0,016367	C2
1	0367	143	17002	Girona	Girona Aeropuerto	0	0	0	681443	0,015677	D2
2	1014	4	20036	Gipuzkoa	Hondarribia	0	0	0	109861	0,002527	D1
3	1082	42	48904	Bizkaia	Bilbao Aeropuerto	0	0	0	1116703	0,02569	C1
4	1109	3	39008	Cantabria	Santander Aeropuerto	0	0	0	228164	0,005249	C1
5	1110	64	39075	Cantabria	Santander	0	1	1	0	0	C1
...	...	...	...	...	...	...	...	...	...	...	...
286	9784P	992	22057	Huesca	Bielsa	0	0	0	20709	0,000476	E1
287	9914A	1020	22230	Huesca	Torla	0	0	1	0	0	E1
288	9981A	50	43155	Tarragona	Tortosa Roquetes	0	0	0	252238	0,005803	B3
289	9987P	1	43902	Tarragona	Sant Jaume D'Enveja	0	0	1	0	0	B3
290	9990X	1161	25025	Lleida	Arties	0	0	1	0	0	E1

Figura 12. Tabla de información general sobre estaciones AEMET (tabla completa en anexo)

Una vez asignada, quedan 6 estaciones con datos completos con población nula por lo que el desglose de las estaciones finales a considerar para el modelo es el siguiente:

#### *LISTADO ESTACIONES AEMET (actual del proceso)*

- 291 estaciones iniciales AEMET
- 258 estaciones peninsulares (33 no peninsular)
- 240 estaciones datos (18 errores de solicitud de datos)
- 149 estaciones con datos suficientes (91 con datos incompletos)
- 143 estaciones con población asignada (6 sin población asignada)

Estaciones AEMET que se van a considerar para el modelo: 143 estaciones.

### 5.6. Análisis de los datos

Se realiza un análisis de los datos durante el cual no se detecta la presencia de "outliers" pero si de "missing values". En este caso tiene sentido debido a las propias características de los datos y su origen. Será necesario por tanto el análisis y tratamiento de los "missing values", éste se realizará en los próximos apartados.

## 5.7. Tratamiento de “missing values”

Dado que es un número reducido de "missing values" y se cuenta con un dataset de tamaño suficiente, se decide tratarlos utilizando el método "Multiple Imputation by Chained Equations (MICE)" de imputación de valores.

Previamente a la utilización del algoritmo MICE es necesaria una preparación de los datos: se añadirá información adicional relevante para ayudar a la imputación por parte del algoritmo y además es necesario realizar un "encoding" tanto de las variables categóricas como de las variables categóricas cíclicas (éstas últimas precisarán de una transformación a coordenadas polares en dos variables nuevas).

### Preparación de los datos previa la imputación de valores

Antes de realizar la imputación de valores y para que el algoritmo MICE funcione correctamente es necesario realizar un ajuste previo de las variables del dataset. Se realizarán las siguientes modificaciones en el dataset:

- Retiramos las columnas 'Ind\_INE', 'Provincia' y 'Nombre', ya que no aportan información nueva que no esté definida en el código identificativo de la propia estación.
- Añadimos las variables 'Longitude' y 'Latitude', variables de las coordenadas de las estaciones que pueden aportar información relevante al algoritmo de imputación.
- Descomponemos la variable 'Fecha' para poder codificarla de manera correcta (dado que el algoritmo MICE no acepta variables categóricas hay que codificarlas).
- Codificamos las variables categóricas cíclicas 'N\_mes' y 'N\_dia\_mes' (variables derivadas de la descomposición de la variable 'Fecha' ).
- Codificamos la variable categórica 'Ind\_AEMET'.

El proceso de "encoding" se va a realizar al dataset completo de datos climáticos ("train" y "test"), ya que va a ser necesario para ambos y no afecta en ningún caso a los datos. Posteriormente cuando se realice la imputación de valores si se separarán, imputando primero valores en el dataset de "train" y posteriormente imputando los valores restantes del subconjunto de "test" con ambos datasets unidos.

### Encoding de variables categóricas cíclicas

En el caso de la variable "Ind\_AEMET" (código de cada estación), esta codificación se puede realizar directamente utilizando la herramienta "One Hot Encoder", no así la variable "Fecha" ya que en caso de utilizar el mismo procedimiento ("One Hot Encoder"), crearíamos 1096 nuevas columnas (orden muy grande) y perderíamos parte de la información recogida en la variable ya que el algoritmo no tendría en cuenta el carácter cíclico de la variables y los posibles efectos estacionales que lleva asociada.

Por ello para la variable "Fecha" se decide desagregar las fechas en 3 nuevas variables: "Year", "Month" y "Day". La primera se va a considerar como una variable numérica directamente ya que el orden de los años es lineal pero las dos siguientes ("Month" y "Day") se van a considerar como categóricas cíclicas.

Estas variables al ser cíclicas, serán objeto de una codificación más particular. Se les aplicará una transformación a coordenadas polares, descomponiendo cada una en dos nuevas variables (componente seno y coseno) que conjuntamente definen un espacio circular y recogen el sentido cíclico de ambas variables. De esta manera permitimos al algoritmo MICE que vea los posibles efectos estacionales entre las observaciones.

Codificamos las variables categóricas cíclicas expresándolas mediante los valores del coseno y el seno de la división de una circunferencia por el número de categorías de la variable.

$$Var\_sin = \sin\left(\frac{variable * 2\pi}{max\_value}\right)$$

$$Var\_cos = \cos\left(\frac{variable * 2\pi}{max\_value}\right)$$

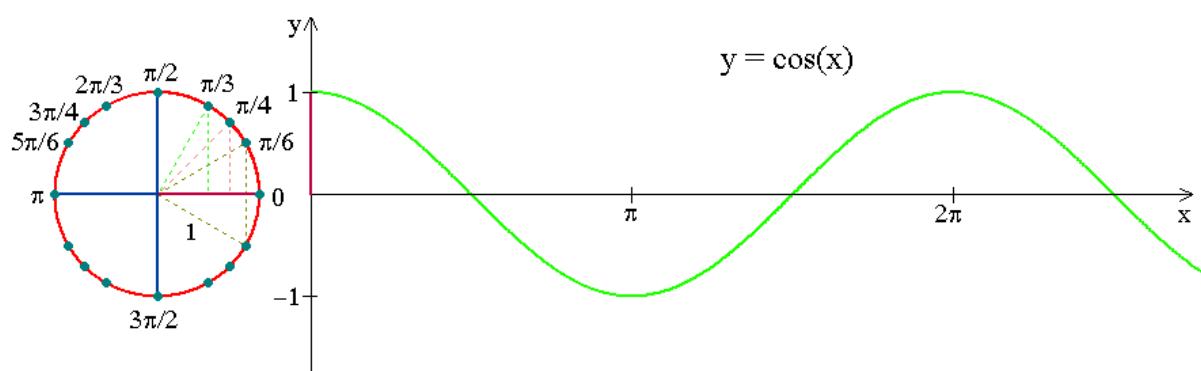


Figura 13. Representación gráfica del “encoding” cíclico realizado

#### Encoding de variable categórica

Realizamos la codificación de la variable categórica "Ind\_AEMET". Para ello se empleará la herramienta "One Hot Encoder" de la librería Scikit Learn.

#### Escalado de variables

Escalamos todas las variables preparadas para evitar que la diferencia en los órdenes de magnitud afecte de forma muy marcada al algoritmo.

#### Imputación de valores "train" y "train"+"test" (MICE)

Aplicamos el algoritmo MICE imputando primero los “missing values” en el dataset de "train" y posteriormente los valores restantes del subconjunto de "test" con ambos datasets unidos.

#### Re-escalado y “reverse encoding” de variables

Deshacemos el escalado y el “encoding” de las variables previos a la imputación de valores mediante el algoritmo MICE. Ya sólo queda preparar el dataframe con los datos finales necesarios para su inclusión en el modelo. Componemos de nuevo la variable "Fecha" utilizando las variables resultantes de su descomposición previa. Esta variable es importante ya que es la clave que sirve para unir todos los dataframes de datos parciales del modelo. Ya sólo queda preparar el dataframe con los datos finales necesarios para su inclusión en el modelo.

## 5.8. Def. temperaturas climáticas por estación y zonas climática

De acuerdo a los expuesto en apartados anteriores, se ha partido de las temperaturas máximas y mínimas diarias de 143 estaciones de AEMET. Una vez tratados los “missing values” se utilizan los datos poblacionales definidos para cada estación y asignados en el apartado anterior. Se ponderan las observaciones de cada estación de acuerdo a su población del censo asignada, para tener en cuenta así la influencia de la población en la demanda eléctrica de cada zona.

Adicionalmente, se ha asignado a cada una de las estaciones su correspondiente zona climática de acuerdo al documento relativo al “Ahorro de energía” del Código Técnico de Edificación (CTE – DBHE) que establece la normativa general de cumplimiento para todas las edificaciones en España. Estas zonas son definidas en base a la provincia y altitud de la localidad, en este caso se han utilizado los datos de cada estación. De acuerdo a este documento el territorio español se divide en 13 zonas: A3, A4, B3, B4, C1, C2, C3, C4, D1, D2, D3, E1 y ALPHA (sólo 12 se emplearán en este modelo ya que la última está asociada a territorios insulares). La letra inicial correspondiendo al grado de severidad climática del invierno y el número a la del verano, como se puede observar en los mapas siguientes.

De esta manera obtenemos una tabla con temperaturas máximas y mínimas ponderadas poblacionalmente para cada estación y fecha de los años analizados (2014 a 2021).

	<b>Fecha</b>	<b>Ind_AEMET</b>	<b>Tmax</b>	<b>Tmin</b>	<b>Pobl_asig</b>	<b>PropPobl_asig</b>	<b>CTE_zona_clima</b>
<b>0</b>	01/01/2014	0016A	15,60	3,30	641870	0,014766	B3
<b>1</b>	01/01/2014	0076	14,50	4,70	711455	0,016367	C2
<b>2</b>	01/01/2014	0149X	12,00	-1,70	509191	0,011714	D2
<b>3</b>	01/01/2014	0200E	14,10	6,20	3884497	0,089364	D2
<b>4</b>	01/01/2014	0255B	13,20	1,90	441129	0,010148	C2
<b>5</b>	01/01/2014	0367	14,60	-0,50	681443	0,015677	D2
...	...	...	...	...	...	...	...
<b>417841</b>	31/12/2021	9698U	15,60	4,60	59213	0,001362	E1
<b>417842</b>	31/12/2021	9771C	6,60	2,60	377150	0,008676	D3
<b>417843</b>	31/12/2021	9784P	13,80	1,90	20709	0,000476	E1
<b>417844</b>	31/12/2021	9898	14,60	6,50	104477	0,002404	D2
<b>417845</b>	31/12/2021	9981A	20,40	7,30	252238	0,005803	B3

Figura 14. Tabla observaciones climáticas por estación y día (incluye población asignada y zona climática)

## 5.9. Comp. vars. climáticas finales del modelo

Utilizando las zonas climáticas definidos para cada estación y asignadas en el apartado anterior a cada una de las observaciones de cada estación, calculamos las temperaturas medias máxima y mínima para cada zona climática y para cada fecha del dataset (2922 observaciones). Éstas serán las variables climáticas empleadas en los modelos a desarrollar.

	<b>Fecha</b>	<b>A3_Tmax</b>	<b>A3_Tmin</b>	<b>A4_Tmax</b>	<b>A4_Tmin</b>	<b>B3_Tmax</b>	...	<b>D2_Tmin</b>	<b>D3_Tmax</b>	<b>D3_Tmin</b>	<b>E1_Tmax</b>	<b>E1_Tmin</b>
<b>0</b>	01/01/2014	1,0755	0,6869	0,3214	0,1931	1,8373	...	0,7977	2,3808	1,2630	0,4374	0,2107
<b>1</b>	02/01/2014	0,9940	0,7739	0,3230	0,2476	1,7854	...	1,5053	2,7507	1,9063	0,5362	0,3015
<b>2</b>	03/01/2014	1,1406	0,7019	0,3656	0,2441	2,0635	...	1,5813	3,1863	2,1842	0,5683	0,3154
<b>3</b>	04/01/2014	1,1967	0,7114	0,3520	0,2037	2,1225	...	0,6549	2,8277	0,9474	0,4325	-0,0183
<b>4</b>	05/01/2014	1,0368	0,5389	0,3339	0,1562	1,7580	...	0,6034	2,2436	0,8102	0,4856	-0,0207
<b>5</b>	06/01/2014	1,1331	0,3944	0,3179	0,1553	1,9694	...	1,2325	2,8784	1,2321	0,5537	0,2968
...	...	...	...	...	...	...	...	...	...	...	...	...
<b>2917</b>	27/12/2021	1,2075	0,8263	0,3827	0,2479	2,3593	...	1,5740	3,5326	2,1864	0,6905	0,3818
<b>2918</b>	28/12/2021	1,1561	0,7733	0,3802	0,2074	2,2813	...	1,7105	3,5589	1,8816	0,7365	0,3305
<b>2919</b>	29/12/2021	1,2356	0,6680	0,3628	0,1857	2,3236	...	1,4860	3,3370	1,3968	0,7589	0,2563
<b>2920</b>	30/12/2021	1,2059	0,5539	0,3279	0,1574	2,2237	...	1,4391	3,7083	0,9137	0,9153	0,2117
<b>2921</b>	31/12/2021	1,0284	0,4779	0,3665	0,1676	1,9864	...	1,2634	3,6419	0,9220	0,9234	0,1865

Figura 15. Tabla observaciones climáticas finales a emplear en el modelo (tabla completa en anexo)

## 6. PREPARACIÓN Y LIMPIEZA DE LOS DATOS

### 6.1. Carga y comp. del dataset completo

Se cargan los datos de las variables consideradas para el desarrollo del modelo. Se cuenta con datos en dos formatos principales: csv y Excel. 119

Inicialmente contamos con 1 variable target y 119 variables explicativas. Adicionalmente preparamos la serie temporal de la variable “Demanda prevista D+1”, valores estimados de la demanda proporcionados por el modelo de predicción de REE.

Las variables explicativas se pueden clasificar de acuerdo a los tres grupos mencionados en apartados anteriores:

- Laboralidad (10)
- Climatología (24)
- Actividad económica (84) Sector Industrial (53), Sector Servicios (10), Índices del mercado laboral (4), Sector de la construcción (1), Índices de Precios de Consumo (14), Índices de fabricación de vehículos (2).

### 6.2. Análisis de los Índices de actividad económica

Un caso particular de cara a su utilización en el modelo es el de las variables correspondientes a los índices de “Actividad económica”. Estos índices son publicados mensualmente (escogidos por este motivo) y no hay posibilidad de obtenerlos a futuro.

	<b>Vars</b>	<b>Desf_Max_Corrs</b>	<b>Corr_max</b>	<b>Corr_0</b>	<b>Corr_1</b>	<b>Corr_2</b>	<b>Corr_3</b>
<b>0</b>	Ind_Indust1	[0; 1]	0,509977	0,449300	0,509977	-0,026950	-0,019251
<b>1</b>	Ind_Indust2	[0; 1]	0,520424	0,498903	0,520424	-0,063817	-0,017200
<b>2</b>	Ind_Indust3	[0; 1; 21]	0,511288	0,404087	0,511288	0,022177	-0,002869
<b>3</b>	Ind_Indust4	[0; 1; 21]	0,477734	0,395162	0,477734	0,110830	0,022815
<b>4</b>	Ind_Indust5	[0; 1; 12; 14; 15]	-0,313223	0,123657	0,144636	-0,258942	-0,211474
...	...	...	...	...	...	...	...
<b>53</b>	Ind_Serv1	[0; 1]	0,584240	0,523213	0,584240	-0,022317	-0,033067
<b>54</b>	Ind_Serv2	[0; 1]	0,570900	0,511270	0,570900	-0,036997	-0,055897
<b>55</b>	Ind_Serv3	[0; 1]	0,562092	0,457678	0,562092	0,095106	0,041142
<b>56</b>	Ind_Serv4	[0; 1]	0,501738	0,450085	0,501738	-0,081767	-0,083012
<b>57</b>	Ind_Serv5	[0; 1]	0,653334	0,605005	0,653334	0,004134	-0,034091
...	...	...	...	...	...	...	...

Figura 16. Tabla para análisis de correlaciones cruzadas en vars. explicativas (tabla completa en anexo)

Como se han comentado anteriormente, para poder emplearlos y cumplir con la condición de implementación real del modelo, se decide comprobar las correlaciones cruzadas de los mismos con la variable target (correlaciones de los sucesivos desfases de cada índice).

Se observa que al desfasar los índices hay algunos que reducen su correlación con la demanda eléctrica, pero hay muchos que mantienen valores considerables o incluso la aumentan por lo que se pueden considerar buenas variables explicativas para el modelo. Por todo ello se desfasarán todos los índices 1 mes para su empleo en el modelo, de manera que los índices del mes en curso permitan la obtención de las predicciones a futuro del modelo.

## 6.4. Encoding de variables cíclicas

Este tipo de variables ya se han codificado con anterioridad en el preprocesado previo de las variables climáticas. Para el dataset del modelo se realizará una codificación similar.

A estas variables, al ser cíclicas, se les aplicará una transformación a coordenadas polares descomponiendo cada una en dos nuevas variables (componente seno y coseno) que conjuntamente definen un espacio circular y recogen el sentido cíclico de la variable. De esta manera permitimos al algoritmo del modelo que vea los posibles efectos estacionales entre las observaciones.

Codificamos las variables categóricas cíclicas expresándolas mediante los valores del coseno y el seno de la división de una circunferencia por el número de categorías de la variable.

$$Var\_sin = \sin\left(\frac{variable * 2\pi}{max\_value}\right)$$

$$Var\_cos = \cos\left(\frac{variable * 2\pi}{max\_value}\right)$$

Las variables categóricas cíclicas a codificar son las siguientes:

- Día de la semana (lunes a domingo) - 'Dia\_sem\_SIN', 'Dia\_sem\_COS'
- Nº del mes (1 a 12) - 'N\_mes\_SIN', 'N\_mes\_COS'
- Nº de semana del año (1 a 52-53) - 'N\_semana\_SIN', 'N\_semana\_COS'
- Nº de día del mes (1 a 28-30-31) - 'N\_dia\_mes\_SIN', 'N\_dia\_mes\_COS'

Para todas las codificaciones se han tenido en cuenta los posibles casos dentro de las mismas. Un ejemplo es el distinto número de días en los distintos meses, por ello para la codificación se ha tenido en cuenta el mes al que pertenecía cada observación y así realizar la codificación de forma exacta sin perder ninguna información.

## 6.5. Selección de variables finales para el modelo

Después de realizar la codificación de las variables cíclicas anteriores, el número de variables en el dataset del modelo es de 123 variables desglosadas de la siguiente manera:

- Laboralidad (10)
- Climatología (28, sustitución de las 4 variables iniciales por las 8 variables codificadas)
- Actividad económica (84)

Dado el elevado número de variables explicativas se decide analizarlas para reducir su número y seleccionar las verdaderamente relevantes para el modelo.

Para realizar la selección de variables se revisan las colinealidades y correlaciones entre variables, así como con la variable target. Se calculan los factores de inflación de la varianza ("Variance Inflation Factor", VIF) mediante la librería "Statsmodel" para las variables de las sucesivas selecciones.

En estadística, el factor de inflación de la varianza (VIF) es la relación de la varianza de la estimación de algún parámetro en un modelo que incluye otros múltiples términos (parámetros) por la varianza de un modelo construido utilizando sólo un término. Cuantifica la gravedad de la multicolinealidad en un análisis de regresión por mínimos cuadrados ordinarios y proporciona un índice que mide cuánto aumenta la varianza (el cuadrado de la desviación estándar de la estimación) de un coeficiente de regresión estimado debido a la colinealidad. Por tanto, el VIF obtenido para una variable es alto, entonces la variable explicativa es altamente colineal con las otras variables explicativas y se podrían generar errores en las estimaciones de los modelos.

Aplicando este método se consigue determinar qué variables pueden ser relevantes para el modelo, pasando de las 123 variables explicativas anteriores a 71 (1 categórica y 70 numéricas). Las variables finales a emplear en los modelos son las siguientes:

#### Demanda eléctrica y Previsión de demanda (API Esios)

- **Variable target (1):** DemReal (demanda real)
- **Variable baseline (1):** DemPrevD1 (Demanda prevista D+1)

#### Laboralidad

- **Variables explicativas (12):**

Clasif\_dia / Lab\_previo\_fest / Lab\_post\_fest / Huelga\_General / Dia\_sem\_SIN, Dia\_sem\_COS  
N\_mes\_SIN, N\_mes\_COS / N\_semana\_SIN, N\_semana\_COS / N\_dia\_mes\_SIN, N\_dia\_mes\_COS  
(la variable “Fecha” se incluye ya descompuesta en el dataset)

#### Climatología

- **Variables explicativas (24):** Censo 2011 (asignación de población)  
A3\_Tmax, A3\_Tmin / A4\_Tmax, A4\_Tmin / B3\_Tmax, B3\_Tmin / B4\_Tmax, B4\_Tmin  
C1\_Tmax, C1\_Tmin / C2\_Tmax, C2\_Tmin / C3\_Tmax, C3\_Tmin / C4\_Tmax, C4\_Tmin  
D1\_Tmax, D1\_Tmin / D2\_Tmax, D2\_Tmin / D3\_Tmax, D3\_Tmin / E1\_Tmax, E1\_Tmin  
(incluyen temperaturas máxima y mínima de 143 estaciones AEMET)

#### Actividad económica

- **Sector Industrial, variables explicativas (26):**

Ind\_Indust4, Ind\_Indust5, Ind\_Indust8, Ind\_Indust9, Ind\_Indust11, Ind\_Indust12,  
Ind\_Indust13, Ind\_Indust14, Ind\_Indust15, Ind\_Indust16, Ind\_Indust17, Ind\_Indust19,  
Ind\_Indust21, Ind\_Indust22, Ind\_Indust23, Ind\_Indust24, Ind\_Indust25, Ind\_Indust26,  
Ind\_Indust27, Ind\_Indust30, Ind\_Indust35, Ind\_Indust37, Ind\_Indust40, Ind\_Indust41,  
Ind\_Indust53, Ind\_Indust56

(incluyen Índices de cifras de negocios en la industria e Índices de Producción Industrial)

**- Sector Servicios, variables explicativas (3):**

Ind\_Serv3, Ind\_Serv8, Ind\_Serv10

(incluyen Índices de cifras de negocios en el sector Servicios)

**- Índices del mercado laboral, variables explicativas (2):**

Ind\_Empleo2 / Ind\_Empleo3

(incluyen estadísticas generales de afiliación a la Seguridad Social y de demanda de empleo)

**- Sector de la construcción, variables explicativas (1):**

Ind\_Cemento

(incluye índice de producción de cemento)

**- Índices de Precios de Consumo, variables explicativas (1):**

Ind\_Precios4

(incluyen índices generales de precios de consumo para todos los ámbitos)

**- Índices de fabricación de vehículos, variables explicativas (2):**

Ind\_Fabr1 / Ind\_Fabr2

(incluyen estadísticas generales de la producción nacional de vehículos)

Las variables que más han reducido su número son las referentes a la actividad económica, lo que tiene sentido porque inicialmente se incluyeron todos los índices que pudieran considerarse relevantes para el modelo, pero su número era muy grande.

## 6.6. Análisis del dataset definido para el modelo

Una vez definida la selección de variables para el modelo se realiza un análisis de los datos, revisando: tipos de variables, clases, distribuciones, correlaciones... En este apartado se recogen las principales observaciones del análisis realizado.

### Variable target (DemReal – Demanda eléctrica real)

Se realiza un análisis de la variable target comprobando que, aunque su distribución no es normal, tiene un cierto parecido. Además, se comprueba que la misma no tiene "outliers" y que tiene una muy ligera asimetría negativa, pero muy pequeña.

Se observa una diferencia grande entre el valor mínimo y máximo, pero analizando la fecha de dichos valores mínimos vemos que la mayoría coinciden con los meses de abril y mayo de 2020 que como sabemos coincide con los primeros confinamientos de población en España debido al COVID-19 (es razonable que descendiera tanto la demanda). Por todo ello y dado que la variable no tiene “missing values” se considera correcta y preparada para su utilización en el modelo.

<b>DemReal</b>	Distinct	2905	Minimum	476475
Real number ( $\mathbb{R}_{\geq 0}$ )	Distinct (%)	99.4%	Maximum	847356
<del>HIGH CORRELATION</del>	Missing	0	Zeros	0
<del>HIGH CORRELATION</del>	Missing (%)	0.0%	Zeros (%)	0.0%
<del>HIGH CORRELATION</del>	Infinite	0	Negative	0
	Infinite (%)	0.0%	Negative (%)	0.0%
	Mean	677870.5007	Memory size	23.0 KiB

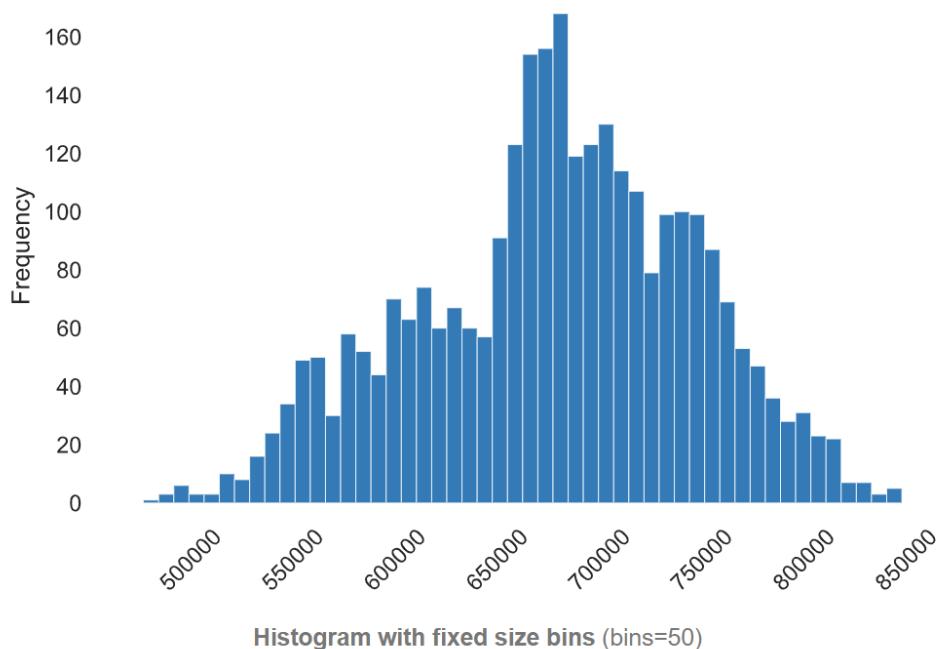


Figura 17. Datos generales e histograma de la variable target “DemReal” (demanda eléctrica)

Adicionalmente se recogen a continuación las estadísticas principales de la variable target:

Quantile statistics	Descriptive statistics
Minimum	476475
5-th percentile	556747.3
Q1	633381.75
median	680361.5
Q3	727349
95-th percentile	783162.2
Maximum	847356
Range	370881
Interquartile range (IQR)	93967.25
	Standard deviation
	0.09995771469
	Kurtosis
	-0.3824612889
	Mean
	677870.5007
	Median Absolute Deviation (MAD)
	46990.5
	Skewness
	-0.2410658534
	Sum
	1980737603
	Variance
	4591198887
	Monotonicity
	Not monotonic

Figura 18. Estadísticos generales de la variable target “DemReal” (demanda eléctrica)

Dado el elevado número de variables se decide analizarlas según los tres grupos principales: laboralidad, climatología y actividad económica.

Para la correcta interpretación de algunos de los gráficos, ya que hay variables cíclicas y que están codificadas en coordenadas polares, se debe tener en cuenta que la clase inicial de cada categoría coincide con Var\_SIN=0 y Var\_COS=1. Teniendo en cuenta el comentario anterior, podemos encontrar relaciones entre variables muy interesantes.

### Laboralidad

Este grupo cuenta con 12 variables:

- 1 var. categórica - "Clasif\_dia" con 7 clases (lunes a domingo).
- 11 vars. numéricas - "Lab\_previo\_fest", "Lab\_post\_fest" y "Huelga\_general" binaria, y el resto numéricas continuas (resultado de la codificación de las vars. categóricas cíclicas).

En las figuras siguientes se representan las distribuciones de las distintas variables:

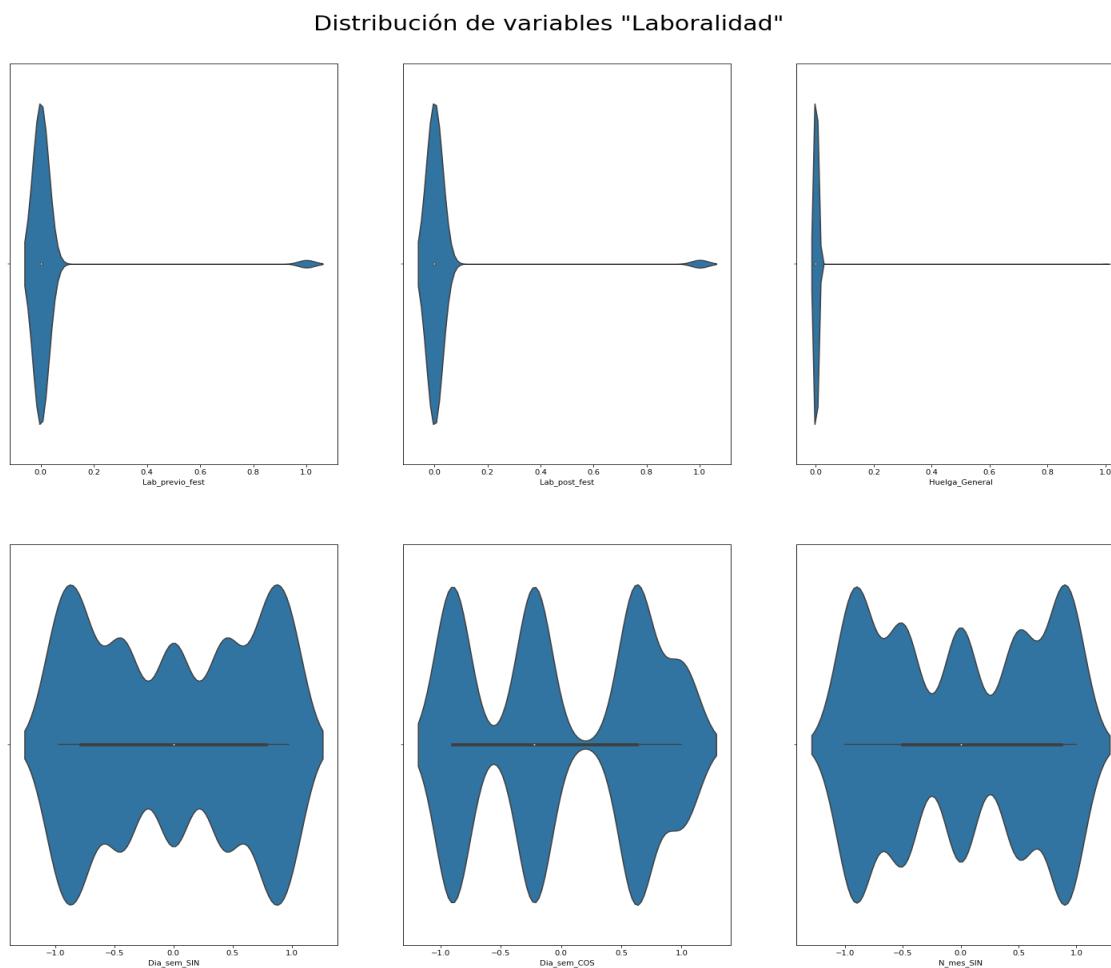


Figura 19. Gráficos tipo "violín" de las distribuciones de vars. "laboralidad"

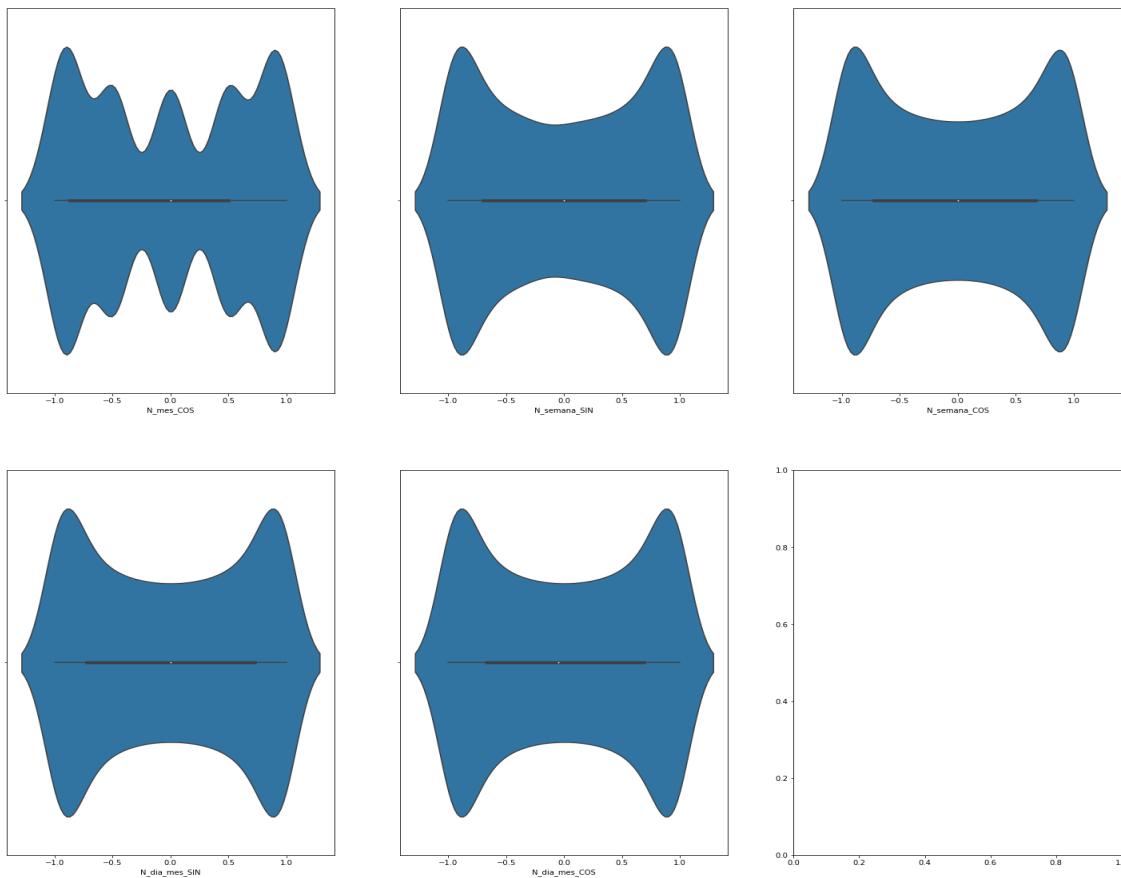


Figura 20. Gráficos tipo “violín” de las distribuciones de vars. “laboralidad”

Se realiza un análisis de las distribuciones para tratar de localizar posibles “outliers” o “missing values”. Salvo las variables “Lab\_previo\_fest”, “Lab\_post\_fest” y “Huelga\_general”, que tienen valores raros pero explicables ya que representan días especiales del calendario, el resto de variables no presenta “outliers”. Por todo ello y dado que las variables no tienen “missing values” se consideran correctas y preparadas para su utilización en el modelo.

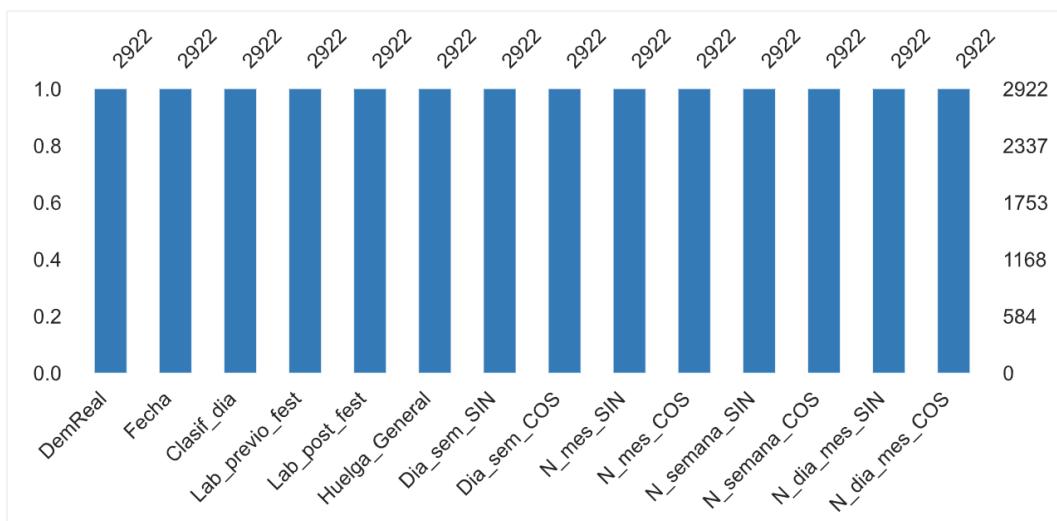


Figura 21. Tabla de “missing values” de las vars. “laboralidad”

Adicionalmente se comprueban posibles correlaciones con la variable target:

### ***DemReal - Dia\_sem***

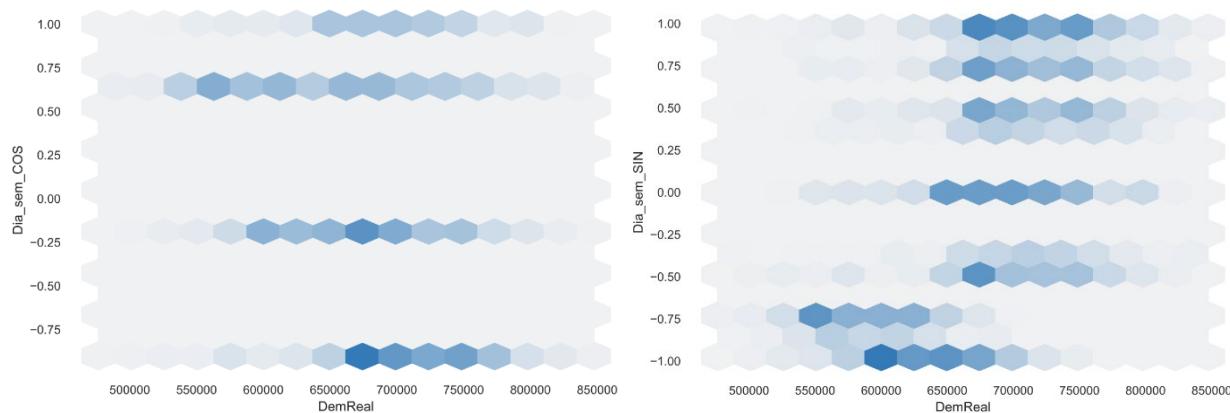


Figura 22. Gráficos de interacción DemReal - Dia\_sem

Se observa como la demanda eléctrica durante el fin de semana desciende (valores cercanos a Var\_SIN=0 y Var\_COS=1), volviendo a aumentar conforme avanza la semana.

### ***DemReal - N\_dia\_mes***

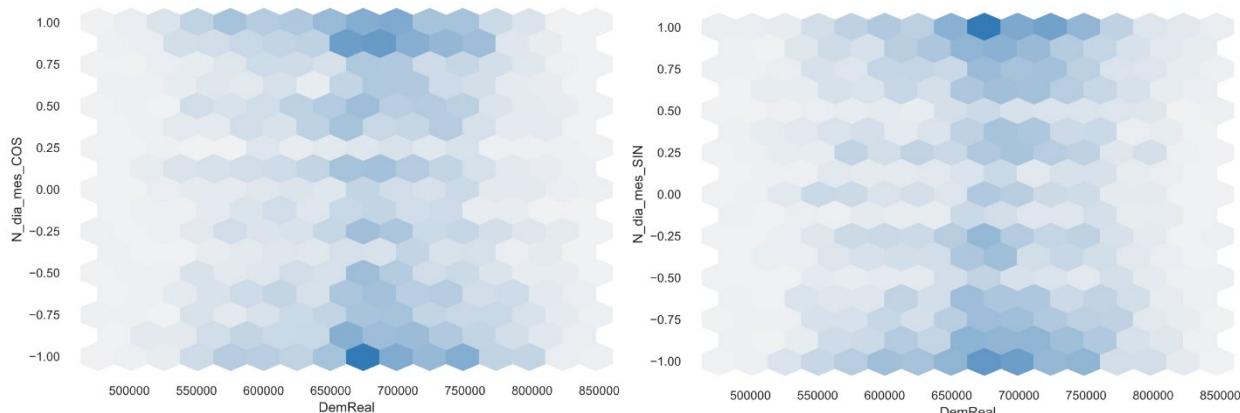


Figura 23. Gráficos de interacción DemReal - N\_dia\_mes

La relación en esta variable no es muy clara pero sí se observa una mayor estabilidad en la demanda eléctrica en los inicios y finales de mes (valores cercanos a Var\_SIN=0 y Var\_COS=1) frente a una distribución más heterogénea en los días entre medias.

### ***DemReal - N\_mes***

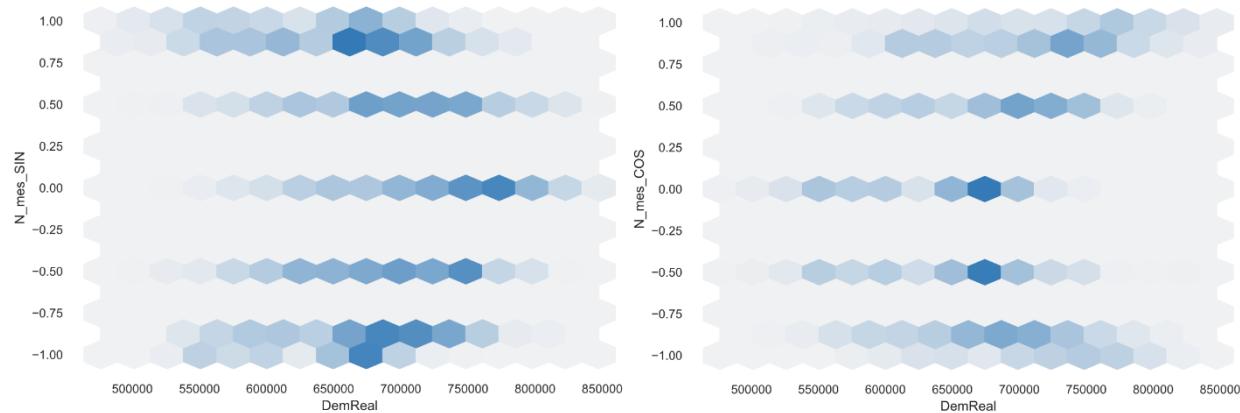


Figura 24. Gráficos de interacción DemReal - N\_mes

Se observa como la demanda eléctrica es mayor durante los meses iniciales y finales del año (valores cercanos a Var\_SIN=0 y Var\_COS=1) descendiendo en los centrales que coinciden con el verano y las vacaciones, lo cual es razonable.

### ***DemReal - N\_semana***

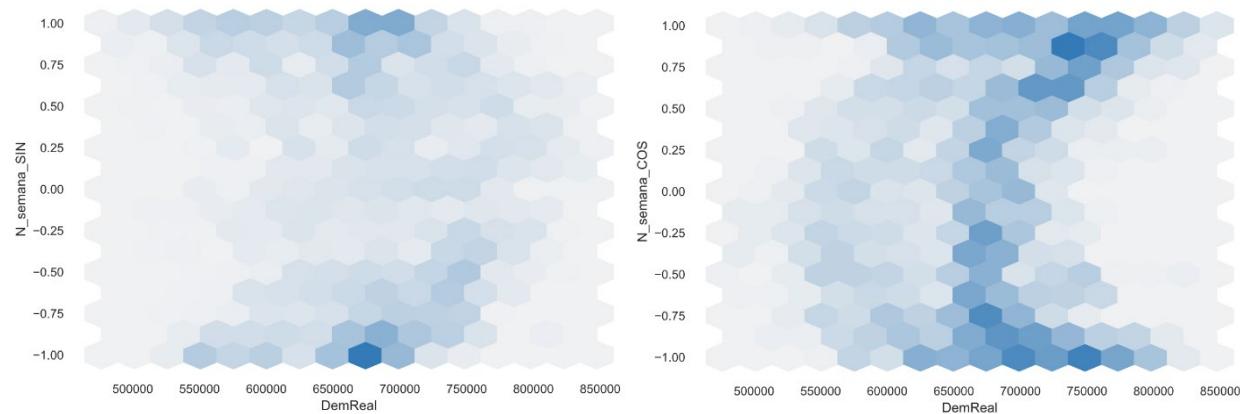


Figura 25. Gráficos de interacción DemReal - N\_semana

Se observa el mismo fenómeno que en la variable anterior, la demanda eléctrica es mayor durante las semanas iniciales y finales del año (valores cercanos a Var\_SIN=0 y Var\_COS=1) descendiendo en las centrales que coinciden con el verano y las vacaciones, lo cual es razonable.

### Climatología

Este grupo cuenta con 24 variables, todas ellas numéricas continuas. En la figura siguiente se representan las distribuciones de las distintas variables:



Figura 26. Gráficos tipo "violín" de las distribuciones de vars. "climatología"

En las distribuciones de las variables se observa que la mayoría suelen tener máximos a uno o ambos lados del eje central, esto puede deberse a las estaciones de invierno y verano, ya que suelen ser más frecuentes las temperaturas más bajas y más altas respectivamente. Los casos en los que no se cumple esta condición pueden deberse a que son zonas con climas más suaves, sin tantos contrastes entre estaciones.

Se realiza un análisis de las distribuciones para tratar de localizar posibles "outliers" o "missing values". Se comprueba que ninguna de las variables presenta "outliers". Por todo ello y dado que las variables no tienen "missing values" (su tratamiento se realizó anteriormente), se consideran correctas y preparadas para su utilización en el modelo.

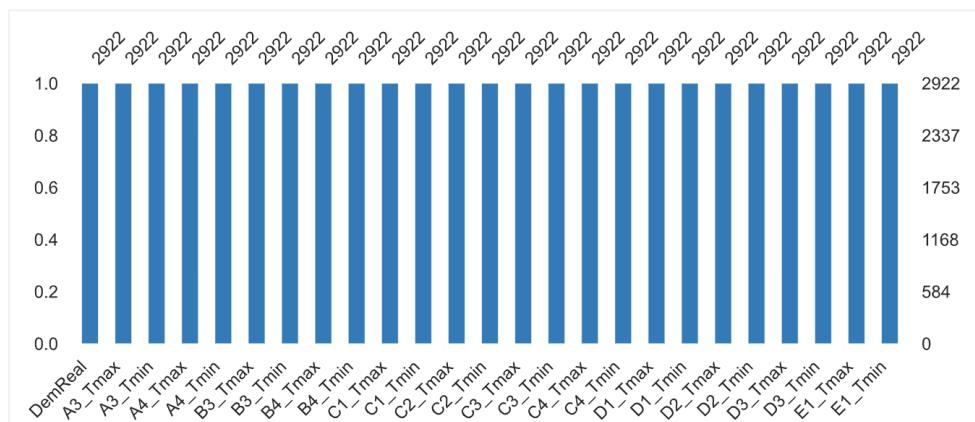


Figura 27. Tabla de "missing values" de las vars. "climatología"

Adicionalmente se comprueban posibles correlaciones con la variable target y se comprueba un comportamiento constante en todas ellas (se adjuntan ejemplos de varias de las variables). Como se puede observar, el aumento de la demanda eléctrica se produce en dos casos: cuando la temperatura alcanza valores altos y cuando desciende a valores bajos. Este fenómeno se ha explicado en apartados anteriores y se debe al uso de aparatos de climatización: la calefacción en invierno y el aire acondicionado en verano. El consumo de energía por parte de estos equipos es mayor cuanto menor sea la temperatura en invierno y cuánto mayor sea la temperatura en verano. En los meses más fríos, un aumento de la temperatura llevará a un menor uso de la electricidad, debido al menor uso de la calefacción. Por el contrario, en los meses cálidos, este aumento de temperatura llevará a un aumento del uso del aire acondicionado y por tanto a un aumento en la demanda de energía eléctrica.

#### ***DemReal - B3\_Tmax, B3\_Tmin***

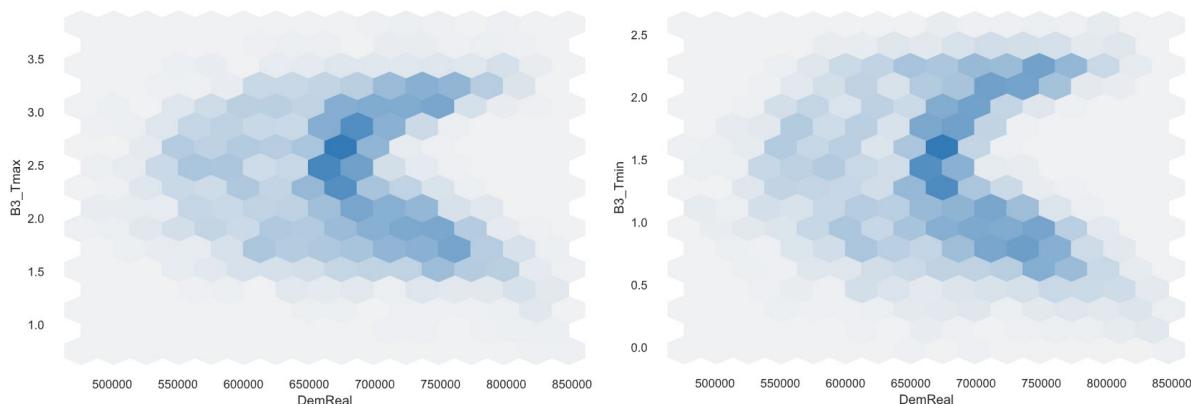


Figura 28. Gráficos de interacción DemReal - B3\_Tmax, B3\_Tmin

### ***DemReal - C2\_Tmax, C2\_Tmin***

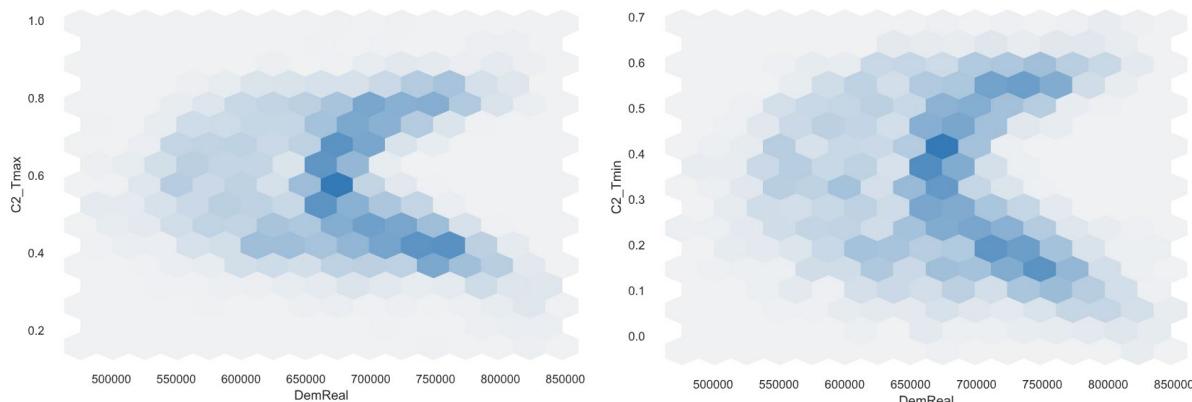


Figura 29. Gráficos de interacción DemReal - C2\_Tmax, C2\_Tmin

### ***DemReal - D2\_Tmax, D2\_Tmin***

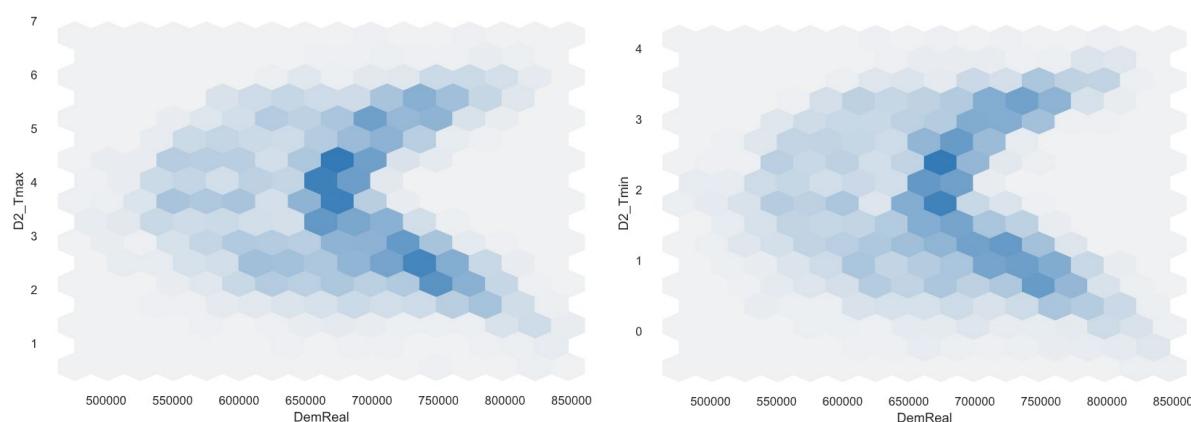


Figura 30. Gráficos de interacción DemReal - D2\_Tmax, D2\_Tmin

### ***DemReal - E1\_Tmax, E1\_Tmin***

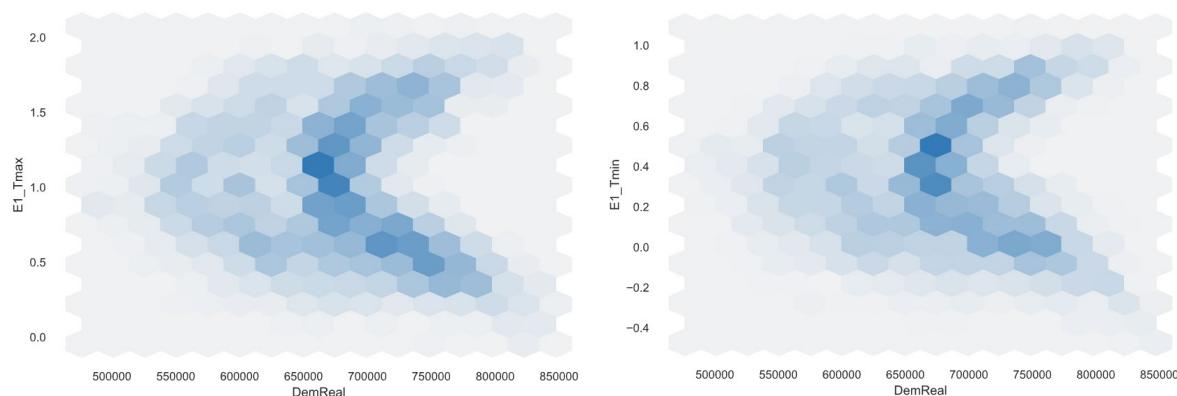


Figura 31. Gráficos de interacción DemReal - E1\_Tmax, E1\_Tmin

### Actividad económica

Este grupo cuenta con 24 variables, todas ellas numéricas continuas.

- Sector Industrial (26)
- Sector Servicios (3)
- Índices del mercado laboral (2)
- Sector de la construcción (1)
- Índices de Precios de Consumo (1)
- Índices de fabricación de vehículos (2)

En las figuras siguientes se representan las distribuciones de las distintas variables:

Distribución de variables "Actividad económica"

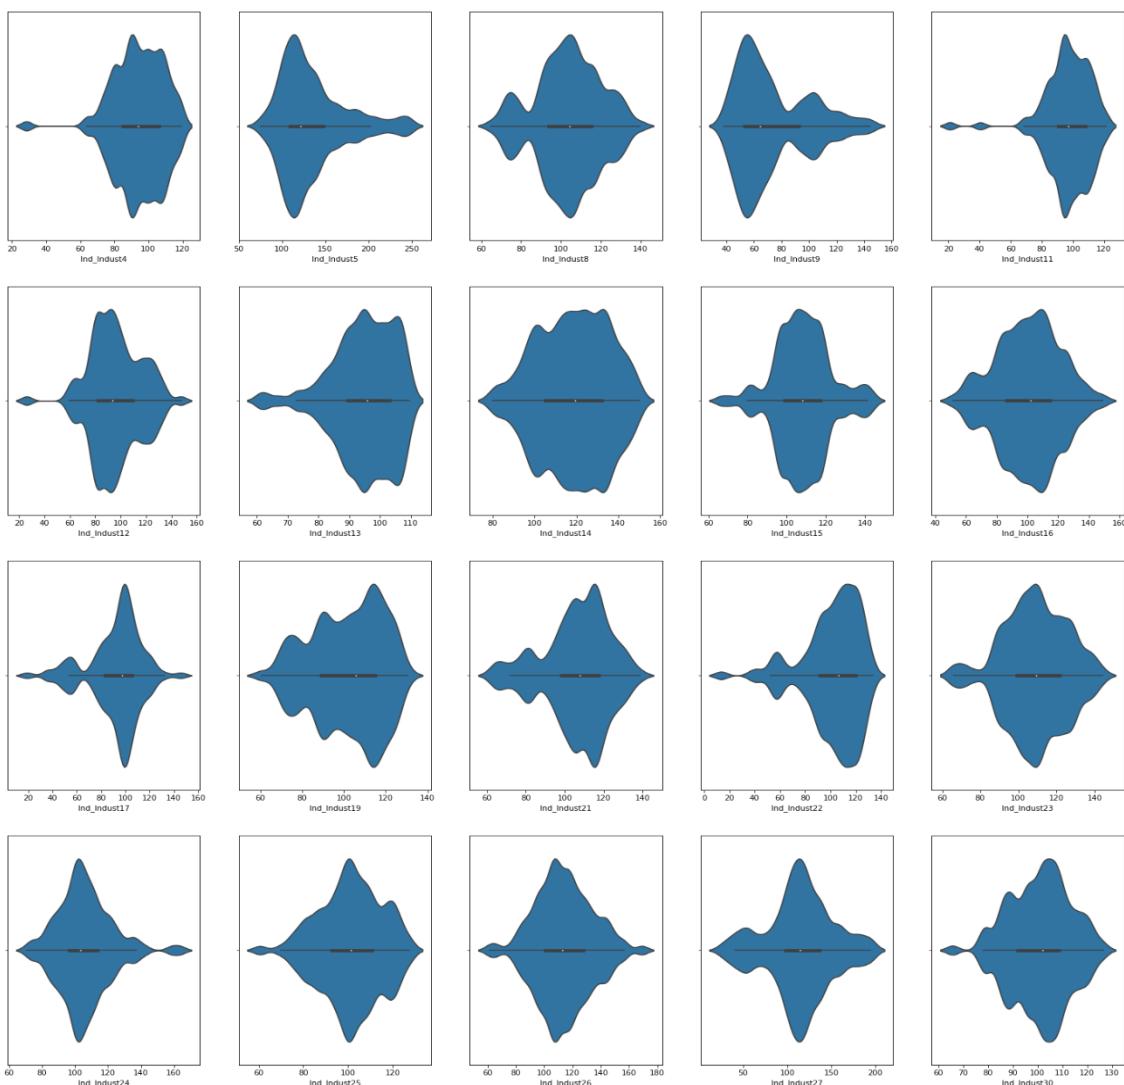


Figura 32. Gráficos tipo “violín” de las distribuciones de vars. “actividad económica”

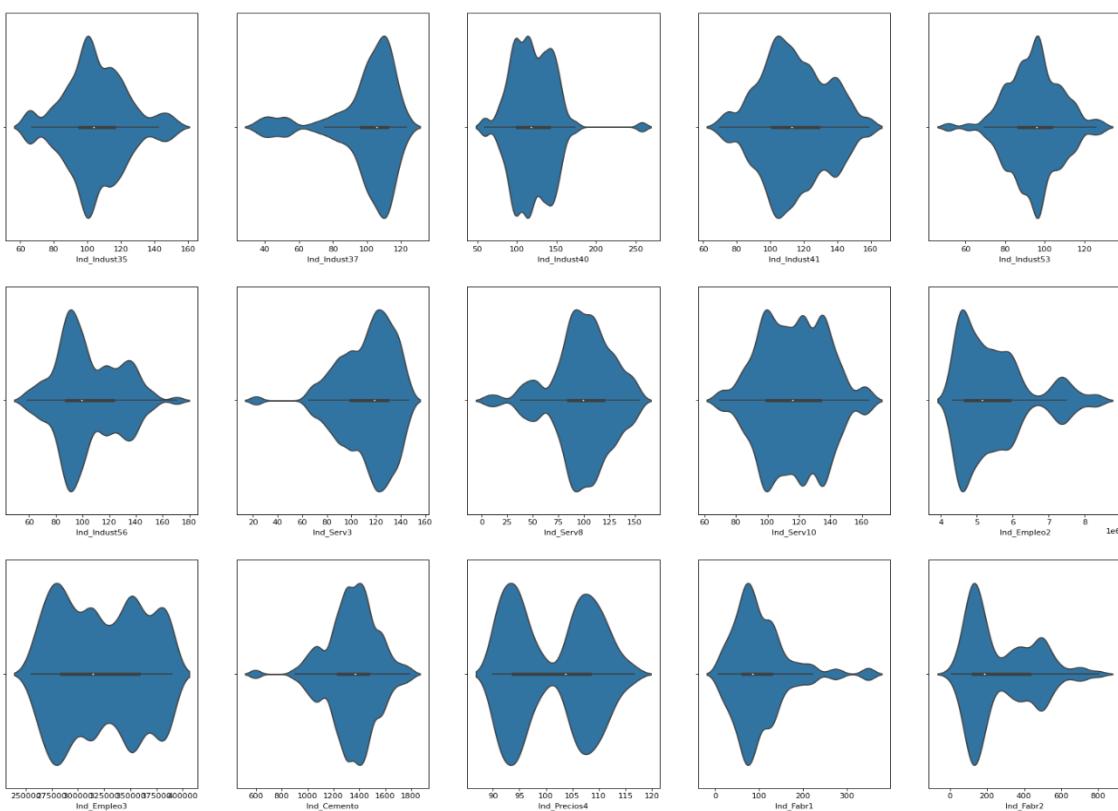


Figura 33. Gráficos tipo “violín” de las distribuciones de vars. “actividad económica”

Se realiza un análisis de las distribuciones para tratar de localizar posibles “outliers” o “missing values”. Se observan algunas variables con valores extremos, pero tras revisarlos se comprueba que son valores correctos de las variables, pudiendo considerar por tanto que las variables no presentan “outliers”. Por todo ello y dado que las variables no tienen “missing values” se consideran correctas y preparadas para su utilización en el modelo.

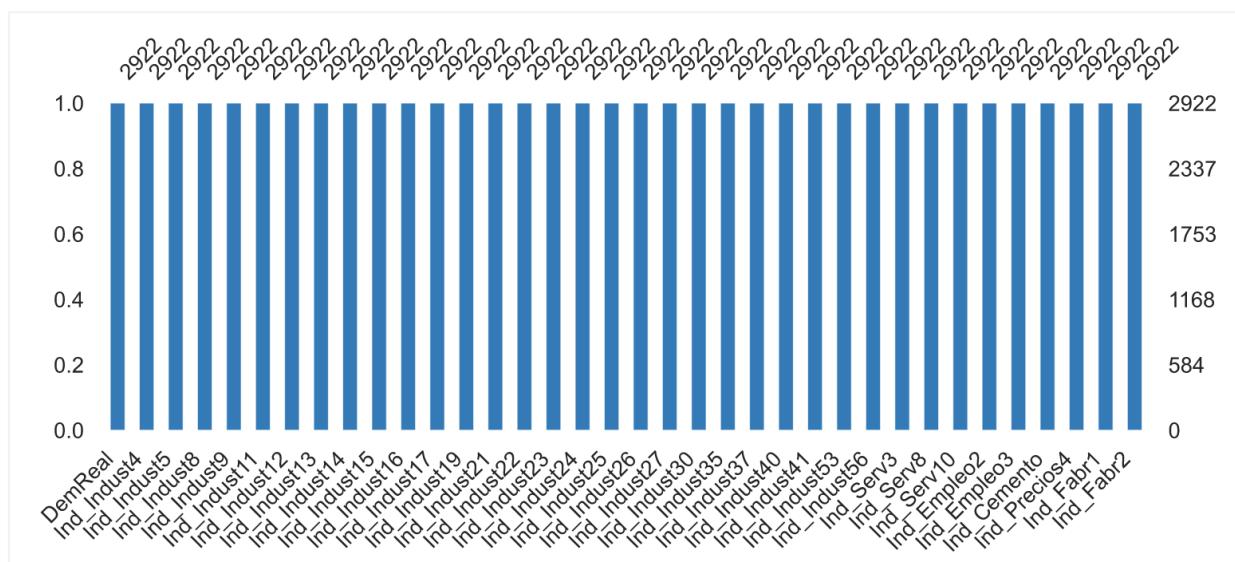


Figura 34. Tabla de “missing values” de las vars. “actividad económica”

Adicionalmente se comprueban las posibles correlaciones con la variable target. Tras el estudio de las mismas se puede observar algunas relaciones, pero en ningún caso son tan claras como en los casos anteriores.

### ***DemReal - Ind\_Indust21***

La variable “Ind\_Indust21” se corresponde con el índice industrial de “Fabricación de maquinaria y equipo n.c.o.p.”.

Aunque no es muy clara, se puede observar una cierta relación directa, de manera que el aumento del índice suele estar relacionado con el aumento de la demanda eléctrica.

Esto tendría sentido ya que el aumento de la producción industrial conlleva un aumento de la demanda eléctrica (ya comentado en apartados anteriores).

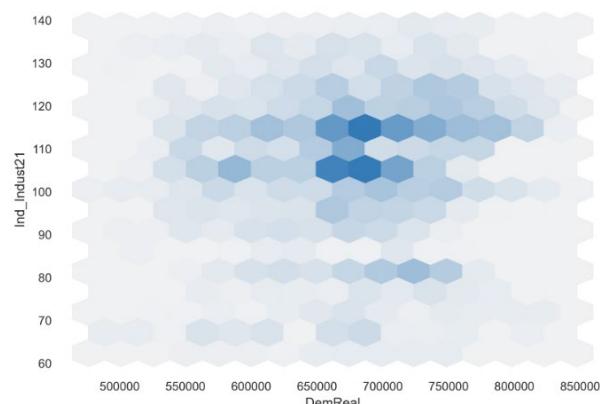


Figura 35. Gráfico de interacción DemReal - Ind\_Indust21

### ***DemReal - Ind\_Empleo2***

La variable “Ind\_Indust21” se corresponde con el índice de empleo de “Demanda de empleo efectiva o pendiente”.

Aunque no es muy clara, se puede observar una cierta relación inversa, de manera que el descenso del índice suele estar relacionado con el aumento de la demanda eléctrica.

Esto tendría sentido ya que el descenso de las tasas de desempleo está relacionado con una mejora en la actividad económica, crecimiento del PIB, aumento de la producción industrial...

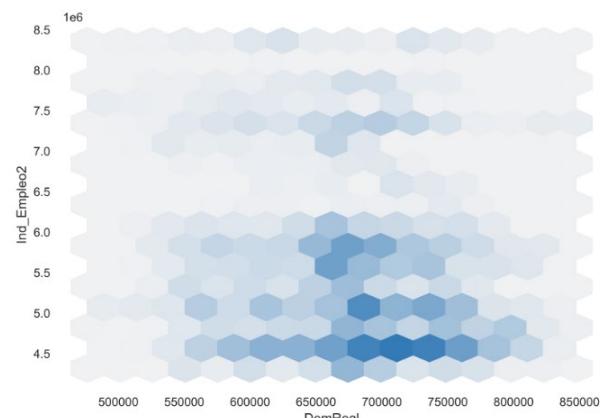


Figura 36. Gráfico de interacción DemReal - Ind\_Empleo2

### ***DemReal - Ind\_Cemento***

La variable “Ind\_Cemento” se corresponde con el índice del sector de la construcción relativo a la “Producción de cemento”.

Aunque no es muy clara, se puede observar una cierta relación directa, de manera que el aumento del índice suele estar relacionado con el aumento de la demanda eléctrica.

Esto tendría sentido ya que el aumento de la producción de materiales de construcción conlleva un aumento de la demanda eléctrica (ya comentado en apartados anteriores).

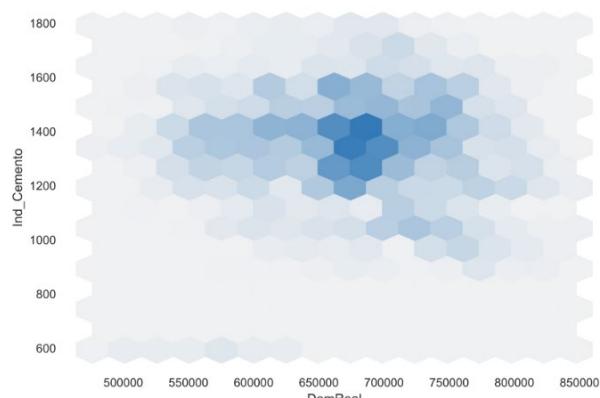


Figura 37. Gráfico de interacción DemReal - Ind\_Cemento

Como se ha comentado con anterioridad, no son relaciones muy claras por lo que pueden tomarse como comentarios sobre las variables.

## 7. METODOLOGÍA EMPLEADA

Los modelos desarrollados han sido de dos tipos: ensambles y redes neuronales. En este apartado se analizan los métodos utilizados y se define el preprocesado necesario que se ha realizado para cada tipo de modelo.

### 7.1. Modelos ML (RF-GB-XG)

#### Modelos Machine Learning (Ensembles)

Estos modelos pueden considerarse como más convencionales, pero son muy utilizados y la mejor solución en infinidad de casos que precisan de machine learning para su resolución. A priori para este tipo de problemas no deberían ser los métodos más idóneos, pero por ello se han escogido, para comprobarlo. De entre los métodos de “ensambles” conocidos se han escogido los considerados más potentes y los más utilizados en la actualidad: “Random Forest”, “Gradient Boosting” y “XGBoost”. Los tres modelos permiten su uso tanto en problemas de regresión como de clasificación.

Los tres modelos, aunque con distintas aproximaciones teóricas, están basados en árboles de decisión y tienen el mismo objetivo: combinar predicciones de varios estimadores base para construir un regresor/clasificador más robusto y con mayor capacidad de generalización que los estimadores bases. Los modelos escogidos se dividen según el tipo de ensemble en:

- **Métodos “bagging” (Random Forest)** se construyen varios estimadores y se promedian sus predicciones (combinación reduce la varianza del modelo final).
- **Metodos “boosting” (Gradient Boottng y XGBoost)** ajuste sucesivo de modelos, cada uno de los cuales asigna mayor peso a las observaciones peor predichas por los modelos previos (combinación reduce el sesgo del modelo final).

#### Modelos ML “RANDOM FOREST” - “GRADIENT BOOSTING” - “XGBOOST”

Como ya se ha comentado, todos estos modelos están basados en árboles de decisión por lo que el preprocesado de variables y la definición del pipeline para el modelo se ha definido de manera conjunta. Para la definición de los modelos se ha empleado la librería “Scikit Learn” debido a su funcionalidad y facilidad de uso. Lo único que cambia para cada modelo es la función del predictor de “Scikit Learn”.

En el presente apartado se recogen los pasos realizados para montar el modelo:

- Carga del dataset (2922 observaciones con 1 var. target y 71 vars. explicativas).
- División del dataset en subconjuntos de “train” y “test” (años 2014 a 2020 con 2557 obs. y año 2021 con 365 observaciones).
- Análisis de variables (tras el preprocesado del dataset se cuenta con 70 variables numéricas y sólo 1 variable categórica, muchas han sido codificadas con anterioridad).

- Preprocesado de las vars. explicativas:

- **Vars. numéricas** - se realizará un escalado de las variables numéricas para evitar que los diferentes órdenes de magnitud influyan de manera muy marcada en las predicciones realizadas por el modelo.
- **Var. categórica** - se transforman las categorías de la variable en variables "dummy" mediante la herramienta "One Hot Encoder".

- Métricas (se define una función para obtener las 3 métricas a considerar en los modelos).

- Preparación de los "pipelines" de los modelos (se definen 2 "tuberías" independientes para el tratamiento de las vars. numéricas y categóricas respectivamente, combinándolas previamente a su introducción en el algoritmo).

- Optimización de hiperparámetros (realizadas 2 optimizaciones, explicadas en el apartado 8)

- Ejecución de los modelos y obtención de resultados (recogido en el apartado 9).

## 7.2. Modelos RRNN (MLP-LSTM)

### Modelos de Redes Neuronales

Las redes neuronales son modelos que, pese a no ser modernos, han sufrido importantes avances en los últimos 10 años que han permitido mejorar exponencialmente su capacidad y aumentar sus casos de uso. Para este tipo de problemas ya se están empleando y dan buenos resultados.

Dentro de los tipos de redes neuronales se han escogido: un tipo básico como es el perceptrón multicapa ("MultiLayer Perceptron" - MLP) y otro más complejo orientado además a su empleo con series temporales como son las redes neuronales recurrentes ("Long Short-Term Memory" - LSTM). Estos últimos modelos deberían funcionar mejor y son entre otros, modelos del estado del arte en este tipo de problemas.

De los modelos definidos, pese a ser ambos redes neuronales, se diferencian claramente y cabe destacar de los mismos algunas características importantes:

-**Multilayer Perceptron (MLP)** también conocido como Red Backpropagation (Backpropagation Net, BPN) es uno de los modelos de red neuronal más conocidos. Pertenecen a la clase de las denominadas redes no realimentadas o «feedforward», su topología es la de un sistema neuronal estructurado en capas donde la información siempre fluye desde la capa de entrada, cuyo único papel es el de enviar los datos de entrada al resto de la red, hacia la de salida, atravesando la capa o capas ocultas.

Esencialmente son las capas internas las encargadas de realizar el procesamiento de la información, extrayendo rasgos característicos de los datos de entrada. Aunque existen multitud de variantes, normalmente cada neurona de una capa se conecta a todas las neuronas de la capa siguiente; sin embargo, no existe conexión, ni por tanto interacción, entre las neuronas de una misma capa.

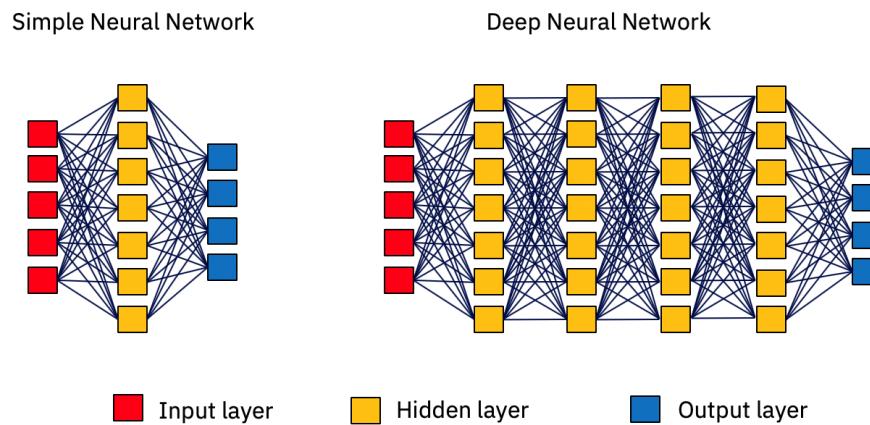


Figura 38. Esquemas de redes neuronales convencionales (simples y profundas)

- **Long Short-Term Memory (LSTM)** son un tipo especial de redes recurrentes. La característica principal de las redes recurrentes es que la información puede persistir introduciendo bucles en el diagrama de la red, por lo que, básicamente, pueden “recordar” estados previos y utilizar esta información para decidir cuál será el siguiente. Esta característica las hace muy adecuadas para manejar series cronológicas. Mientras las redes recurrentes estándar pueden modelar dependencias a corto plazo (es decir, relaciones cercanas en la serie cronológica), las LSTM pueden aprender dependencias largas, por lo que se podría decir que tienen una «memoria» a más largo plazo.

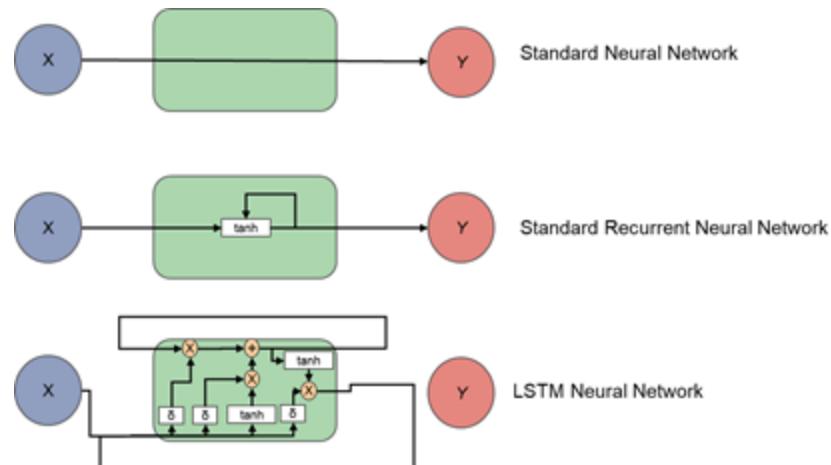


Figura 39. Comparativa de esquemas de redes neuronales: estándar, recurrentes y “LSTM”

### Modelos RRNN “MLP” - “LSTM”

Ambos modelos, debido a su naturaleza comparten la mayor parte del preprocesado de las variables, aunque la composición final de los datos varía, como se explicará a continuación. Para la definición de las redes se ha empleado la librería “Keras” debido a su funcionalidad y facilidad de uso para el desarrollo de redes neuronales. Cabe destacar además el uso de “Google Colab” para la definición y entrenamiento de estas redes, lo que ha supuesto una reducción de tiempo y una mejora en la capacidad de procesamiento.

En el presente apartado se recogen los pasos realizados para montar el modelo:

- Carga del dataset (2922 observaciones con 1 var. target y 71 vars. explicativas).
- División del dataset en subconjuntos de “train” y “test” (años 2014 a 2020 con 2557 obs. y año 2021 con 365 observaciones).
- Análisis de variables (tras el preprocessado del dataset se cuenta con 70 variables numéricas y sólo 1 variable categórica, muchas han sido codificadas con anterioridad).
- Preprocessado de las vars. explicativas:
  - **Vars. numéricas** - se realizará un escalado de las variables numéricas para evitar que los diferentes órdenes de magnitud influyan de manera muy marcada en las predicciones realizadas por el modelo.
  - **Var. categórica** - se transforman las categorías de la variable en variables “dummy” mediante la herramienta “One Hot Encoder”.
- Composición final de los datos para su implementación en los modelos:
  - **Red “MLP”** - es necesario transformar los datos a estructura de “timeseries”.
  - **Red “LSTM”** - es necesario transformar los datos a estructura “3D”.
- Métricas (se define una función para obtener las 3 métricas a considerar en los modelos).
- Def. de la arquitectura de las redes neuronales (explicado en el apartado 8)
- Optimización de hiperparámetros (explicado en el apartado 8)
- Ejecución de los modelos y obtención de resultados (recogido en el apartado 9).

## 8. OPTIMIZACIÓN DE MODELOS

Una vez definidos los modelos a utilizar, preparados los datos y montado el pipeline para el modelo, se debe realizar la optimización de los hiperparámetros del mismo. En el caso de estos modelos se ha optado por utilizar la librería de optimización “Optuna” para Python.

Esta librería permite incluir el pipeline y la métrica del modelo en una función a la que se facilitan rangos de valores para los hiperparámetros del modelo. La librería cuenta con varios tipos de algoritmos, pero lo que hacen en esencia todos, es escoger unos hiperparámetros iniciales para el modelo dentro de los rangos definidos e ir iterando, probando nuevas combinaciones siempre teniendo en cuenta las pruebas anteriores, y buscando mejorar la métrica definida para el modelo. El número de pruebas es también definido por el usuario. No es una forma de optimización muy precisa, pero en el presente caso ha supuesto un ahorro considerable de tiempo y capacidad computacional.

Para evitar la posibilidad de alcanzar un máximo local y no lograr la mejor optimización se optó por realizar una primera optimización muy amplia para luego, con los resultados obtenidos, realizar una optimización más precisa. Los datos incluidos en este apartado son los resultados de esa segunda optimización más precisa.

Para esta segunda optimización de los modelos se han seguido estos parámetros generales:

**Métrica de optimización\_ R2**  
**Nº de iteraciones\_ 100**

## 8.1. Modelos ML (RF-GB-XG)

### Modelo ML “RANDOM FOREST”



Figura 40. Visualizaciones de la optimización del Modelo ML – “Random Forest”

Como se puede observar los modelos con mejores métricas son aquellos con: profundidad en torno a 50, 23-25 como nº máximo de vars. consideradas, 3 como nº mínimo de obs. para hacer un Split y en torno a 100 estimadores para el ensemble. En este modelo definido la variabilidad de los resultados depende principalmente del hiperparámetro ‘max\_features’ y en bastante menor medida de “n\_estimators”.

El modelo “Random Forest” que se empleará tendrá los siguientes parámetros:

- ‘max\_depth’ = 49
- ‘max\_features’ = 24
- ‘min\_samples\_split’ = 3
- ‘n\_estimators’ = 74

### Modelo ML “GRADIENT BOOSTING”

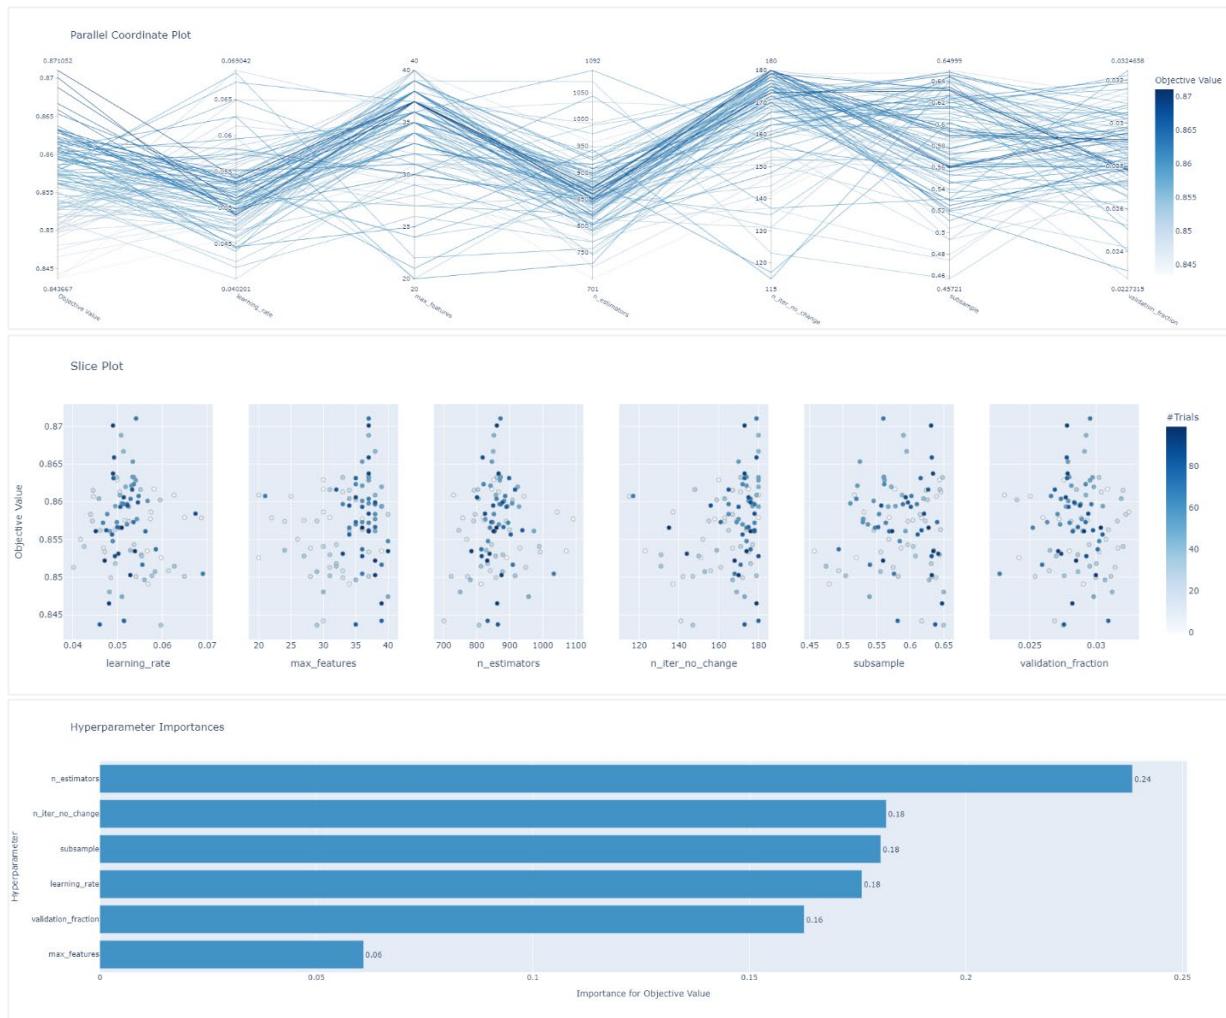


Figura 41. Visualizaciones de la optimización del Modelo ML – “Gradient Boosting”

Como se puede observar los modelos con mejores métricas son aquellos con: tasas de aprendizaje bajas, entre 35-40 como nº máximo de vars. consideradas, en torno a 800-900 estimadores, máximo de 180 iteraciones sin mejora. Las variables “sample” y “validation\_fraction”, el porcentaje de muestreo y el del subconjunto de validación respectivamente toman valores un poco más fluctuantes. Además, la dependencia de los resultados obtenidos está mucho muy distribuida entre los distintos hiperparámetros.

El modelo “Gradient Boosting” que se empleará tendrá los siguientes parámetros:

- ‘learning\_rate’ = 0.05
- ‘n\_estimators’ = 872

- 'subsample' = 0.56
- 'max\_features' = 37
- 'validation\_fraction' = 0.03
- 'n\_iter\_no\_change' = 179

### Modelo ML “XGBOOST”



Figura 42. Visualizaciones de la optimización del Modelo ML – “XGBoost”

Como se puede observar los modelos con mejores métricas son aquellos con: “colsample\_bylevel” y “colsample\_bytree” de en torno a 0.50-0.55 y 0.98 respectivamente, “gamma” en torno a 0.80-0.85, nº de estimadores en torno a 2500 y muestreo de datos en torno a 0.15-0.20. Las variables relativas a la tasa de aprendizaje y la profundidad, toman valores un poco más fluctuantes. La dependencia de los resultados obtenidos está bastante distribuida entre las distintos hiperparámetros, aunque destacan por encima de los demás “subsample” y “min\_child\_weight”.

El modelo “XGBoost” que se empleará en los modelos finales tendrá los siguientes parámetros:

- 'learning\_rate' = 0.02
- 'max\_depth' = 663
- 'n\_estimators' = 3276
- 'subsample' = 0.16

- 'min\_child\_weight'= 0.47
- 'gamma' = 0.81
- 'subsample' = 37
- 'colsample\_bylevel' = 0.50
- 'colsample\_bytree' = 0.97

## 8.2. Modelos RRNN (MLP-LSTM)

A diferencia de los modelos de machine learning convencionales anteriores, la optimización de las redes neuronales desarrolladas se ha realizado de una forma un poco más manual. Se parte definiendo y probando distintas arquitecturas para, una vez encontrada la que proporciona en promedio los mejores resultados y más estables, pasar a la optimización de los hiperparámetros restantes. Se ha tratado de buscar información acerca de arquitecturas “arquetipo” que pudieran funcionar mejor para el caso del presente trabajo, pero no se encontró, por lo que el ajuste se ha realizado en base a las pruebas realizadas.

La idea es, partiendo de redes básicas (1 capa de 100 neuronas), realizar pruebas para comprobar las arquitecturas más idóneas para el caso y el modelo desarrollado. A continuación, se recogen las observaciones de dichas pruebas y se definen la arquitectura e hiperparámetros finales de ambas redes neuronales.

### Modelo RN “MLP”

La arquitectura de partida en esta red fue de 1 capa oculta con 100 neuronas. Tras las sucesivas pruebas se comprobaron los hechos que se recogen a continuación y que acabaron definiendo la arquitectura final de la red que se puede observar en la figura.

#### - Nº de capas

Se partió de 1 sola capa oculta, pero ésta no permitía complejidad suficiente a la red como para poder aprender y ajustarse al problema. A partir de la 2 capa los resultados mejoraron considerablemente hasta alcanzar sus máximos con las 3 capas finales. Las pruebas con 4 capas ocultas no mostraron una mejora en los resultados por lo que se decidió optar por la arquitectura más sencilla posible.

#### - Nº de neuronas

Se partió de 1 sola capa con 100 neuronas, pero el número de neuronas unido al hecho de tener sólo una capa oculta no permitía complejidad suficiente a la red como poder aprender y ajustarse al problema. Conforme se iban añadiendo capas se fueron probando distintos números de neuronas: 500, 1000, 1000-500, 2000-1000, 2000-1000-500, 4000-2000-1000, etc., hasta alcanzar la arquitectura más estable y que mejores resultados ha dado.

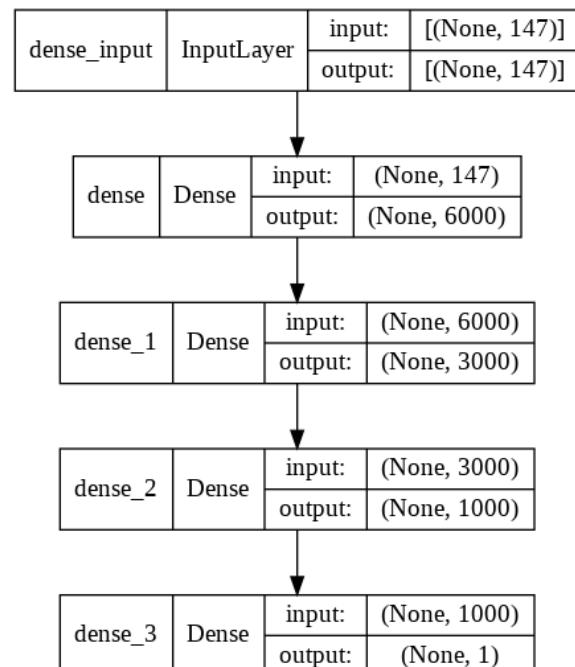


Figura 43. Esquema red Modelo RRNN – “MLP”

### - Capas de “dropout”

Durante las pruebas se definieron capas de “dropout” dentro de la red, aplicando porcentajes muy pequeños del mismo tanto de manera homogénea en todas las capas (todas con 0,01 ó 0,05) como con porcentajes decrecientes desde las iniciales hasta las más profundas (0,10-0,05-0,01). Se probaron muchos valores, pero ninguno resultaba óptimo para la red, no reducían el “overfitting” de la misma, tan sólo empeoraban considerablemente su aprendizaje sin que este pudiera recuperarse aumentando el número de épocas.

### - Nº de épocas

Se partió de un número reducido de iteraciones (25/50) para comprobar las arquitecturas, pero una vez éstas se fueron definiendo, se aumentó su número comprobándose que los mejores resultados se obtenían entre las 200 y 300 épocas. Se decidió optar finalmente por 300 épocas porque se consiguen en promedio resultados mejores con esas redes. Al aumentar el nº de épocas se aumenta ligeramente el “overfitting” de la red, pero dado que éste último en el mejor modelo obtenido se encuentra entre R2\_train=0,9952 y R2\_test=0.9383, puede considerarse asumible.

### - Tamaño del “batch”

Dada la naturaleza de los datos (serie temporal) se han probado tamaños de “batch” en concordancia: 1, 7, 30, 60, 90, etc. Se comprueba que definiendo un tamaño de 7 se consiguen los mejores resultados, muy ligeramente por encima de un tamaño 30, pero con un coste computacional y de tiempo mucho mayor. Por este hecho finalmente se define el tamaño en 30.

Teniendo en cuenta todas las conclusiones anteriores se pudieron la arquitectura e hiperparámetros finales de la red.

**Red tipo:** “MultiLayer Perceptron – MLP”

**Nº de capas ocultas:** 3

**Nº de neuronas (capas ocultas):** 6000-3000-1000

**Capas de dropout:** Ninguna

**Nº de épocas:** 300

**Tamaño del “batch”:** 30

### Modelo RN “LSTM”

La arquitectura de partida en esta red fue de 1 capa oculta con 100 neuronas. Tras las sucesivas pruebas se comprobaron los hechos que se recogen a continuación y que acabaron definiendo la arquitectura final de la red que se puede observar en la figura.

#### - Nº de capas

Se partió de 1 sola capa oculta, ésta ya contaba con capacidad suficiente para poder aprender y ajustarse al problema. Adicionalmente se probó con 2 y 3 capas, comprobando que los mejores resultados y más estables se obtenían con la arquitectura de 2 capas. La utilización de 3 capas generaba mayor “overfitting” y no mejoraba el modelo por lo que se decidió optar por la arquitectura más sencilla posible.

#### - Nº de neuronas

Se partió de 1 sola capa con 100 neuronas y con ello el modelo era capaz de obtener buenos resultados. Se probaron más combinaciones de neuronas incluyendo versiones de 1, 2 y 3 capas, aunque tras ver los resultados del modelo se tendió a las pruebas con 1 y 2 capas: 25, 50, 100, 50-25, 100-100, 150-150, etc. Se comprueba que los mejores modelos de 1 capa se encuentran entre 25 y 50 neuronas, y los de 2 capas entre 100 y 200 para ambas capas.

#### - Capas de “dropout”

Durante las pruebas se definieron capas de “dropout” dentro de la red, aplicando porcentajes muy pequeños del mismo tanto de manera homogénea en todas las capas (todas con 0,01 o 0,05) como con porcentajes decrecientes desde las iniciales hasta las más profundas (0,10-0,05-0,01). Se probaron muchos valores, pero ninguno resultaba óptimo para la red, no reducían el “overfitting” de la misma, tan sólo empeoraban considerablemente su aprendizaje sin que este pudiera recuperarse aumentando el número de épocas.

#### - Nº de épocas

Se partió de un número reducido de iteraciones (25/50) para comprobar las arquitecturas, pero se constató que con 25 iteraciones era suficiente para que la red aprendiera y proporcionaría buenas predicciones. Se probó con un mayor número de iteraciones (50, 100 y 150) pero los resultados fueron un mayor “overfitting” del modelo sin una mejora razonable de las predicciones. Por ello se decide mantener un número bajo de iteraciones.

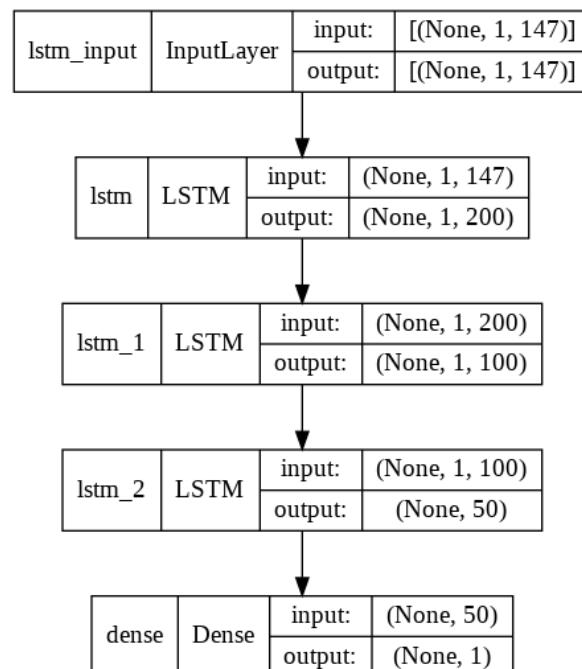


Figura 44. Esquema red Modelo RRNN – “LSTM”

### - Tamaño del “batch”

Dada la naturaleza de los datos (serie temporal) se han probado tamaños de “batch” en concordancia: 1, 7, 30, 60, 90, etc. Se comprueba que definiendo un tamaño de 7 se consiguen los mejores resultados, muy ligeramente por encima de un tamaño 30. Definir el tamaño en 1 suponía un empeoramiento del modelo a parte del mayor coste computacional y de tiempo. Por este hecho finalmente se define el tamaño en 7.

Teniendo en cuenta todas las conclusiones anteriores se pudieron la arquitectura e hiperparámetros finales de la red.

**Red tipo:** “Long Short-Term Memory – LSTM”

**Nº de capas ocultas:** 2

**Nº de neuronas (capas ocultas):** 200-100

**Capas de dropout:** Ninguna

**Nº de épocas:** 25

**Tamaño del “batch”:** 7

## 9. RESULTADOS

Tras la optimización realizada anteriormente se procede a ejecutar los modelos, recopilar los resultados y analizarlos. En este apartado se recogen los resultados de todos los modelos desarrollados.

### 9.1. Modelos ML (RF-GB-XG)

Dado que los tres modelos desarrollados son similares (mismo preprocesado y pipeline) salvo por el algoritmo de predicción empleado, se decidió generar un “GridSearch” conjunto con diccionarios incluyendo las “tuberías” que conforman el preprocesado de variables del pipeline, la definición del propio pipeline y la definición de los algoritmos de los modelos y sus hiperparámetros optimizados en el apartado anterior.

#### Métricas de los modelos

Se definió una función para calcular las tres métricas seleccionadas para nuestro problema y utilizando el “GridSearch” comentado anteriormente fue sencillo ejecutarlo y obtener los resultados de todos los modelos para cada una de las métricas.

Los resultados obtenidos están recogidos en las tablas siguientes, separados por métricas:

	<b>Predictor</b>	<b>R2_train</b>	<b>R2_cv_train</b>	<b>R2_validation</b>	<b>R2_test</b>
<b>0</b>	RandomForest	0,98821	0,98843	0,81494	0,84853
<b>1</b>	GradientBoosting	0,99083	0,99232	0,87105	0,74576
<b>2</b>	XGBoost	0,99997	0,99997	0,86576	0,72545

Figura 45. Tabla resultados modelos ML - Métrica R2

	<b>Predictor</b>	<b>RMSE_train</b>	<b>RMSE_cv_train</b>	<b>RMSE_validation</b>	<b>RMSE_test</b>
<b>0</b>	RandomForest	7423,89	7348,06	27958,34	24234,98
<b>1</b>	GradientBoosting	6547,54	5987,28	23005,50	31398,12
<b>2</b>	XGBoost	351,79	383,76	23794,25	32627,92

Figura 46. Tabla resultados modelos ML - Métrica RMSE

	<b>Predictor</b>	<b>MAPE_train</b>	<b>MAPE_cv_train</b>	<b>MAPE_validation</b>	<b>MAPE_test</b>
<b>0</b>	RandomForest	0,00748	0,00755	0,03053	0,02582
<b>1</b>	GradientBoosting	0,00744	0,00673	0,02563	0,03361
<b>2</b>	XGBoost	0,00026	0,00028	0,02645	0,03777

Figura 47. Tabla resultados modelos ML - Métrica MAPE

Por tanto, de acuerdo a los resultados obtenidos el mejor modelo es el de “Gradient Boosting” con un R2=0.87105 en validación, seguido de “XGBoost” y por último “Random Forest”.

De todas formas, si analizamos en profundidad los resultados podemos obtener más información de los mismos:

- Los tres modelos sufren de “overfitting”, más marcado aún en el caso del segundo (“Gradient Boosting”) y el tercero (XGBoost) modelos donde obtienen métricas de R2 casi perfectas en “train”, se reducen en validación y empeoran considerablemente en el “test”.
- Es claro que el segundo y tercer modelos no generalizan bien y parte de los malos resultados en el “test” pueden deberse a ello.
- En cambio, el primer modelo (“Random Forest”) pese a tener resultados peores que el segundo en validación, obtiene unos resultados considerablemente mejores en el “test”.
- Aunque el primer modelo sufre de “overfitting” es considerablemente menor que el de cualquiera de los otros dos modelos.

Teniendo en cuenta los resultados y todos los comentarios, se puede considerar que los modelos obtenidos no son malos (R2 entre 0,7-0,85 y MAPE entre 2,5-3,7%), tienen buena capacidad de predicción, aunque sufren un marcado “overfitting”.

De cara a desarrollar futuros modelos de este tipo para este problema particular sería interesante profundizar aún más en el análisis de variables explicativas o realizar búsquedas adicionales para tratar de mejorar la variabilidad explicada por estas en los modelos.

### Interpretabilidad de los modelos

Además de las métricas de los modelos, un aspecto muy importante de los mismos y que también se debe analizar es el de tratar de comprender cómo funciona el modelo y a qué variables les está otorgando mayor importancia. Esto permite la interpretabilidad del mismo.

En relación a los modelos del presente trabajo se han obtenido las “feature importances” de los tres modelos para su análisis. A continuación, se incluyen las 12 variables con mayor peso en las predicciones de los tres modelos de machine learning convencionales desarrollados, las tablas completas se pueden revisar en el anexo correspondiente.

	vars_pred	feat_imp		vars_pred	feat_imp		vars_pred	feat_imp	
0	Dia_sem_SIN	0,399337		0	B4_Tmax	0,421129	0	Clasif_dia	0,063915
1	Clasif_dia	0,095228		1	D2_Tmin	0,345568	1	N_mes_SIN	0,061258
2	C1_Tmax	0,077459		2	C4_Tmax	0,096349	2	Lab_post_fest	0,056345
3	D3_Tmin	0,063506		3	D2_Tmax	0,068450	3	Dia_sem_SIN	0,054254
4	C3_Tmin	0,055292		4	Lab_previo_fest	0,049274	4	N_semana_COS	0,047532
5	N_semana_COS	0,040908		5	N_dia_mes_SIN	0,019231	5	Ind_Indust15	0,034030
6	Ind_Serv3	0,032718		6	Ind_Serv8	0,000000	6	D3_Tmin	0,030091
7	D3_Tmax	0,021354		7	Ind_Indust9	0,000000	7	Lab_previo_fest	0,029304
8	Ind_Indust22	0,018406		8	Ind_Fabr2	0,000000	8	Ind_Indust4	0,028252
9	D2_Tmin	0,015636		9	Ind_Indust27	0,000000	9	D2_Tmin	0,026588
10	C2_Tmax	0,011199		10	Ind_Indust26	0,000000	10	D3_Tmax	0,021879
11	N_mes_SIN	0,011085		11	B3_Tmax	0,000000	11	Ind_Indust17	0,019400
...	...	...		...	...	...	...	...	

Figura 48. Importancia de variables modelos ML (izda. a drcha. “Random Forest”, “Gradient Boosting” y “XGBoost”)

Observando las tablas podemos obtener información relevante en relación a diferentes aspectos:

- **Distribución de importancia**\_ cada modelo distribuye las importancias de manera diferente, el primero le otorga mucha importancia a una variable y distribuye el resto entre las demás variables, el segundo opta por lo que parece una regularización otorgando importancia sólo a las variables que considera relevantes, y el tercero es el más equilibrado repartiendo la importancia al menos dentro del mismo orden de magnitud.
- **Grupos de las vars. relevantes**\_ si atendemos a los tres grupos en los que hemos clasificado las variables explicativas también podemos sacar conclusiones a tener en cuenta. Es claro que en cualquiera de los tres modelos las variables más importantes son las de tipo “laboralidad” y/o las “climatológicas”, en el primer y tercer modelo las variables de “actividad económica” tienen poco peso mientras que en el segundo directamente no lo tienen debido a la “regularización”.
- **Facilidad de interpretación**\_ si tenemos como condición obligada el proporcionar junto con el modelo la interpretabilidad del mismo, siempre será mejor que las importancias obtenidas tengan una distribución lógica y sencilla. No será sencilla si contamos con muchísimas variables todas con baja importancia o si contamos con muy pocas con demasiada, lo interesante sería tener un equilibrio. Revisando desde este punto de vista los tres modelos desarrollados, quizás el mejor en este apartado sea el segundo pese a tener un par de variables con mucho más peso que las demás. Los modelos primero y tercero reparten mucho las importancias y podría ser complicada su explicación a alguien sin conocimientos en el área.

Lo que está claro es que se debe buscar un equilibrio y que en muchos casos la interpretabilidad puede llegar a ser un requisito indispensable de los modelos, por lo que siempre se debe analizar.

## 9.2. Modelos RRNN (MLP-LSTM)

En el caso de las redes neuronales los resultados se han obtenido de forma independiente ya que son redes de tipos diferentes y, por tanto, se han desarrollado de forma independiente.

Cabe hacer mención a un detalle acerca de los resultados de las redes neuronales: por su propia naturaleza las redes neuronales cuentan con un importante componente aleatorio, pese a partir de unos pesos iniciales por neurona, la aleatoriedad del aprendizaje de las mismas hace que los resultados obtenidos cada vez sean siempre diferentes y por tanto no reproducibles.

Pese a haber definido una sesión y fijado todas las semillas aleatorias de la misma, siempre se va a tener una pequeña variación en los resultados obtenidos, a diferencia de los modelos anteriores donde la fijación de las semillas es un paso imprescindible y permite la reproducibilidad de los ensayos realizados.

Este hecho es conocido y se ha considerado para el análisis de los resultados de las redes neuronales desarrolladas en el presente trabajo. Por esta razón se ha decidido entrenar y obtener resultados de 50 redes para cada uno de los dos modelos desarrollados. Y de cara a los resultados se analizarán los promedios de dichos resultados, pero tomando eso sí, el mejor modelo para en el próximo apartado obtener las visualizaciones de los dos modelos.

De acuerdo a lo comentado procedemos a analizar los resultados de las redes obtenidas.

### Modelo RN “MLP”

En la tabla siguiente se recogen los resultados de las cinco mejores redes neuronales tipo “MultiLayer Perceptron” (MLP) desarrolladas. La tabla completa con los resultados de las 50 redes neuronales entrenadas se puede revisar en el anexo correspondiente.

	Name	R2_train	RSME_train	MAPE_train	R2_test	RSME_test	MAPE_test
0	MODEL_MLP - 16	0,99527	4700,61	0,00522	0,93834	15435,52	0,01824
1	MODEL_MLP - 25	0,99528	4693,59	0,00525	0,92789	16692,86	0,01966
2	MODEL_MLP - 33	0,99597	4336,65	0,00490	0,92488	17037,83	0,01982
3	MODEL_MLP - 37	0,99398	5302,55	0,00547	0,92457	17072,53	0,01986
4	MODEL_MLP - 27	0,99597	4340,32	0,00465	0,92176	17387,93	0,02067
5	MODEL_MLP - 35	0,99614	4248,60	0,00472	0,92161	17404,64	0,01962
6	MODEL_MLP - 24	0,99396	5309,69	0,00615	0,91766	17837,45	0,02097
7	MODEL_MLP - 28	0,99438	5124,22	0,00566	0,91724	17882,36	0,02069
8	MODEL_MLP - 39	0,98835	7378,54	0,00939	0,91680	17929,88	0,02140
9	MODEL_MLP - 48	0,99590	4374,17	0,00472	0,91488	18136,41	0,02118

Figura 49. Tabla resultados 10 mejores modelos “MLP” - Métricas R2, RSME y MAPE (tabla completa en anexo)

El promedio de los resultados de las 50 redes entrenadas es el siguiente:

	Name	R2_train	RSME_train	MAPE_train	R2_test	RSME_test	MAPE_test
0	MODEL_MLP - Promedio	0,99453	4974,99	0,00556	0,90374	19233,10	0,02251

Figura 50. Tabla promedio resultados modelos “MLP” - Métricas R2, RSME y MAPE

Como se puede observar, pese a seguir teniendo “overfitting” en el modelo, los resultados son bastante mejores. Además en el caso del mejor modelo obtenido el “overfitting” existe pero podría considerarse como poco relevante.

Si que debe tenerse en cuenta la variabilidad de los resultados, se puede observar el orden comparando las métricas promedio con las métricas de los mejores modelos obtenidos (hay una variabilidad considerable).

Teniendo en cuenta todo lo anterior se puede afirmar que los resultados son buenos y el modelo es capaz de predecir con errores bastante reducidos (R2 entre 0,903 y MAPE entre 2,251%) la demanda eléctrica peninsular.

### Modelo RN "LSTM"

En la tabla siguiente se recogen los resultados de las cinco mejores redes neuronales tipo “Long Short-Term Memory” (LSTM) desarrolladas. La tabla completa con los resultados de las 50 redes neuronales entrenadas se puede revisar en el anexo correspondiente.

	Name	R2_train	RSME_train	MAPE_train	R2_test	RSME_test	MAPE_test
0	MODEL_LSTM - 39	0,97708	10346,67	0,01091	0,93883	15374,16	0,01769
1	MODEL_LSTM - 49	0,97641	10497,39	0,01112	0,93598	15728,64	0,01833
2	MODEL_LSTM - 11	0,97732	10292,30	0,01090	0,93598	15728,72	0,01845
3	MODEL_LSTM - 14	0,97584	10624,08	0,01138	0,93533	15808,14	0,01873
4	MODEL_LSTM - 8	0,97599	10589,92	0,01121	0,93451	15907,33	0,01875
5	MODEL_LSTM - 18	0,97648	10481,83	0,01098	0,93301	16089,01	0,01858
6	MODEL_LSTM - 12	0,97468	10876,51	0,01155	0,93247	16153,27	0,01879
7	MODEL_LSTM - 16	0,97708	10346,17	0,01086	0,93193	16217,81	0,01918
8	MODEL_LSTM - 17	0,97589	10612,46	0,01121	0,93102	16326,36	0,01927
9	MODEL_LSTM - 9	0,97579	10634,87	0,01128	0,93098	16330,62	0,01885

Figura 51. Tabla resultados 10 mejores modelos “LSTM” - Métricas R2, RSME y MAPE (tabla completa en anexo)

El promedio de los resultados de las 50 redes entrenadas es el siguiente:

	Name	R2_train	RSME_train	MAPE_train	R2_test	RSME_test	MAPE_test
0	MODEL_LSTM - Promedio	0,97555	10684,01	0,01131	0,92413	17098,52	0,01995

Figura 52. Tabla promedio resultados modelos “LSTM” - Métricas R2, RSME y MAPE

Los resultados obtenidos con este segundo tipo de redes neuronales son aún mejores que los de las anteriores. Destacar de los resultados que se reduce el “overfitting” del modelo a la vez que se mejora el resultado del “test”, en este caso pese a tenerlo de facto se podría considerar directamente como poco relevante. Además si comparamos las métricas promedio con los resultados de los mejores modelos se comprueba que la varianza de los resultados se ha reducido también, por lo que este modelo es también más estable.

Teniendo en cuenta todo lo anterior se puede afirmar que los resultados son muy buenos y el modelo es capaz de predecir con errores reducidos (R2 entre 0,924 y MAPE entre 1,995%) la demanda eléctrica peninsular.

### Interpretabilidad de los modelos (RRNN)

En referencia a la interpretabilidad de estos modelos, a diferencia de los “ensembles” anteriores, las redes neuronales no permiten la obtención de las importancias de las variables por lo menos de una forma sencilla. Son modelos tipo “caja negra” como se les suele denominar, esto quiere expresar que se define su arquitectura y se los entrena, pero no se sabe muy bien como funcionan en su interior ni cuánto peso le está otorgando la red neuronal a cada variable.

Además hay que tener en cuenta que en una red neuronal profunda el número de pesos, parámetros y neuronas es enorme, por lo que no son modelos sencillos.

Por tanto, esta característica constituye una de las desventajas de las redes neuronales, más aún si el problema exige la necesidad de aportar la interpretabilidad del modelo. De todas maneras las redes neuronales tienen un potencial muy grande y como se ve en los resultados pueden ser la solución perfecta para muchos problemas de machine learning complejos.

### 9.3. Modelo REE (Predicción Demanda D+1)

De acuerdo a lo expuesto en los apartados iniciales del presente trabajo, Red Eléctrica Española (REE) cuenta con un modelo propio de predicción y proporciona predicciones de demanda con un día de antelación. Se han conseguido los datos de la serie temporal de esta predicción y se va a emplear dicho modelo como “baseline” para contrastar el rendimiento de los modelos que han sido desarrollados. Por ello se obtienen las métricas del modelo de REE, que se recogen en la tabla incluida a continuación.

Dado que la serie temporal de la predicción sólo cuenta con datos desde 2019, se ha dividido los datos en dos períodos: 2019 a 2020 ambos incluidos y que coincide con parte del periodo de “train” de nuestros modelos, y 2021 que coincide completamente con nuestro subconjunto de “test”. De esta forma las comparaciones serán más exactas, aunque adicionalmente se han obtenido también las métricas globales del modelo.

	Name	R2	RMSE	MAPE
0	Modelo REE (2019-2020)	0,978270	10651,75	0,010839
1	Modelo REE (2021)	0,983851	7913,19	0,008980
2	Modelo REE (2019-2021)	0,979780	9824,88	0,010220

Figura 53. Tabla resultados modelo “REE” - Métricas R2, RMSE y MAPE

Las métricas ya en el periodo de 2019 a 2020 estaban en un MAPE=1,083%, pero hay que destacar que en 2021 se mejoraron aún más hasta un MAPE=0,898% (por debajo del 1% de error porcentual). Por ello se han dividido también los períodos, dado que esa mejora se diluye en las métricas globales.

Revisando los resultados del modelo tan sólo cabe decir que son inmejorables, por lo menos desde el punto de vista de este trabajo, pero nos sirven como objetivo para tratar de mejorar y seguir avanzando con nuestros modelos en el futuro. Estas métricas se utilizarán para hacer las comparaciones finales en el apartado de conclusiones posterior.

## 10. VISUALIZACIÓN

En este apartado se recogen las visualizaciones de las series temporales de entrenamientos y predicciones de todos los modelos: Modelos ML (RF-GB-XG), Modelos RRNN (MLP-LSTM) y Modelo de REE (Predicción de la demanda D+1). Las visualizaciones se pueden revisar también con mayor detalle en los apartados correspondientes de los anexos.

## 10.1. Modelos ML (RF-GB-XG)

### Modelo ML “RANDOM FOREST”

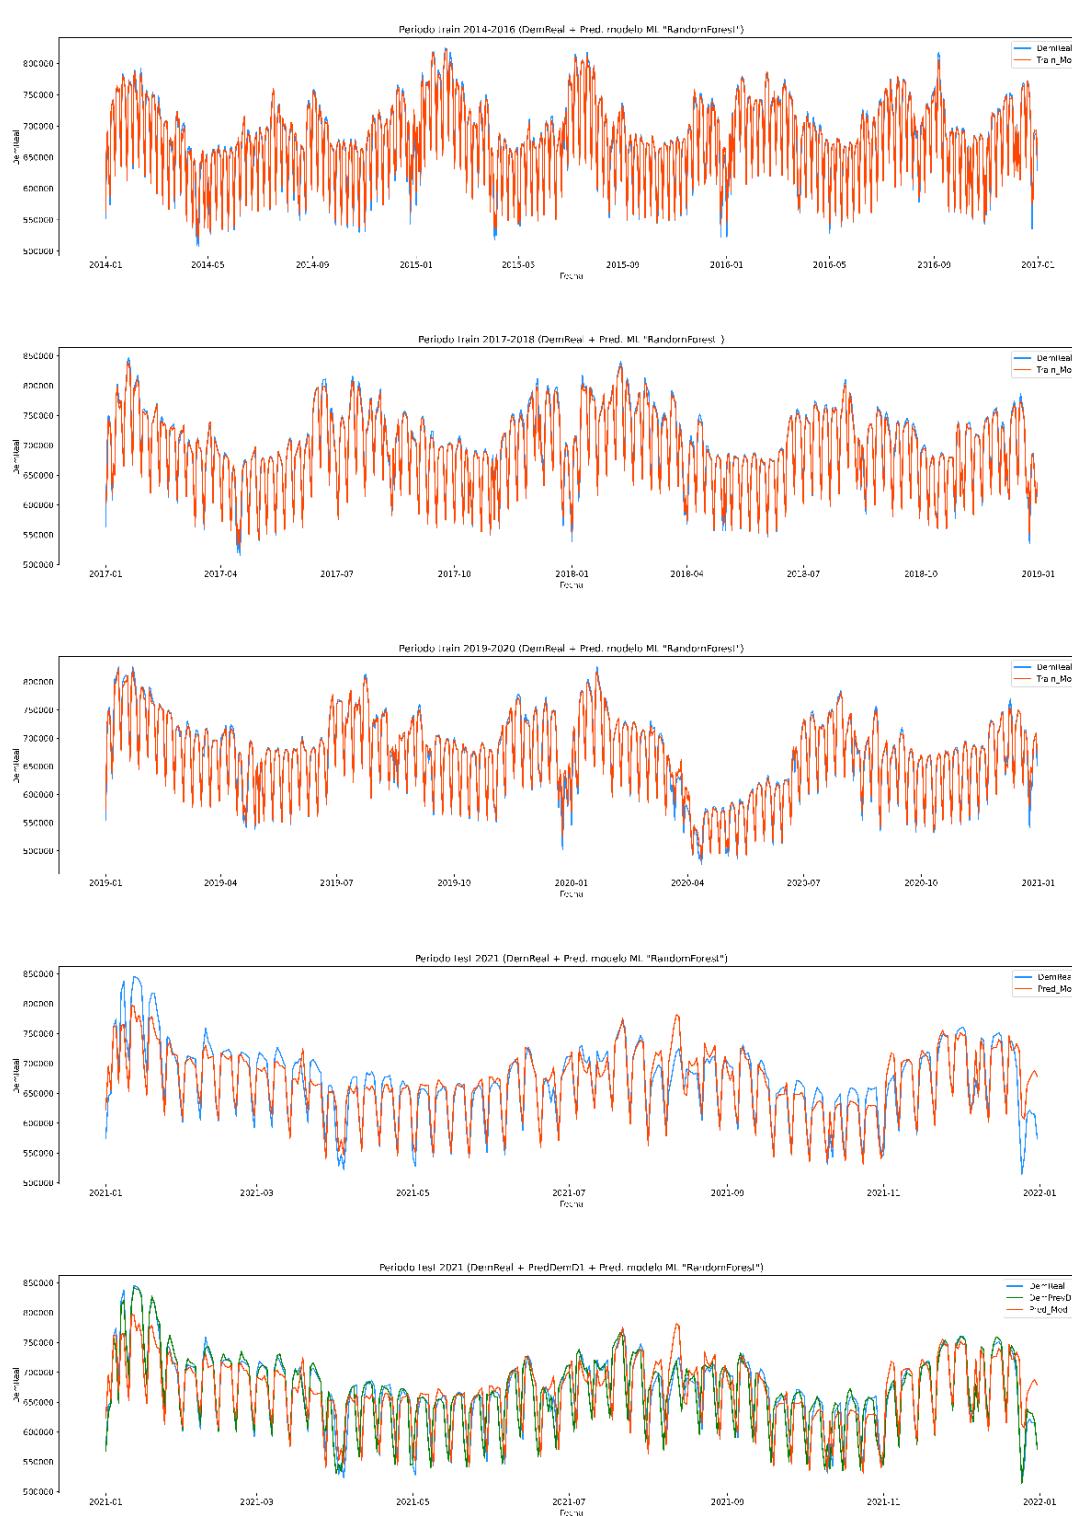


Figura 54. Visualizaciones Modelo ML – “Random Forest”

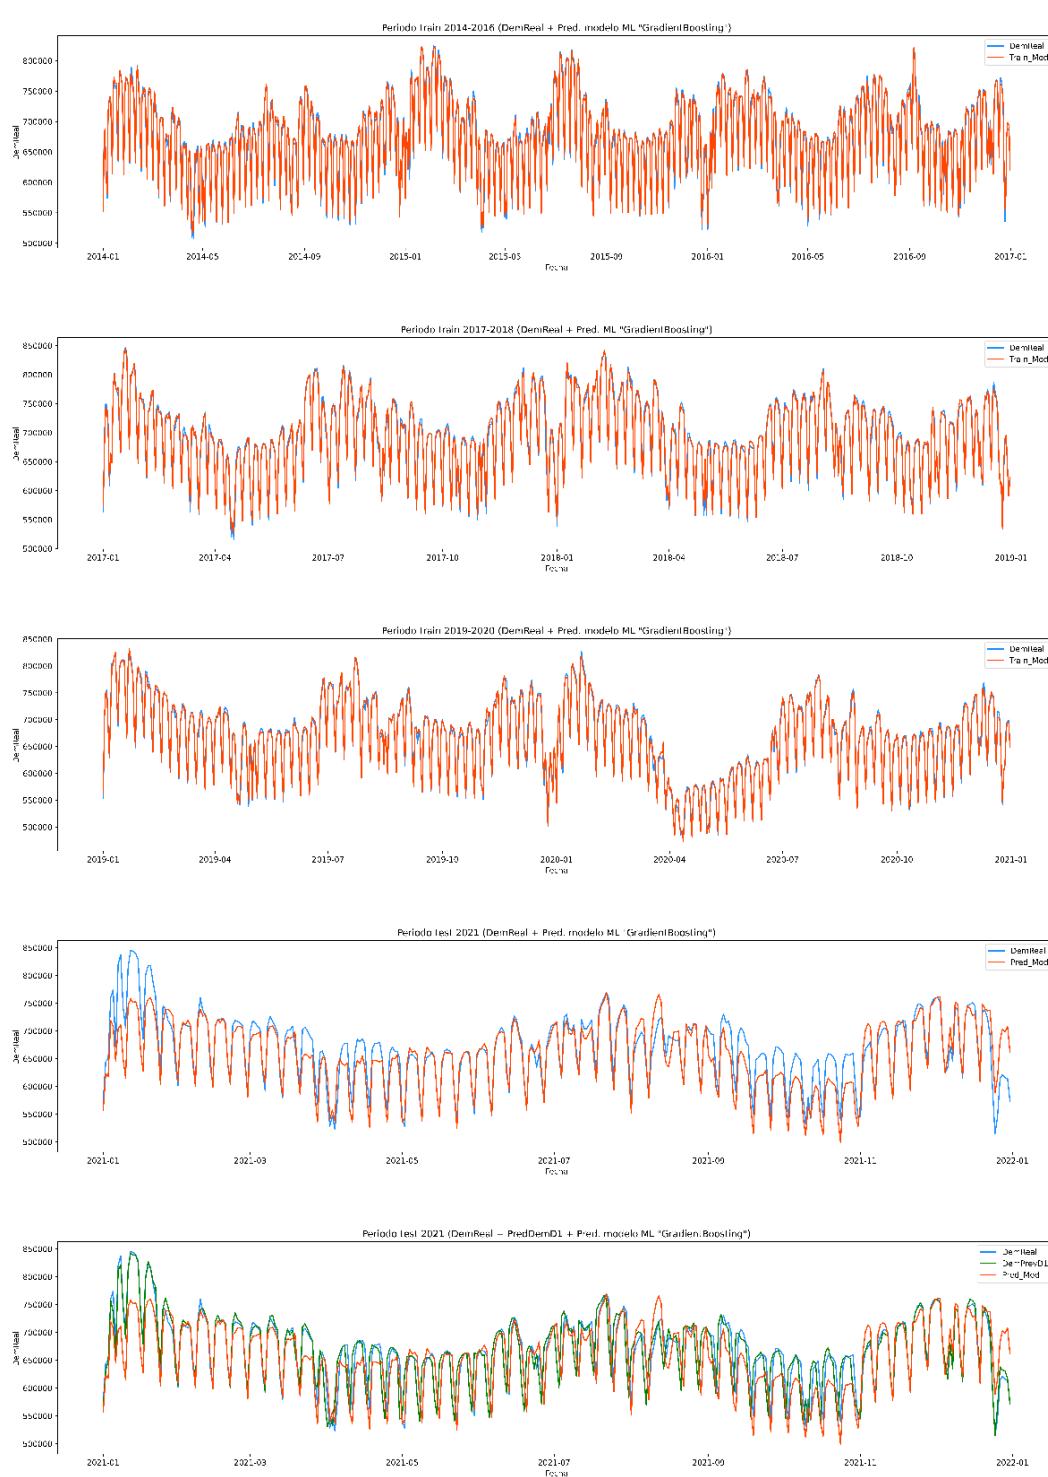
**Modelo ML “GRADIENT BOOSTING”**


Figura 55. Visualizaciones Modelo ML – “Gradient Boosting”

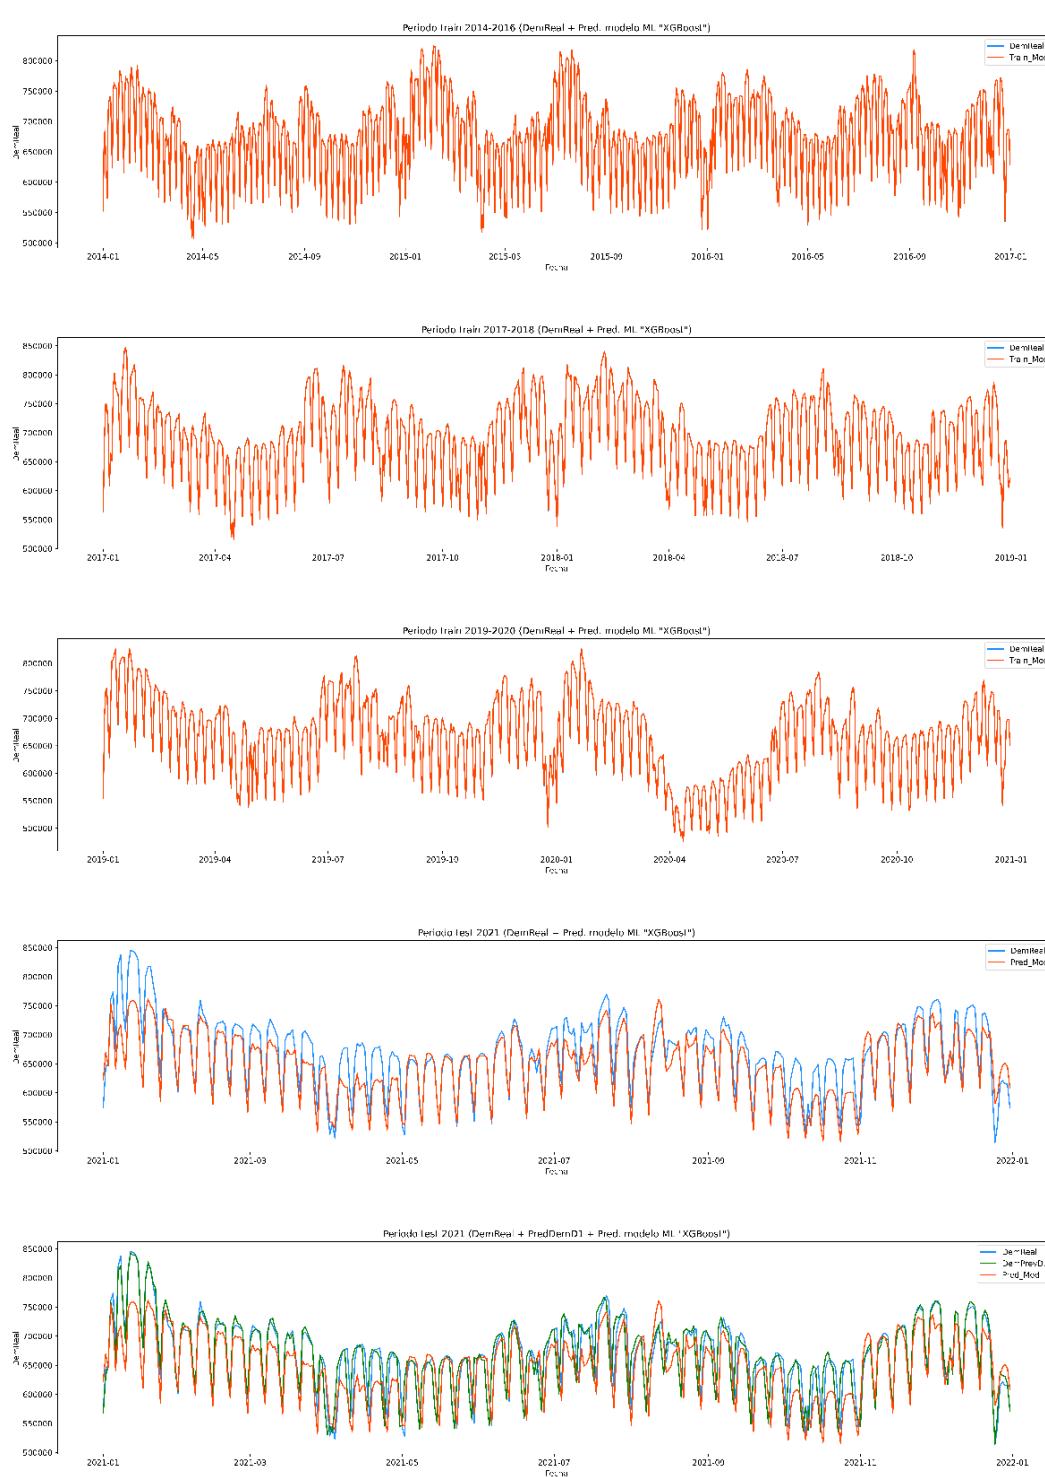
**Modelo ML "XGBOOST"**


Figura 56. Visualizaciones Modelo ML – "XGBoost"

## 10.2. Modelos RRNN (MLP-LSTM)

### Modelo RN “MLP”

Para estas visualizaciones se toma el mejor modelo “MLP” obtenido (MODELO MLP - 16).

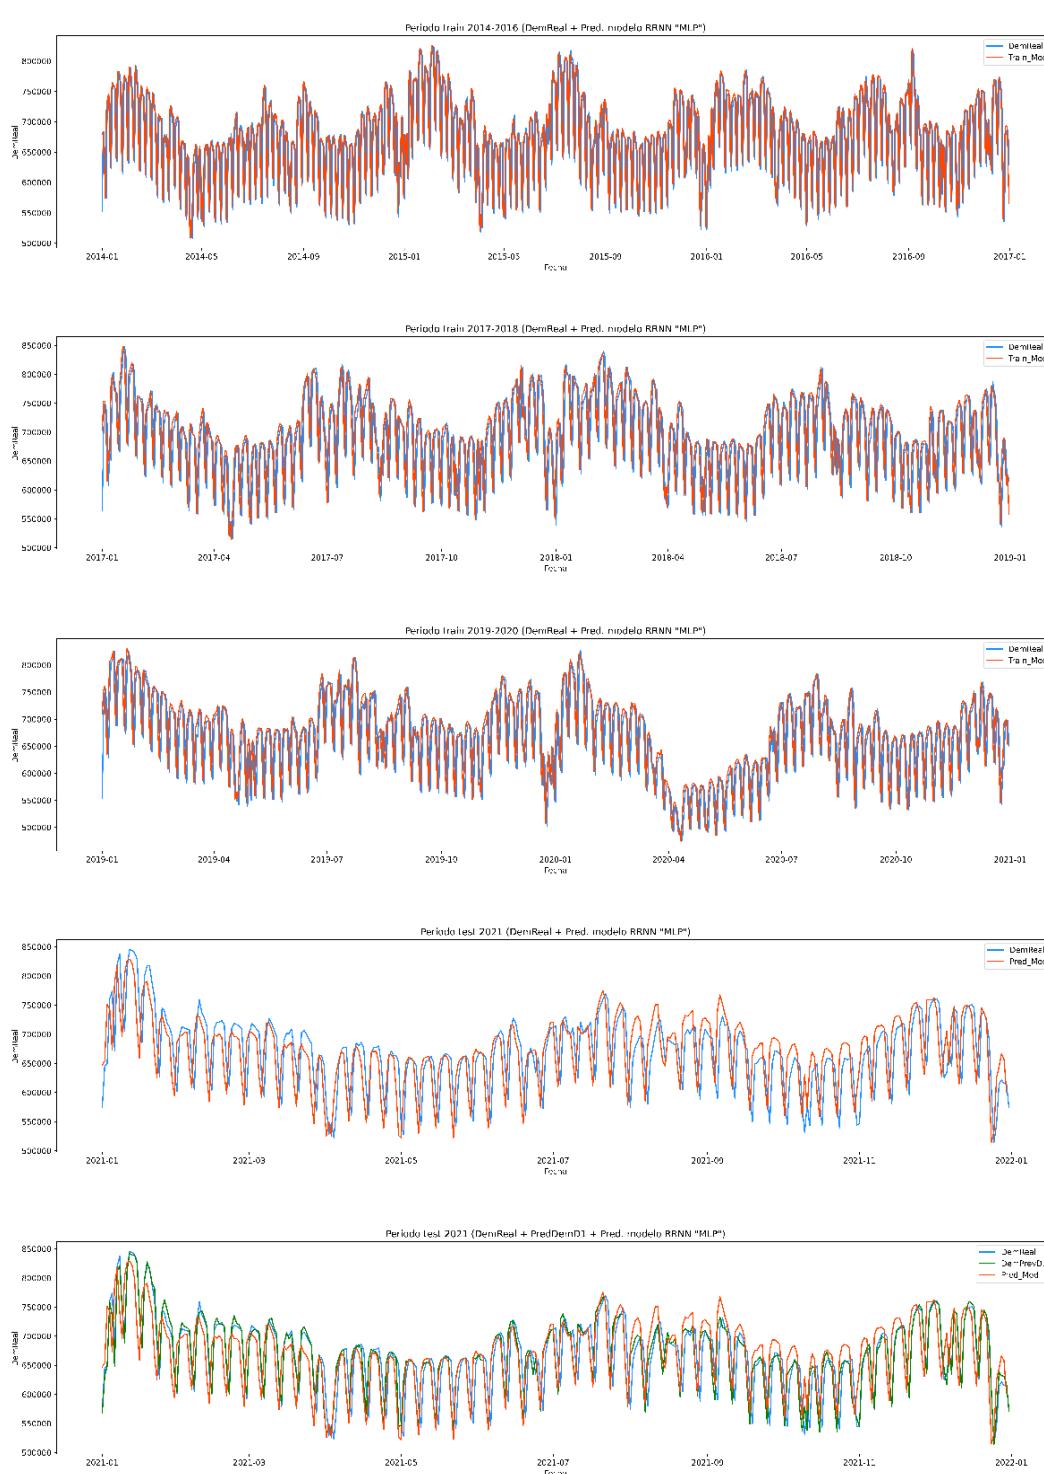


Figura 57. Visualizaciones Modelo RRNN – “MLP”

### Modelo RN "LSTM"

Para estas visualizaciones se toma el mejor modelo "LSTM" obtenido (MODELO LSTM - 39).

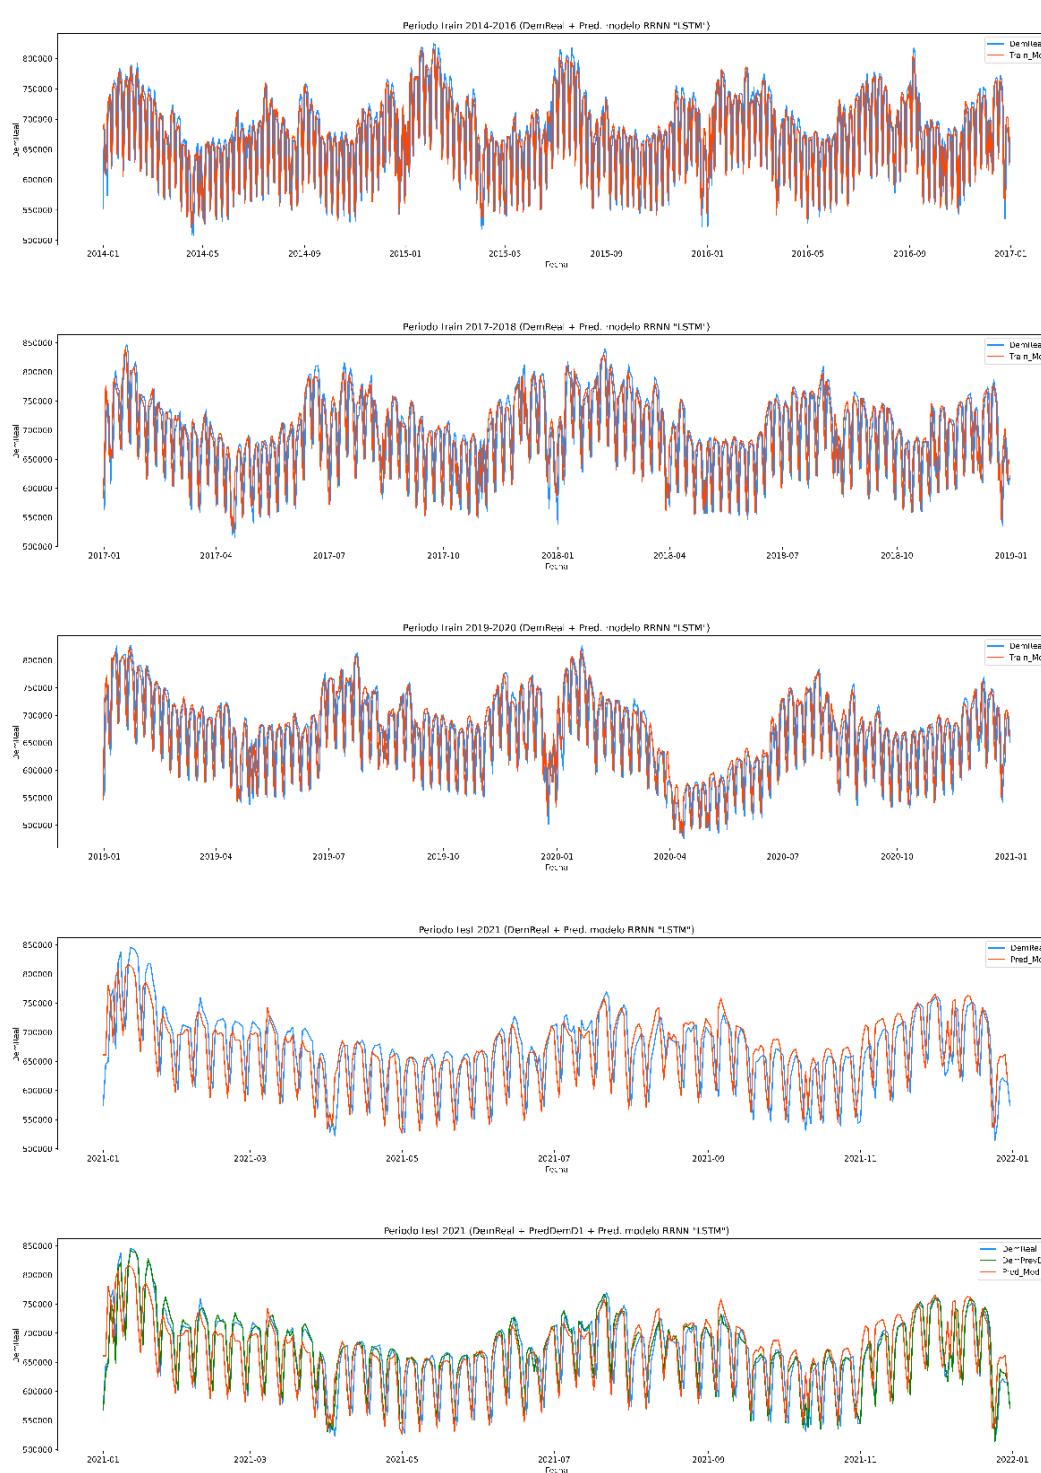


Figura 58. Visualizaciones Modelo RRNN – "LSTM"

### 10.3. Modelo REE (Predicción Demanda D+1)

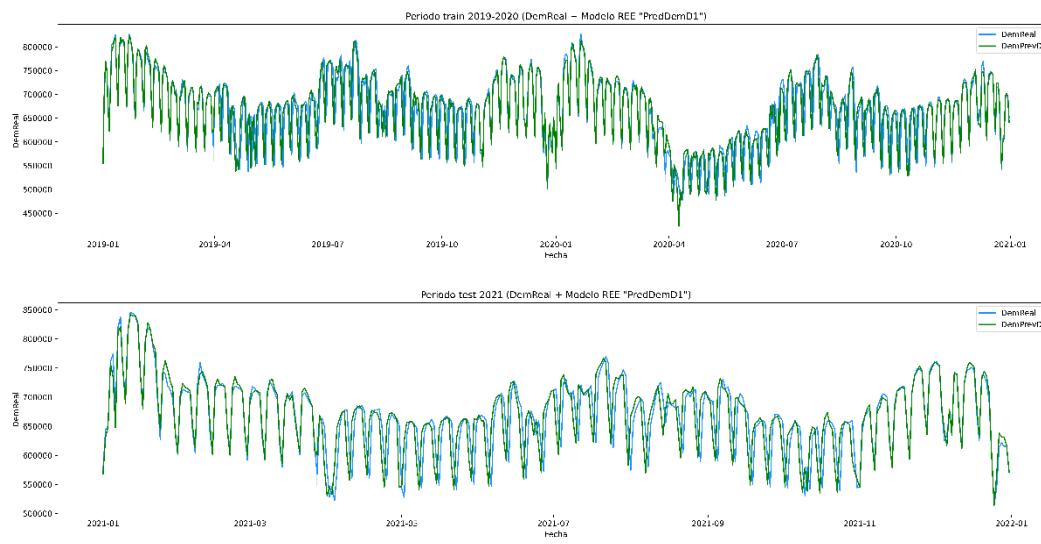


Figura 59. Visualizaciones Modelo REE (Red Eléctrica Española)

## 11. CONCLUSIONES

El objeto principal del presente trabajo era el de crear una serie de modelos operativos para la predicción de la demanda eléctrica peninsular. Adicionalmente, dado que se definieron dos tipos de modelos a desarrollar, se realiza una comparación de los mismos.

Salvo en el aspecto de la interpretabilidad y quizás el pequeño inconveniente de su variabilidad debido a su componente aleatoria, los modelos de redes neuronales:

- Reducen el “overfitting” de los modelos hasta casi poder considerarlo poco relevante.
- Mejoran los resultados de las predicciones, reduciendo el error porcentual hasta la mitad comparado con algunos de los modelos desarrollados.
- Reducen la complejidad del modelo. En el caso de la red neuronal tipo “LSTM” se han conseguido los mejores resultados con una red de dos capas, con 200 y 100 neuronas.

Sería necesario realizar más análisis en profundidad pero parece que este tipo de modelos funciona mejor y obtiene mejores resultados en este tipo de problemas que los modelos de machine learning más convencionales.

Sería necesario realizar más análisis en profundidad pero, una vez revisados los datos, métricas y visualizaciones detalladas en los apartados anteriores, se puede afirmar que los modelos de redes neuronales son claramente mejores en este tipo de problemas que los modelos de machine learning más convencionales. Esta conclusión está en línea con lo que se presuponía desde el inicio y lo que se observa en el estado del arte actual.

De todas maneras si podría ser interesante y en ese sentido se están desarrollando algunos de los modelos híbridos actuales, el combinar ambos tipos de modelos para conseguir modelos compuestos mejores y más estables.

## 12. TRABAJO FUTURO

Se exponen a continuación los puntos que se consideran más importantes de cara a la ampliación del estudio del presente trabajo o el avance en el desarrollo de modelos de este tipo en el futuro.

### Nuevos modelos

En términos generales este trabajo constituye un buen punto de partida para el estudio y predicción de series temporales mediante modelos de machine learning, permitiendo la mejora futura de los modelos e incluso el estudio y desarrollo de nuevos.

No ha sido posible en este trabajo debido al gran número de modelos ya considerados, pero inicialmente se había planteado el desarrollo adicional de un modelo de series temporales ARIMA. Éste puede ser, por ejemplo, uno de los futuros modelos de estudio. Sería interesante a su vez seguir estudiando modelos más avanzados dentro del estado del arte de este tipo de problemas.

### Capacidad de implementación real y aplicación a nuevos tipos de problemas

Cómo se ha expuesto a lo largo del trabajo, los modelos se han desarrollado con la idea de implementación real. Todas las variables utilizadas, llamadas a API's, modelos... se ha definido y desarrollado en todo momento con la condición de que los modelos desarrollados se puedan implementar en la vida real. A pesar de añadir cierto grado de complejidad, no considerando el trabajo como un ejercicio meramente teórico, esto constituía un ejercicio muy interesante y útil de cara al aprendizaje y a la utilización del propio trabajo para el futuro.

Lo explicado anteriormente permite también a su vez el uso de parte del mismo para el desarrollo de modelos en nuevos problemas relacionados con el del trabajo como, por ejemplo, la predicción del precio de la energía (muy de actualidad).

### Bases de datos y automatización

A lo largo de este trabajo se han desarrollado aplicaciones de llamada a las API's utilizadas para la actualización de los datos empleados en el modelo. Éstas están ligadas a la condición de implementación real del modelo. De todas maneras, todas ellas se pueden perfeccionar y considerar este aspecto como una posible mejora más a futuro.

### Variables explicativas para el modelo

Otro punto interesante también sería el de mejorar las variables explicativas empleadas para el modelo, así como la búsqueda de nuevas variables relevantes que se hayan podido pasar por alto.

Como ejemplos de mejora podemos considerar algunos relativos a la "laboralidad": la necesidad de inclusión de los "festivos regionales" de alguna forma en el modelo o la inclusión de más eventos singulares para que el modelo cuente con mayor detalle.

Como ejemplos de búsqueda tenemos los relativos a la "actividad económica", su influencia es muy grande en la evolución de la demanda por lo que la inclusión de variables explicativas que incluyan información relevante sobre este aspecto es muy importante para el modelo. Además, como se ha comentado en los apartados iniciales, el principal problema que presentan los indicadores económicos a la hora de utilizarlos en la construcción de los modelos de predicción es la dificultad de modelizarlos. Por ello no es mala idea buscar la continua mejora de los mismos.

### 13. BIBLIOGRAFÍA

Para la realización del presente trabajo se ha precisado la búsqueda de multitud de información en relación a muy diversas áreas. En este apartado se detallan las principales fuentes de consulta y bibliografía que se han empleado.

- [B-1] REE-REData, Servicio de información y datos del Sistema Eléctrico de Red Eléctrica de España. Actualización continua (fuente de datos y gráficos) [\[Ref\]](#)
- [B-2] REE-Esios, Sistema de información del operador del Sistema Eléctrico, Red Eléctrica de España. Actualización continua (fuente de datos y gráficos) [\[Ref\]](#)
- [B-3] El sistema eléctrico español 2020 (informe elaborado con datos hasta el 11 de abril del 2021); Departamento de Acceso a la Información del Sistema Eléctrico de Red Eléctrica de España. Edición: junio 2021. [\[Ref\]](#)
- [B-4] López, M.; Valero, S.; Rodriguez, Ana; Veirasc, I.; Senabre, C. New online load forecasting system for the Spanish Transport System Operator. Univ. Miguel Hernández de Elche, Spain; Red Eléctrica de España (REE), Spain; ALTEN, Spain. *Electric Power Systems Research* 154 (2018) 401–412. [\[Ref\]](#)
- [B-5] Caro, E.; Ruiz, J. Short-Term Load Forecasting for Spanish Insular Electric Systems; Statistics Laboratory, ETSII, University Politécnica de Madrid. *Energies* 2020, 13, 3645. [\[Ref\]](#)
- [B-6] Portal de Datos abiertos de AEMET. Agencia Estatal de Meteorología [\[Ref\]](#)
- [B-7] Climent, F.J.; Valor, E.; Torró, H.; Caselles, V. Incidencia de la climatología en el consumo de gas y electricidad en España; ICE - Infraestructuras: transportes e industrias de red. Nº 808, Julio 2003. [\[Ref\]](#)
- [B-8] Documento Básico (HE) sobre Ahorro de energía del Código Técnico de la Edificación (CTE). Ministerio de Fomento, Secretaría de Estado de Infraestructuras, Transporte y Vivienda. Aprobado por el Real Decreto 314/2006, de 17 de marzo (BOE 28-marzo-2006) [\[Ref\]](#)
- [B-9] Análisis del consumo energético del sector residencial en España, Informe final - PROYECTO SECH-SPAHOUSEC. Instituto para la Diversificación y Ahorro de la Energía (IDAE). Ministerio de Industria, Energía y Turismo; Eurostat – European Comission. Julio 2011 [\[Ref\]](#)
- [B-10] Brownlee, J.; Deep Learning for Time Series Forecasting, Predict the Future with MLPs, CNNs and LSTMs in Python; Machine Learning Mastery; 2019 [\[Ref\]](#)
- [B-11] Pramono, S.H.; Rohmatillah, M.; Maulana, E.; Hasanah, R.N.; Hario, F. Deep Learning-Based Short-Term Load Forecasting for Supporting Demand Response Program in Hybrid Energy System. *Energies* 2019, 12, 3359. [\[Ref\]](#)
- [B-12] López, M.; Sans, C.; Valero, S.; Senabre, C. Classification of Special Days in Short-Term Load Forecasting: The Spanish Case Study. *Energies* 2019, 12, 1253. [\[Ref\]](#)
- [B-13] Kong, W.; Dong, Z.Y.; Jia, Y.; Hill, D.J.; Xu, Y.; Zhang, Y. Short-Term Residential Load Forecasting Based on LSTM Recurrent Neural Network. *IEEE Trans. Smart Grid* 2017, 10, 841–851. [\[Ref\]](#)
- [B-14] Pham, M.H.; Vu, T.A.; Nguyen, D.Q.; Dang, V.H.; Nguyen, N.T.; Dang, T.H.; Nguyen, T.V. Study on Selecting the Optimal Algorithm and the Effective Methodology to ANN-Based Short-Term Load Forecasting Model for the Southern Power Company in Vietnam. *Energies* 2019, 12, 2283. [\[Ref\]](#)
- [B-15] Zhang, G.; Guo, J. A Novel Method for Hourly Electricity Demand Forecasting. *IEEE Trans. Power Syst.* 2020, 35, 1351–1363. [\[Ref\]](#)
- [B-16] Ahmad, W.; Ayub, N.; Ali, T.; Irfan, M.; Awais, M.; Shiraz, M.; Glowacz, A. Towards Short Term Electricity Load Forecasting Using Improved Support Vector Machine and Extreme Learning Machine. *Energies* 2020, 13, 2907. [\[Ref\]](#)

## 14. ANEXOS

### ANEXO 14.1. TABLA DE DATOS GENÉRICOS DE LAS ESTACIONES AEMET (LISTADO INICIAL)

	Ind_AEMET	Altitud	Provincia	Nombre	Ind_INE	Provincia_Loc	Nombre_Loc	No_penins
0	0076	4	BARCELONA	BARCELONA AEROPUERTO	08169	Barcelona	Barcelona Aeropuerto	0
1	0367	143	GIRONA	GIRONA AEROPUERTO	17002	Girona	Girona Aeropuerto	0
2	1014	4	GIPIJKOA	HONDARRIBIA, MALKARROA	20036	Gipuzkoa	Hondarribia	0
3	1082	42	BIZKIA	BILBAO AEROPUERTO	48904	Bizkai	Bilbao Aeropuerto	0
4	1109	3	CANTABRIA	SANTANDER AEROPUERTO	39008	Cantabria	Santander Aeropuerto	0
5	1110	64	CANTABRIA	SANTANDER, CIUDAD	39075	Cantabria	Santander	0
6	1111	52	CANTABRIA	SANTANDER	39075	Cantabria	Santander	0
7	1159	38	CANTABRIA	SAN VICENTE DE LA BARQUERA	39080	Cantabria	San Vicente De La Barquera	0
8	1208	3	ASTURIAS	GIJON	33024	Asturias	Gijon	0
9	1351	80	A CORUNA	ESTACA DE BARES	27066	Coruna	Estaca De Bares	0
10	1387	58	A CORUNA	A CORUNA	15030	Coruna	A Coruna	0
11	1393	50	A CORUNA	CABO VILAN	15016	Coruna	Faro de Cabo Vilan-Camarinas	0
12	1400	230	A CORUNA	FISTERRA	15037	Coruna	Fisterra	0
13	1428	370	A CORUNA	SANTIAGO DE COMPOSTELA AEROPUERTO	15066	Coruna	Santiago De Compostela Aeropuerto	0
14	1484	19	PONTEVEDRA	PONTEVEDRA, INSTITUTO	36038	Pontedvedra	Pontevedra	0
15	1495	261	PONTEVEDRA	VIGO AEROPUERTO	36033	Pontedvedra	Vigo Aeropuerto	0
16	1505	445	LUGO	LUGO AEROPUERTO	27028	Lugo	Lugo Aeropuerto	0
17	1542	1530	ASTURIAS	PUERTO DE LEITARIEGOS	24202	Asturias	Puerto De Leitariegos	0
18	1549	534	LEON	PONFERRADA	24115	Leon	Ponferrada	0
19	2030	1082	SORIA	SORIA	42173	Soria	Soria	0
20	2298	1080	BURGOS	PALACIOS DE LA SIERRA	09246	Burgos	Palacios De La Sierra	0
21	2331	891	BURGOS	BURGOS AEROPUERTO	09074	Burgos	Burgos Aeropuerto	0
22	2401	750	PALENCIA	PALENCIA, OBSERVATORIO	34120	Palencia	Palencia	0
23	2422	735	VALLADOLID	VALLADOLID	47186	Valladolid	Valladolid	0
24	2444	1130	AVILA	AVILA	05019	Avila	Avila	0
25	2462	1894	MADRID	PUERTO DE NAVACERRADA	28093	Madrid	Puerto De Navacerrada	0
26	2465	1005	SEGOVIA	SEGOVIA	40194	Segovia	Segovia	0
27	2539	846	VALLADOLID	VALLADOLID AEROPUERTO	47217	Valladolid	Valladolid Aeropuerto	0
28	2614	656	ZAMORA	ZAMORA	49275	Zamora	Zamora	0
29	2661	912	LEON	LEON, VIRGEN DEL CAMINO	24142	Leon	La Virgen Del Camino	0
30	2867	790	SALAMANCA	SALAMANCA AEROPUERTO	37175	Salamanca	Salamanca Aeropuerto	0
31	2870	775	SALAMANCA	SALAMANCA	37274	Salamanca	Salamanca	0
32	3013	1062	GUADALAJARA	MOLINA DE ARAGON	19190	Guadalajara	Molina De Aragon	0
33	3129	609	MADRID	MADRID AEROPUERTO	28130	Madrid	Madrid Aeropuerto	0
34	3175	607	MADRID	TORREJON DE ARDOZ	28148	Madrid	Torrejon De Ardoz	0
35	3195	667	MADRID	MADRID, RETIRO	28079	Madrid	Madrid Retiro	0
36	3196	690	MADRID	MADRID, CUATRO VIENTOS	28074	Madrid	Madrid Cuatro Vientos	0
37	3200	620	MADRID	GETAFE	28065	Madrid	Getafe	0
38	3259	540	TOLEDO	TOLEDO, LORENZANA	45168	Toledo	Toledo	0
39	3338	763	MADRID	ROBLEDO DE CHAVELA	28125	Madrid	Robledo De Chavela	0
40	3391	630	AVILA	SOTILLO DE LA ADRA	05240	Avila	Sotillo De La Adra	0
41	3469	459	CACERES	CACERES, CIUDAD	10037	Caceres	Caceres	0
42	4067	690	TOLEDO	MADRIDEJOS	45087	Toledo	Madrilejos	0
43	4121	628	CIUDAD REAL	CIUDAD REAL	13034	Ciudad Real	Ciudad Real	0
44	4148	804	CIUDAD REAL	VISO DEL MARQUES	13098	Ciudad Real	Viso Del Marques	0
45	4452	185	BADAJOZ	BADAJOZ AEROPUERTO	06128	Badajoz	Badajoz Aeropuerto	0
46	4605	17	HUELVA	HUELVA	21041	Huelva	Huelva	0
47	5192	862	JAEN	VILLARRODRIGO	23101	Jaen	Villarrodrigo	0
48	5246	770	JAEN	SANTA ELENA	23076	Jaen	Santa Elena	0
49	5270	510	JAEN	JAEN, INSTITUTO	23050	Jaen	Jaen	0
50	5402	90	CORDOBA	CORDOBA AEROPUERTO	14021	Cordoba	Cordoba Aeropuerto	0
51	5514	687	GRANADA	GRANADA BASE AEREA	18087	Granada	Granada	0
52	5783	34	SEVILLA	SEVILLA AEROPUERTO	41004	Sevilla	Sevilla Aeropuerto	0
53	5796	87	SEVILLA	MORON DE LA FRONTERA	41065	Sevilla	Moron De La Frontera	0
54	5910	21	CADIZ	ROTA, BASE NAVAL	11030	Cadiz	Rota	0
55	5960	27	CADIZ	JEREZ DE LA FRONTERA AEROPUERTO	11020	Cadiz	Jerez De La Frontera Aeropuerto	0
56	5973	2	CADIZ	CADIZ	11012	Cadiz	Cadiz	0
57	6001	32	CADIZ	TARIFA	11035	Cadiz	Tarifa	0
58	6297	7	ALMERIA	ALMERIA	04013	Almeria	Almeria	0
59	6381	15	ALMERIA	ALBORAN	04003	Almeria	Alboran	0
60	7031	4	MURCIA	SAN JAVIER AEROPUERTO	30035	Murcia	San Javier Aeropuerto	0
61	7209	312	MURCIA	LORCA	30024	Murcia	Lorca	0
62	7228	75	MURCIA	ALCANTARILLA, BASE AEREA	30005	Murcia	Alcantarilla	0
63	8019	43	ALICANTE	ALICANTE-ELCHE AEROPUERTO	03121	Alicante	Elche Aeropuerto	0
64	8025	81	ALICANTE	ALICANTE/ALACANT	03014	Alicante	Alicante	0
65	8096	948	CUENCA	CUENCA	16078	Cuenca	Cuenca	0
66	8175	702	ALBACETE	ALBACETE BASE AEREA	02003	Albacete	Albacete	0
67	8416	11	VALENCIA	VALENCIA	46250	Valencia	Valencia	0
68	8501	23	CASTELLON	CASTELLO DE LA PLANA	12040	Castellon	Castello De La Plana	0
69	9051	580	BURGOS	MEDINA DE POMAR	09209	Burgos	Medina De Pomar	0
70	9087	521	ARABA/ALAVA	VITORIA AERODROMO	01059	Alava	Vitoria	0
71	9111	820	BURGOS	BELORADO	09048	Burgos	Belorado	0
72	9170	353	LA RIOJA	LOGRONO, AEROPUERTO	26002	La Rioja	Logrono Aeropuerto	0
73	9262	450	NAVARRA	PAMPLONA	31201	Navarra	Pamplona	0
74	9381	932	TERUEL	CALAMOCHA, AERODROMO	44050	Teruel	Calamocha	0
75	9390	779	ZARAGOZA	DAROCA	50094	Zaragoza	Daroca	0
76	9434	249	ZARAGOZA	ZARAGOZA, AEROPUERTO	50272	Zaragoza	Zaragoza Aeropuerto	0
77	9585	1703	GIRONA	LA MOLINA	17006	Girona	La Molina	0
78	9619	677	LLEIDA	LA SEU D'URGELL	25203	Lleida	La Seu D'Urgell	0
79	9771	199	LLEIDA	LLEIDA, OBSERVATORIO	25120	Lleida	Lleida	0
80	9898	546	HUESCA	HUESCA, AEROPUERTO	22015	Huesca	Huesca Aeropuerto	0
81	0002I	32	TARRAGONA	VANDELLOS	43162	Tarragona	Vandellos	0
82	0016A	71	TARRAGONA	REUS AEROPUERTO	43907	Tarragona	Reus Aeropuerto	0
83	0149X	291	BARCELONA	MANRESA	08113	Barcelona	Manresa	0
84	0200E	408	BARCELONA	BARCELONA, FABRA	08077	Barcelona	Tibidabo	0
85	0201D	6	BARCELONA	BARCELONA	08019	Barcelona	Barcelona	0
86	0229I	146	BARCELONA	SABADELL AEROPUERTO	08187	Barcelona	Sabadell Aeropuerto	0

87	0252D	74	BARCELONA	ARENYS DE MAR	08006	Barcelona	Arenys De Mar	0
88	0255B	40	BARCELONA	SANTA SUSANNA	08261	Barcelona	Santa Susanna	0
89	0324A	675	GIRONA	RIPOLL	17147	Girona	Ripoll	0
90	0370B	95	GIRONA	GIRONA, ANTIC INSTITUT	17079	Girona	Girona	0
91	0372C	157	GIRONA	PORQUERES	17137	Girona	Porqueres	0
92	1002Y	183	NAVARRA	BAZTAN, IRURITA	31050	Navarra	Baztan Irurita	0
93	1014A	4	GIPUZKOA	SAN SEBASTIAN AEROPUERTO	20036	Gipuzkoa	Hondarribia	0
94	1024E	251	GIPUZKOA	DONOSTIA/SAN SEBASTIAN, IGUELDO	20069	Gipuzkoa	Igueldo	0
95	5000C	87	CEUTA	CEUTA	0	Ceuta	Ceuta	1
96	5000A	200	CEUTA	CEUTA, MONTE HACHO	0	Ceuta	Ceuta Monte Hacho	1
97	1037Y	420	GIPUZKOA	ZUMARRAGA	20080	Gipuzkoa	Zumarraga	0
98	1041A	28	GIPUZKOA	ZUMAIJA	20081	Gipuzkoa	Zumaia	0
99	1050J	119	GIPUZKOA	ELGOIBAR	20032	Gipuzkoa	Elgoibar	0
100	1055B	12	BIZKAIA	LEKEITIO	48057	Bizkaia	Lekeitio	0
101	1057B	93	BIZKAIA	MACHICHACO	48017	Bizkaia	Cabo Matxitxako	0
102	1059X	90	BIZKAIA	PUNTA GALEA	48044	Bizkaia	Punta Galea	0
103	1078I	208	BIZKAIA	GUENES	48045	Bizkaia	Guenes	0
104	1083L	45	CANTABRIA	CASTRO URDALES	39020	Cantabria	Castro Urdiales	0
105	1111X	52	CANTABRIA	SANTANDER	39075	Cantabria	Santander	0
106	1183X	10	ASTURIAS	LLANES	33036	Asturias	Llanes	0
107	1207U	26	ASTURIAS	GIJON, CAMPUS	33024	Asturias	Gijon	0
108	1208A	22	ASTURIAS	GIJON, LA MERCED	33024	Asturias	Gijon La Merced	0
109	1208H	5	ASTURIAS	GIJON, PUERTO	33024	Asturias	Gijon	0
110	1210X	100	ASTURIAS	CABO PENAS	33025	Asturias	Cabo Penas	0
111	1212E	127	ASTURIAS	ASTURIAS AEROPUERTO	33039	Asturias	Asturias Aeropuerto	0
112	1221D	1480	ASTURIAS	PAJARES-VALGRANDE	24901	Asturias	Pajares Valgrande	0
113	1249I	336	ASTURIAS	OVIEDO	33044	Asturias	Oviedo	0
114	1249X	336	ASTURIAS	OVIEDO	33044	Asturias	Oviedo	0
115	1283U	60	ASTURIAS	CABO BUSTO	33034	Asturias	Cabo Busto	0
116	1331A	40	ASTURIAS	CASTROPOL	33017	Asturias	Castropol	0
117	1387E	98	A CORUNA	A CORUNA AEROPUERTO	15031	A Coruna	Tarrio	0
118	1437O	685	A CORUNA	MONTE IROITE	15011	A Coruna	Iroite	0
119	1473A	100	A CORUNA	PADRON	15065	A Coruna	Padron	0
120	1475X	240	A CORUNA	SANTIAGO DE COMPOSTELA	15078	A Coruna	Santiago De Compostela	0
121	1484C	108	PONTEVEDRA	PONTEVEDRA	36038	Pontevedra	Pontevedra	0
122	1631E	840	OURENSE	A POBRA DE TRIVES	32063	Ourense	A Pobra De Trives	0
123	1690A	143	OURENSE	OURENSE,INSTITUTO	32054	Ourense	Ourense	0
124	1690B	148	OURENSE	O CARBALLINO	32019	Ourense	O Carballino	0
125	1700X	400	OURENSE	XINZO DE LIMIA	32032	Ourense	Xirzo De Limia	0
127	2117D	790	BURGOS	ARANDA DE DUERO	09018	Burgos	Aranda De Duero	0
128	2150H	1798	SEGOVIA	LA PINILLA, ESTACION DE ESQUI	40172	Segovia	La Pinilla Estacion De Esqui	0
129	2235U	1140	PALENCIA	CERVERA DE PISUERGA	34056	Palencia	Cervera De Pisuegra	0
130	2374X	830	PALENCIA	CARRION DE LOS CONDES	34047	Palencia	Carion De Los Condes	0
131	2400E	874	PALENCIA	AUTILLA DEL PINO	34018	Palencia	Autilla Del Pino	0
132	2444C	1143	AVILA	AVILA, AYUNTAMIENTO	05019	Avila	Avila	0
133	2465A	990	SEGOVIA	SEGOVIA, INSTITUTO	40194	Segovia	Segovia	0
134	2491C	1960	SLAMANCA	LA COVATILLA, ESTACION DE ESQUI	37163	Salamanca	La Covatilla Estacion De Esqui	0
135	2503X	740	VALLADOLID	OLMEDO	47104	Valladolid	Olmedo	0
136	2630X	1510	LEON	PUERTO DE SAN ISIDRO	24177	Leon	Puerto De San Isidro	0
137	2661B	912	LEON	LEON AEROPUERTO	24089	Leon	Leon Aeropuerto	0
138	2737E	1020	LEON	LAGUNAS DE SOMOZA	24091	Leon	Lagunas De Somoza	0
139	2755X	715	ZAMORA	BENAVENTE	49021	Zamora	Benavente	0
140	2775X	850	ZAMORA	VILLARDECIEVOS	49262	Zamora	Villardeciervos	0
141	2811A	1525	AVILA	NAVARREDONDA DE GREDOS	05165	Avila	Navarredonda De Gredos	0
142	2916A	769	SLAMANCA	VITIGUDINO	37376	Salamanca	Vitigudino	0
143	B569X	57	ILLES BALEARS	CAPDEPERA	0	Illes Balears	Capdepera	1
144	B013X	490	ILLES BALEARS	ESCORCA, LLUC	0	Illes Balears	Escorca Lluc	1
145	B954	6	ILLES BALEARS	IBIZA, AEROPUERTO	0	Illes Balears	Ibiza Aeropuerto	1
146	B893	91	ILLES BALEARS	MENORCA, AEROPUERTO	0	Illes Balears	Menorca Aeropuerto	1
147	B278	8	ILLES BALEARS	PALMA DE MALLORCA, AEROPUERTO	0	Illes Balears	Palma De Mallorca Aeropuerto	1
148	B228	3	ILLES BALEARS	PALMA, PUERTO	0	Illes Balears	Palma Puerto	1
149	B346X	120	ILLES BALEARS	PORRERES	0	Illes Balears	Porreres	1
150	B434X	17	ILLES BALEARS	PORTOCOLOM	0	Illes Balears	Portocolom	1
151	B691Y	40	ILLES BALEARS	SA POBLA	0	Illes Balears	Sa Pobla	1
152	B248	1030	ILLES BALEARS	SIERRA DE ALFABIA, BUNYOLA	0	Illes Balears	Sierra De Alfabia Bunyola	1
153	2946X	680	SLAMANCA	SAELICES EL CHICO	37272	Salamanca	Saelices El Chico	0
154	3044X	928	CUENCA	CANIZARES	16053	Cuenca	Canizares	0
155	3094B	808	CUENCA	TARANCON	16203	Cuenca	Tarancon	0
156	3100B	540	MADRID	ARANJUEZ	28013	Madrid	Aranjuez	0
157	3110C	1030	MADRID	BUITRAGO DEL LOZOYA	28027	Madrid	Buitrago Del Lozoya	0
158	3111D	1450	MADRID	SOMOSIERRA	28143	Madrid	Somosierra	0
159	3130C	1005	GUADALAJARA	SIGUENZA	19257	Guadalajara	Siguenza	0
160	3168A	685	GUADALAJARA	GUADALAJARA, INSTITUTO	19130	Guadalajara	Guadalajara	0
161	C249I	25	LAS PALMAS	FUERTEVENTURA AEROPUERTO	0	Las Palmas	Fuerteventura Aeropuerto	1
162	C649I	32	LAS PALMAS	GRAN CANARIA AEROPUERTO	0	Las Palmas	Gran Canaria Aeropuerto	1
163	C619I	10	LAS PALMAS	LA ALDEA DE SAN NICOLAS	0	Las Palmas	La Aldea De San Nicolas	1
164	C029O	14	LAS PALMAS	LANZAROTE AEROPUERTO	0	Las Palmas	Lanzarote Aeropuerto	1
165	C659M	15	LAS PALMAS	S PALMAS DE GRAN CANARIA, PL. DE LA FEF	0	Las Palmas	as Palmas De Gran Canaria Plaza De La Feri	1
166	C659H	55	LAS PALMAS	S PALMAS DE GRAN CANARIA, SAN CRISTOB	0	Las Palmas	Las Palmas De Gran Canaria San Cristobal	1
167	C689E	6	LAS PALMAS	MASPALOMAS	0	Las Palmas	Maspalomas	1
168	C629X	10	LAS PALMAS	MOGAN, PUERTO	0	Las Palmas	Mogan Puerto	1
169	C229J	15	LAS PALMAS	PAJARA	0	Las Palmas	Pajara	1
170	C839I	10	LAS PALMAS	TEGUISE	0	Las Palmas	Teguise	1
171	3168C	639	GUADALAJARA	GUADALAJARA, EL SERRANILLO	19171	Guadalajara	Marchamalo	0
172	3168D	721	GUADALAJARA	GUADALAJARA	19130	Guadalajara	Guadalajara	0
173	3191E	1004	MADRID	COLMENAR VIEJO	28045	Madrid	Colmenar Viejo	0
174	3194U	664	MADRID	MADRID, CIUDAD UNIVERSITARIA	28079	Madrid	Madrid	0

175	3260B	515	TOLEDO	TOLEDO	45168	Toledo	Toledo	0
176	3266A	1532	MADRID	PUERTO ALTO DEL LEON	28068	Madrid	Guadarrama	0
177	3298X	917	TOLEDO	SAN PABLO DE LOS MONTES	45153	Toledo	San Pablo De Los Montes	0
178	3365A	372	TOLEDO	TALAVERA DE LA REINA	45165	Toledo	Talavera De La Reina	0
179	3434X	269	CACERES	NAVALMORAL DE LA MATA	10131	Caceres	Navalmoral De La Mata	0
180	3463X	503	CACERES	TRUJILLO	10195	Caceres	Trujillo	0
181	3469A	394	CACERES	CACERES	10037	Caceres	Caceres	0
182	3519X	415	CACERES	PLASENCIA	10148	Caceres	Plasencia	0
183	3526X	313	CACERES	CORIA	10067	Caceres	Coria	0
184	3576X	444	CACERES	VALENCIA DE ALCANTARA	10203	Caceres	Valencia De Alcantara	0
185	4061X	691	TOLEDO	QUINTANAR DE LA ORDEN	45142	Toledo	Quintanar De La Orden	0
186	4090Y	728	CUENCA	SAN CLEMENTE	16190	Cuenca	San Clemente	0
187	4103X	662	CIUDAD REAL	TOMELLOSO	13082	Ciudad Real	Tomelloso	0
188	4121C	627	CIUDAD REAL	CIUDAD REAL, INSTITUTO	13034	Ciudad Real	Ciudad Real	0
189	4147X	700	CIUDAD REAL	VALDEPENAS	13087	Ciudad Real	Valdepenas	0
190	4220X	486	CIUDAD REAL	PUEBLA DE DON RODRIGO	13068	Ciudad Real	Puebla De Don Rodrigo	0
191	4244X	447	BADAJOZ	HERRERA DEL DUQUE	06063	Badajoz	Herrera Del Duque	0
192	4267X	551	CORDOBA	HINOJOSA DEL DUQUE	14035	Cordoba	Hinojosa Del Duque	0
193	4358X	273	BADAJOZ	DON BENITO	06044	Badajoz	Don Benito	0
194	4386B	655	BADAJOZ	LLERENA	06074	Badajoz	Llerena	0
195	4410X	228	BADAJOZ	MERIDA	06083	Badajoz	Merida	0
196	4511C	381	BADAJOZ	JEREZ DE LOS CABALLEROS	06070	Badajoz	Jerez De Los Caballeros	0
197	4549Y	2	HUELVA	AYAMONTE	21010	Huelva	Ayamonte	0
198	4560Y	572	HUELVA	ALAJAR	21001	Huelva	Alajar	0
199	4642E	19	HUELVA	HUELVA, RONDA ESTE	21041	Huelva	Huelva	0
200	5038X	782	JAEN	CAZORLA	23028	Jaen	Cazorla	0
201	5047E	785	GRANADA	BAZA	18023	Granada	Baza	0
202	5051X	1092	GRANADA	HUESCAR	18098	Granada	Huescar	0
203	5181D	580	JAEN	ARROYO DEL OJANCO	23905	Jaen	Arroyo Del Ojanco	0
204	6000A	52	MELILLA	MELILLA	0	Melilla	Melilla	1
205	5270B	580	JAEN	JAEN	23050	Jaen	Jaen	0
206	5298X	202	JAEN	ANDUJAR	23005	Jaen	Andujar	0
207	5390Y	750	CORDOBA	VILLANUEVA DE CORDOBA	14069	Cordoba	Villanueva De Cordoba	0
208	5427X	650	CORDOBA	DONA MENCIA	14022	Cordoba	Dona Mencia	0
209	5530E	567	GRANADA	GRANADA AEROPUERTO	18059	Granada	Granada Aeropuerto	0
210	5582A	760	GRANADA	LOJA	18122	Granada	Loja	0
211	5612B	410	SEVILLA	LA RODA DE ANDALUCIA	41082	Sevilla	La Roda De Andalucia	0
212	5641X	130	SEVILLA	ECIJA	41039	Sevilla	Ecija	0
213	5704B	550	SEVILLA	CAZALLA DE LA SIERRA	41032	Sevilla	Cazalla De La Sierra	0
214	5860E	41	HUELVA	MOGUER, EL ARENOSILLO	21050	Huelva	Moguer El Arenosillo	0
215	5911A	913	CADIZ	GRAZALEMA	11019	Cadiz	Grazalema	0
216	5972X	28	CADIZ	SAN FERNANDO	11031	Cadiz	San Fernando	0
217	5995B	186	CADIZ	VEJER DE LA FRONTERA	11039	Cadiz	Vejer De La Frontera	0
218	6032B	766	MALAGA	RONDA	29084	Malaga	Ronda	0
219	6058I	19	MALAGA	ESTEPONA	29051	Malaga	Estepona	0
220	6084X	8	MALAGA	FUENGIROLA	29054	Malaga	Fuengirola	0
221	6106X	408	MALAGA	ANTEQUERA	29015	Malaga	Antequera	0
222	6155A	5	MALAGA	MALAGA AEROPUERTO	29901	Malaga	Malaga Aeropuerto	0
223	6156X	54	MALAGA	MALAGA, CENTRO METEOROLICO	29067	Malaga	Malaga	0
224	6172O	25	MALAGA	MALAGA, PUERTO	29067	Malaga	Malaga Puerto	0
225	6205X	3	MALAGA	TORROX	29091	Malaga	Torrox	0
226	6268X	12	GRANADA	MOTRIL	18140	Granada	Motril	0
227	6277B	8	ALMERIA	ADRA	04003	Almeria	Adra	0
228	6293X	3	ALMERIA	ROQUETAS DE MAR	04079	Almeria	Roquetas De Mar	0
229	6302A	869	ALMERIA	ABLA	04001	Almeria	Abla	0
230	6325O	21	ALMERIA	ALMERIA AEROPUERTO	04013	Almeria	Almeria Aeropuerto	0
231	6332X	16	ALMERIA	CARBONERAS	04032	Almeria	Carboneras	0
232	6367B	300	ALMERIA	HUERCAL-OVERA	04053	Almeria	Huercal Overa	0
233	7002Y	26	MURCIA	AGUILAS	30003	Murcia	Aguilas	0
234	7012C	17	MURCIA	CARTAGENA	30016	Murcia	Cartagena	0
235	7031X	4	MURCIA	SAN JAVIER AEROPUERTO	30035	Murcia	San Javier Aeropuerto	0
236	7096B	646	ALBACETE	HELLIN	02037	Albacete	Hellin	0
237	7119B	643	MURCIA	CARAVACA DE LA CRUZ	30015	Murcia	Caravaca De La Cruz	0
238	7145D	265	MURCIA	CIEZA	30019	Murcia	Cieza	0
239	7178I	61	MURCIA	MURCIA	30030	Murcia	Murcia	0
240	7247X	575	ALICANTE	PINOSO	03105	Alicante	Pinoso	0
241	7275C	640	MURCIA	YECLA	30043	Murcia	Yecla	0
242	8050X	15	ALICANTE	JAVEA/XABIA	03082	Alicante	Javea	0
243	8058X	5	VALENCIA	OLIVA	46181	Valencia	Oliva	0
244	8177A	880	ALBACETE	CHINCHILLA	02029	Albacete	Chinchilla De Morte Aragon	0
245	8178D	676	ALBACETE	ALBACETE	02003	Albacete	Albacete	0
246	8293X	88	VALENCIA	XATIVA	46145	Valencia	Xativa	0
247	C439J	115	TA. CRUZ DE TENERIF	GUIMAR	0	Santa Cruz de Tenerife	Guimara	1
248	C929I	32	TA. CRUZ DE TENERIF	HIERRO AEROPUERTO	0	Santa Cruz de Tenerife	Hierro Aeropuerto	1
249	C430E	2371	TA. CRUZ DE TENERIF	IZANA	0	Santa Cruz de Tenerife	Izana	1
250	C139E	33	TA. CRUZ DE TENERIF	LA PALMA AEROPUERTO	0	Santa Cruz de Tenerife	La Palma Aeropuerto	1
251	C459Z	25	TA. CRUZ DE TENERIF	PUERTO DE LA CRUZ	0	Santa Cruz de Tenerife	Puerto De La Cruz	1
252	C329Z	15	TA. CRUZ DE TENERIF	SAN SEBASTIAN DE LA GOMERA	0	Santa Cruz de Tenerife	San Sebastian De La Gomera	1
253	C449C	35	TA. CRUZ DE TENERIF	STA.CRUZ DE TENERIFE	0	Santa Cruz de Tenerife	Santa Cruz De Tenerife	1
254	C129Z	62	TA. CRUZ DE TENERIF	TAZACORTE	0	Santa Cruz de Tenerife	Tazacorte	1
255	C447A	632	TA. CRUZ DE TENERIF	TENERIFE NORTE AEROPUERTO	0	Santa Cruz de Tenerife	Tenerife Norte Aeropuerto	1
256	C429I	64	TA. CRUZ DE TENERIF	TENERIFE SUR AEROPUERTO	0	Santa Cruz de Tenerife	Tenerife Sur Aeropuerto	1
257	8309X	758	VALENCIA	UTIEL	46249	Valencia	Utiel	0
258	8325X	12	VALENCIA	POLINYA DE XUQUER	46197	Valencia	Polinya De Xuquer	0
259	8368U	900	TERUEL	TERUEL	44216	Teruel	Teruel	0
260	8414A	56	VALENCIA	VALENCIA AEROPUERTO	46159	Valencia	Valencia Aeropuerto	0
261	8416Y	11	VALENCIA	VALENCIA, VIVEROS	46250	Valencia	Valencia Viveros	0
262	8489X	1131	CASTELLON	VILLAFRANCA DEL CID/VILLAFRANCA	12129	Castellon	Villafranca Del Cid	0

263	8500A	43	CASTELLON	CASTELLON - ALMASSORA	12009	Castellon	Almassora	0
264	8523X	111	CASTELLON	VINAROS	12138	Castellon	Vinaros	0
265	9001D	870	CANTABRIA	REINOSA	39059	Cantabria	Reinosa	0
266	9019B	720	CANTABRIA	VALDERREDIBLE, POLIENTES	39094	Cantabria	Valderredible Polientes	0
267	9091O	513	ARABA/ALAVA	FORONDA-TXOKIZA	01059	Alava	Foronda	0
268	9091R	513	ARABA/ALAVA	VITORIA GASTEIZ AEROPUERTO	01059	Alava	Vitoria Gasteiz Aeropuerto	0
269	9201K	823	HUESCA	JACA	22130	Huesca	Jaca	0
270	9208E	1040	HUESCA	ARAGUES DEL PUERTO	22032	Huesca	Aragues Del Puerto	0
271	9244X	626	ZARAGOZA	SOS DEL REY CATOLICO	50248	Zaragoza	Sos Del Rey Catolico	0
272	9263D	459	NAVARRA	PAMPLONA, AEROPUERTO	31905	Navarra	Pamplona Aeropuerto	0
273	9263X	572	NAVARRA	ARANGUREN, ILLUNDAIN	31023	Navarra	Aranguren	0
274	9283X	268	NAVARRA	CADREITA	31064	Navarra	Cadreita	0
275	9294E	295	NAVARRA	BARDENAS REALES, BASE AEREA	31032	Navarra	Arguedas	0
276	9381I	890	TERUEL	CALAMOCHA	44050	Teruel	Calamocha	0
277	9394X	582	ZARAGOZA	CALATAYUD	50067	Zaragoza	Calatayud	0
278	9434P	254	ZARAGOZA	ZARAGOZA, VALDESPARTERA	50089	Zaragoza	Zaragoza Valdespartera	0
279	9563X	1220	CASTELLON	CASTELLFORT	12038	Castellon	Castellfort	0
280	9569A	466	TERUEL	CALANDA	44051	Teruel	Calanda	0
281	9573X	334	TERUEL	ALCANIZ	44013	Teruel	Alcaniz	0
282	9576C	357	ZARAGOZA	BUJARALOZ	50059	Zaragoza	Bujaraloz	0
283	9698U	807	LLEIDA	TALARN	25215	Lleida	Talarm	0
284	9720X	388	LLEIDA	TARREGA	25217	Lleida	Tarrega	0
285	9771C	185	LLEIDA	LLEIDA	25120	Lleida	Lleida	0
286	9784P	992	HUESCA	BIELSA	22057	Huesca	Bielsa	0
287	9814A	1020	HUESCA	TORLA	22230	Huesca	Torla	0
288	9981A	50	TARRAGONA	ESTACION DE TORTOSA (ROQUETES)	43155	Tarragona	Tortosa Roquetes	0
289	9987P	1	TARRAGONA	SANT JAUME D'ENVEJA	43902	Tarragona	Sant Jaume D'Enveja	0

**ANEXO 14.2. TABLA ANÁLISIS DE DATOS CLIMÁTICOS POR ESTACIONES AEMET**

	Fecha	Ind_AEMET	Ind_INE	Provincia	Nombre	Tmax	Tmin	N_obs	N_miss	%_miss	Fecha_min	Fecha_max
0	0	3168C	0	0	0	2	2	403	2521	0,86277	01/01/2014	02/08/2015
1	0	3298X	0	0	0	620	620	2736	806	0,27584	01/01/2014	31/12/2021
2	0	8368U	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
3	0	1690A	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
4	0	2614	0	0	0	1	1	2922	1	0,34223	01/01/2014	31/12/2021
5	0	8175	0	0	0	1	0	2922	1	0,34223	01/01/2014	31/12/2021
6	0	9091O	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
7	0	9585	0	0	0	16	16	2883	55	0,18823	01/01/2014	31/12/2021
8	0	9784P	0	0	0	7	7	2859	70	0,23956	01/01/2014	31/12/2021
9	0	9990X	0	0	0	23	23	2651	294	0,10062	01/01/2014	31/12/2021
10	0	0367	0	0	0	39	41	2922	41	0,14031	01/01/2014	31/12/2021
11	0	2491C	0	0	0	9	9	2509	422	0,14442	01/01/2014	31/12/2021
12	0	3013	0	0	0	1	1	2922	1	0,34223	01/01/2014	31/12/2021
13	0	4452	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
14	0	9170	0	0	0	4	4	2921	5	0,17112	01/01/2014	31/12/2021
15	0	0201D	0	0	0	205	205	2912	215	0,73580	01/01/2014	31/12/2021
16	0	2374X	0	0	0	14	14	2908	28	0,95825	04/01/2014	31/12/2021
17	0	2503X	0	0	0	7	9	1438	1493	0,51095	01/01/2014	10/12/2017
18	0	5704B	0	0	0	29	29	2869	82	0,28063	01/01/2014	31/12/2021
19	0	5910	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
20	0	8050X	0	0	0	21	21	2841	102	0,34908	01/01/2014	31/12/2021
21	0	8489X	0	0	0	15	15	2877	60	0,20534	01/01/2014	31/12/2021
22	0	9898	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
23	0	9576C	0	0	0	123	123	1563	1482	0,50719	08/01/2014	06/06/2018
24	0	5270B	0	0	0	15	15	2922	15	0,51335	01/01/2014	31/12/2021
25	0	1057B	0	0	0	1396	1396	2801	1517	0,51916	01/01/2014	31/12/2021
26	0	1221D	0	0	0	70	70	2797	195	0,66735	01/01/2014	31/12/2021
27	0	5612B	0	0	0	93	93	2839	176	0,60233	01/01/2014	31/12/2021
28	0	4061X	0	0	0	687	687	2785	824	0,28200	01/01/2014	31/12/2021
29	0	9294E	0	0	0	116	116	2863	175	0,59890	01/01/2014	31/12/2021
30	0	5995B	0	0	0	54	54	2914	62	0,21218	01/01/2014	31/12/2021
31	0	5270	0	0	0	272	272	272	2922	0,10000	01/01/2014	30/09/2014
32	0	0200E	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
33	0	9091R	0	0	0	8	8	2922	8	0,27379	01/01/2014	31/12/2021
34	0	6332X	0	0	0	135	135	781	2276	0,77892	22/10/2015	27/07/2021
35	0	7275C	0	0	0	13	27	2915	34	0,11636	01/01/2014	31/12/2021
36	0	5051X	0	0	0	405	405	1213	2114	0,72348	01/01/2014	31/03/2018
37	0	3110C	0	0	0	257	257	2615	564	0,19302	01/01/2014	31/12/2021
38	0	0255B	0	0	0	70	70	2884	108	0,36961	01/01/2014	31/12/2021
39	0	1249I	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
40	0	1473A	0	0	0	36	36	2829	129	0,44148	01/01/2014	31/12/2021
41	0	8309X	0	0	0	10	10	2898	34	0,11636	01/01/2014	31/12/2021
42	0	5514	0	0	0	1	0	2922	1	0,34223	01/01/2014	31/12/2021
43	0	7247X	0	0	0	34	34	2889	67	0,22930	01/01/2014	31/12/2021
44	0	0372C	0	0	0	126	126	2733	315	0,10780	01/01/2014	31/12/2021
45	0	6367B	0	0	0	56	56	2922	56	0,19165	01/01/2014	31/12/2021
46	0	5972X	0	0	0	40	40	2904	58	0,19849	01/01/2014	31/12/2021
47	0	2870	0	0	0	79	80	2918	84	0,28747	01/01/2014	31/12/2021
48	0	7145D	0	0	0	39	55	2920	57	0,19507	01/01/2014	31/12/2021
49	0	7002Y	0	0	0	8	26	2922	26	0,88980	01/01/2014	31/12/2021
50	0	9019B	0	0	0	27	27	2907	42	0,14374	01/01/2014	31/12/2021
51	0	9051	0	0	0	11	13	2767	168	0,57495	01/01/2014	31/12/2021
52	0	1331A	0	0	0	44	44	2545	421	0,14408	20/11/2014	31/12/2021
53	0	5796	0	0	0	2	2	2922	2	0,68446	01/01/2014	31/12/2021
54	0	6156X	0	0	0	32	32	2902	52	0,17796	01/01/2014	31/12/2021
55	0	5973	0	0	0	6	5	2922	6	0,20534	01/01/2014	31/12/2021
56	0	9771C	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
57	0	0229I	0	0	0	496	496	812	2606	0,89185	01/01/2014	20/04/2016
58	0	5530E	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
59	0	9434	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
60	0	4358X	0	0	0	36	36	2914	44	0,15058	01/01/2014	31/12/2021
61	0	6032B	0	0	0	0	0	1	2921	0,99966	20/01/2016	20/01/2016
62	0	4267X	0	0	0	44	44	2865	101	0,34565	01/01/2014	31/12/2021
63	0	6058I	0	0	0	119	119	2794	247	0,84531	01/01/2014	31/12/2021
64	0	1082	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021

65	0	6001	0	0	0	54	54	2863	113	0,38672	01/01/2014	31/12/2021
66	0	0016A	0	0	0	123	124	2922	124	0,42437	01/01/2014	31/12/2021
67	0	1631E	0	0	0	6	6	2901	27	0,92402	01/01/2014	31/12/2021
68	0	3469A	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
69	0	4147X	0	0	0	12	12	2733	201	0,68789	01/01/2014	31/12/2021
70	0	4386B	0	0	0	22	22	2922	22	0,75291	01/01/2014	31/12/2021
71	0	1159	0	0	0	17	17	2922	17	0,58179	01/01/2014	31/12/2021
72	0	2150H	0	0	0	12	15	2689	248	0,84873	01/01/2014	31/12/2021
73	0	8025	0	0	0	2	2	2922	2	0,68446	01/01/2014	31/12/2021
74	0	1437O	0	0	0	88	88	1021	1989	0,68070	21/05/2014	02/10/2017
75	0	1183X	0	0	0	36	36	2841	117	0,40041	01/01/2014	31/12/2021
76	0	1387E	0	0	0	13	13	2918	17	0,58179	01/01/2014	31/12/2021
77	0	2737E	0	0	0	83	85	2659	348	0,11910	01/01/2014	31/12/2021
78	0	3526X	0	0	0	153	153	2908	167	0,57153	01/01/2014	31/12/2021
79	0	1542	0	0	0	188	188	2652	458	0,15674	01/01/2014	31/12/2021
80	0	5783	0	0	0	19	20	2922	20	0,68446	01/01/2014	31/12/2021
81	0	9201K	0	0	0	59	59	2859	122	0,41752	01/01/2014	31/12/2021
82	0	3094B	0	0	0	44	44	2916	50	0,17112	01/01/2014	31/12/2021
83	0	9698U	0	0	0	40	40	2877	85	0,29090	01/01/2014	31/12/2021
84	0	6325O	0	0	0	4	5	2922	5	0,17112	01/01/2014	31/12/2021
85	0	7178I	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
86	0	3044X	0	0	0	50	50	2506	466	0,15948	01/01/2014	31/12/2021
87	0	6293X	0	0	0	116	116	2422	616	0,21081	01/01/2014	31/12/2021
88	0	1700X	0	0	0	44	44	2879	87	0,29774	01/01/2014	31/12/2021
89	0	1210X	0	0	0	1217	1217	2732	1407	0,48152	01/01/2014	31/12/2021
90	0	1207U	0	0	0	73	73	2922	73	0,24983	01/01/2014	31/12/2021
91	0	3129	0	0	0	1	1	2922	1	0,34223	01/01/2014	31/12/2021
92	0	3196	0	0	0	2	2	2922	2	0,68446	01/01/2014	31/12/2021
93	0	2331	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
94	0	8019	0	0	0	23	23	2922	23	0,78713	01/01/2014	31/12/2021
95	0	1549	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
96	0	1249X	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
97	0	3338	0	0	0	556	556	2543	935	0,31999	01/01/2014	31/12/2021
98	0	4511C	0	0	0	115	115	2868	169	0,57837	01/01/2014	31/12/2021
99	0	9263X	0	0	0	168	168	2776	314	0,10746	01/01/2014	31/12/2021
100	0	0252D	0	0	0	46	46	2755	213	0,72895	01/01/2014	31/12/2021
101	0	4121	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
102	0	9981A	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
103	0	1055B	0	0	0	162	162	2247	837	0,28645	01/01/2014	29/03/2020
104	0	9208E	0	0	0	20	20	2800	142	0,48597	01/01/2014	31/12/2021
105	0	3576X	0	0	0	49	49	2914	57	0,19507	01/01/2014	31/12/2021
106	0	5427X	0	0	0	75	75	2867	130	0,44490	01/01/2014	31/12/2021
107	0	8178D	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
108	0	2235U	0	0	0	58	63	2843	142	0,48597	01/01/2014	31/12/2021
109	0	1059X	0	0	0	243	243	2897	268	0,91718	01/01/2014	31/12/2021
110	0	7119B	0	0	0	25	44	2917	49	0,16769	01/01/2014	31/12/2021
111	0	9569A	0	0	0	7	7	2895	34	0,11636	01/01/2014	31/12/2021
112	0	6381	0	0	0	208	208	442	2688	0,91992	01/01/2014	11/06/2016
113	0	9563X	0	0	0	39	39	2877	84	0,28747	01/01/2014	31/12/2021
114	0	6172O	0	0	0	0	0	25	2897	0,99144	01/01/2016	31/01/2016
115	0	3168D	0	0	0	1	1	2922	1	0,34223	01/01/2014	31/12/2021
116	0	9381I	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
117	0	8325X	0	0	0	152	152	2884	190	0,65024	01/01/2014	31/12/2021
118	0	1393	0	0	0	97	97	2749	270	0,92402	09/01/2014	31/12/2021
119	0	1283U	0	0	0	24	24	2784	162	0,55441	01/01/2014	31/12/2021
120	0	1024E	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
121	0	2775X	0	0	0	32	33	2905	50	0,17112	01/01/2014	31/12/2021
122	0	1495	0	0	0	14	16	2922	16	0,54757	01/01/2014	31/12/2021
123	0	2422	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
124	0	3175	0	0	0	3	5	2922	5	0,17112	01/01/2014	31/12/2021
125	0	1735X	0	0	0	77	77	2677	322	0,11020	01/01/2014	31/12/2021
126	0	3194U	0	0	0	215	215	2633	504	0,17248	01/01/2014	14/06/2021
127	0	3463X	0	0	0	299	299	2043	1178	0,40315	09/01/2014	30/09/2019
128	0	7012C	0	0	0	26	36	2922	36	0,12320	01/01/2014	31/12/2021
129	0	1351	0	0	0	47	47	2909	60	0,20534	01/01/2014	31/12/2021
130	0	3391	0	0	0	42	51	2352	621	0,21253	01/01/2014	25/12/2021

131	0	4067	0	0	0	21	21	2685	258	0,88296	16/01/2014	31/12/2021
132	0	4642E	0	0	0	9	9	2913	18	0,61602	01/01/2014	31/12/2021
133	0	2916A	0	0	0	5	6	2916	12	0,41068	01/01/2014	31/12/2021
134	0	1428	0	0	0	5	6	2922	6	0,20534	01/01/2014	31/12/2021
135	0	8501	0	0	0	256	256	256	2922	0,10000	20/04/2021	31/12/2021
136	0	2946X	0	0	0	12	14	2920	16	0,54757	01/01/2014	31/12/2021
137	0	9619	0	0	0	179	179	2801	300	0,10267	01/01/2014	31/12/2021
138	0	5047E	0	0	0	15	15	2716	221	0,75633	01/01/2014	31/12/2021
139	0	7031X	0	0	0	26	36	2922	36	0,12320	01/01/2014	31/12/2021
140	0	2298	0	0	0	15	22	2836	108	0,36961	01/01/2014	31/12/2021
141	0	5911A	0	0	0	30	30	2888	64	0,21903	01/01/2014	31/12/2021
142	0	3260B	0	0	0	10	10	2917	15	0,51335	01/01/2014	31/12/2021
143	0	2539	0	0	0	0	3	2922	3	0,10267	01/01/2014	31/12/2021
144	0	5641X	0	0	0	107	107	2869	160	0,54757	01/01/2014	31/12/2021
145	0	0149X	0	0	0	19	19	2883	58	0,19849	01/01/2014	31/12/2021
146	0	1083L	0	0	0	79	79	2683	318	0,10883	29/04/2014	31/12/2021
147	0	1109	0	0	0	39	39	2922	39	0,13347	01/01/2014	31/12/2021
148	0	5390Y	0	0	0	1	1	2922	1	0,34223	01/01/2014	31/12/2021
149	0	5960	0	0	0	19	19	2922	19	0,65024	01/01/2014	31/12/2021
150	0	2661	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
151	0	8058X	0	0	0	188	188	2717	393	0,13450	01/01/2014	19/10/2021
152	0	9111	0	0	0	396	399	2551	770	0,26352	01/01/2014	31/12/2021
153	0	1400	0	0	0	13	13	2711	224	0,76660	01/01/2014	31/12/2021
154	0	9390	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
155	0	3191E	0	0	0	1	1	2922	1	0,34223	01/01/2014	31/12/2021
156	0	9001D	0	0	0	66	66	2874	114	0,39014	01/01/2014	31/12/2021
157	0	8096	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
158	0	9244X	0	0	0	60	60	2800	182	0,62286	07/01/2014	31/12/2021
159	0	9434P	0	0	0	3	3	2905	20	0,68446	01/01/2014	31/12/2021
160	0	5582A	0	0	0	329	329	2603	648	0,22177	01/01/2014	31/12/2021
161	0	7031	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
162	0	1212E	0	0	0	38	44	2922	44	0,15058	01/01/2014	31/12/2021
163	0	1037Y	0	0	0	27	27	2900	49	0,16769	01/01/2014	31/12/2021
164	0	1014A	0	0	0	16	16	2922	16	0,54757	01/01/2014	31/12/2021
165	0	3130C	0	0	0	46	46	2772	196	0,67077	01/01/2014	31/12/2021
166	0	8500A	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
167	0	2117D	0	0	0	7	4	2922	7	0,23956	01/01/2014	31/12/2021
168	0	7209	0	0	0	27	38	2912	48	0,16427	01/01/2014	31/12/2021
169	0	6106X	0	0	0	218	218	2676	464	0,15880	01/01/2014	31/12/2021
170	0	5038X	0	0	0	628	628	1409	2141	0,73272	01/01/2014	02/10/2018
171	0	2867	0	0	0	4	5	2922	5	0,17112	01/01/2014	31/12/2021
172	0	1505	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
173	0	6084X	0	0	0	470	470	2908	484	0,16564	01/01/2014	31/12/2021
174	0	1078I	0	0	0	66	66	2429	559	0,19131	01/01/2014	31/12/2021
175	0	1387	0	0	0	0	1	2922	1	0,34223	01/01/2014	31/12/2021
176	0	5402	0	0	0	18	20	2922	20	0,68446	01/01/2014	31/12/2021
177	0	8416Y	0	0	0	34	34	2918	38	0,13005	01/01/2014	31/12/2021
178	0	2630X	0	0	0	7	6	2422	507	0,17351	01/01/2014	31/12/2021
179	0	5246	0	0	0	15	15	2675	262	0,89665	01/01/2014	31/12/2021
180	0	4090Y	0	0	0	174	174	2148	948	0,32444	13/11/2014	31/12/2021
181	0	5298X	0	0	0	36	37	2758	201	0,68789	01/01/2014	31/12/2021
182	0	1475X	0	0	0	48	48	2867	103	0,35250	01/01/2014	31/12/2021
183	0	1111X	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
184	0	3111D	0	0	0	280	280	2374	828	0,28337	09/01/2014	31/12/2021
185	0	1111	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
186	0	2661B	0	0	0	0	0	1218	1704	0,58316	01/04/2014	31/07/2017
187	0	9814A	0	0	0	71	71	842	2151	0,73614	01/01/2014	04/05/2016
188	0	2444	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
189	0	1208H	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
190	0	7228	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
191	0	8293X	0	0	0	77	77	2912	87	0,29774	01/01/2014	31/12/2021
192	0	9987P	0	0	0	499	499	2002	1419	0,48563	01/01/2014	03/12/2019
193	0	9283X	0	0	0	25	25	1025	1922	0,65777	01/01/2014	12/02/2017
194	0	3365A	0	0	0	66	66	2691	297	0,10164	01/01/2014	31/12/2021
195	0	8177A	0	0	0	34	34	2534	422	0,14442	01/01/2014	31/12/2021
196	0	2811A	0	0	0	466	465	2064	1324	0,45311	01/01/2014	16/02/2020

197	0	2400E	0	0	0	27	26	2890	59	0,20192	01/01/2014	31/12/2021
198	0	0324A	0	0	0	183	183	2832	273	0,93429	01/01/2014	31/12/2021
199	0	4549Y	0	0	0	78	78	2910	90	0,30801	01/01/2014	31/12/2021
200	0	2462	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
201	0	1484C	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
202	0	2465	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
203	0	2755X	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
204	0	3195	0	0	0	4	4	2922	4	0,13689	01/01/2014	31/12/2021
205	0	0076	0	0	0	19	19	2922	19	0,65024	01/01/2014	31/12/2021
206	0	2030	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
207	0	0002I	0	0	0	136	136	2041	1017	0,34805	01/01/2014	06/07/2021
208	0	6155A	0	0	0	2	2	2922	2	0,68446	01/01/2014	31/12/2021
209	0	8416	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
210	0	9573X	0	0	0	67	67	2885	104	0,35592	01/01/2014	31/12/2021
211	0	4148	0	0	0	265	265	2789	398	0,13621	01/01/2014	31/12/2021
212	0	4103X	0	0	0	10	10	2696	236	0,80767	22/01/2014	31/12/2021
213	0	3519X	0	0	0	126	126	2887	161	0,55099	01/01/2014	31/12/2021
214	0	1041A	0	0	0	15	15	2922	15	0,51335	01/01/2014	31/12/2021
215	0	8523X	0	0	0	28	29	2434	517	0,17693	01/01/2014	14/12/2020
216	0	1014	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
217	0	5181D	0	0	0	73	73	2819	176	0,60233	01/01/2014	31/12/2021
218	0	4244X	0	0	0	98	98	2908	112	0,38330	01/01/2014	31/12/2021
219	0	3434X	0	0	0	18	18	2918	22	0,75291	01/01/2014	31/12/2021
220	0	8414A	0	0	0	6	7	2922	7	0,23956	01/01/2014	31/12/2021
221	0	9720X	0	0	0	586	586	1638	1870	0,63997	01/01/2014	13/11/2019
222	0	1050J	0	0	0	16	16	2897	41	0,14031	01/01/2014	31/12/2021
223	0	5860E	0	0	0	54	54	2836	140	0,47912	01/01/2014	31/12/2021
224	0	9262	0	0	0	34	34	2858	98	0,33539	01/01/2014	31/12/2021
225	0	1002Y	0	0	0	118	118	2842	198	0,67762	01/01/2014	31/12/2021
226	0	3100B	0	0	0	95	95	2864	153	0,52361	01/01/2014	30/12/2021
227	0	6302A	0	0	0	85	85	2921	86	0,29432	01/01/2014	31/12/2021
228	0	4560Y	0	0	0	18	18	2877	63	0,21561	01/01/2014	31/12/2021
229	0	7096B	0	0	0	34	34	2830	126	0,43121	01/01/2014	31/12/2021
230	0	3266A	0	0	0	32	32	2640	314	0,10746	01/01/2014	31/12/2021
231	0	9263D	0	0	0	46	44	2922	46	0,15743	01/01/2014	31/12/2021
232	0	9394X	0	0	0	13	13	2882	53	0,18138	01/01/2014	31/12/2021
233	0	4410X	0	0	0	50	50	2921	51	0,17454	01/01/2014	31/12/2021
234	0	6205X	0	0	0	97	97	2447	572	0,19576	01/01/2014	31/12/2021
235	0	4220X	0	0	0	445	445	2643	724	0,24778	01/01/2014	31/12/2021
236	0	3200	0	0	0	0	0	2922	0	0,00000	01/01/2014	31/12/2021
237	0	6268X	0	0	0	37	37	198	2761	0,94490	01/01/2014	13/12/2016
238	0	6277B	0	0	0	74	73	2660	336	0,11499	01/01/2014	31/12/2021
239	0	5192	0	0	0	7	7	1661	1268	0,43395	02/01/2014	14/11/2021

**ANEXO 14.3. TABLA COORDENADAS ESTACIONES AEMET**

<b>Ind_AEMET</b>	<b>Longitude</b>	<b>Latitude</b>					
0	0076	2,079047	41,296944	64	8025	-0,488171	38,343637
1	0367	2,762426	41,904495	65	8096	-1,908819	40,248163
2	1014	-1,797246	43,367157	66	8175	-1,855915	38,995092
3	1082	-2,919130	43,301721	67	8416	-0,376335	39,469707
4	1109	-3,822845	43,427161	68	8501	-0,037735	39,986035
5	1110	-3,809972	43,462041	69	9051	-3,406815	42,949232
6	1111	-3,809972	43,462041	70	9087	-2,672403	42,846509
7	1159	-4,400270	43,383180	71	9111	-3,191782	42,419703
8	1208	-5,662750	43,544942	72	9170	-2,323794	42,460788
9	1351	-7,688285	43,790312	73	9262	-1,644256	42,818454
10	1387	-8,395943	43,370970	74	9381	-1,299434	40,919882
11	1393	-9,2111386	43,160361	75	9390	-1,417064	41,113326
12	1400	-9,263789	42,906477	76	9434	-1,055630	41,656008
13	1428	-8,418913	42,897642	77	9585	1,956206	42,342739
14	1484	-8,643159	42,431888	78	9619	1,456007	42,357572
15	1495	-8,626166	42,232922	79	9771	0,626784	41,614761
16	1505	-7,556575	43,011844	80	9898	-0,319546	42,077236
17	1542	-6,425571	42,992619	81	0002I	0,849659	40,998763
18	1549	-6,593872	42,545412	82	0016A	1,157435	41,146412
19	2030	-2,464204	41,763384	83	0149X	1,828677	41,728894
20	2298	-3,128238	41,963936	84	0200E	2,118914	41,422368
21	2331	-3,621585	42,357640	85	0201D	2,177432	41,382894
22	2401	-4,532874	42,010886	86	0229I	2,101634	41,521143
23	2422	-4,728562	41,652133	87	0252D	2,549156	41,579703
24	2444	-4,700217	40,656478	88	0255B	2,706593	41,635726
25	2462	-4,002663	40,786289	89	0324A	2,193250	42,198239
26	2465	-4,124149	40,950216	90	0370B	2,819944	41,979301
27	2539	-4,854374	41,706834	91	0372C	2,725495	42,122682
28	2614	-5,744804	41,505657	92	1002Y	-1,548632	43,130842
29	2661	-5,643742	42,581665	93	1014A	-1,797246	43,367157
30	2867	-5,501640	40,951007	94	1024E	-1,982348	43,323644
31	2870	-5,664018	40,965157	95	1037Y	-2,314093	43,085997
32	3013	-1,887940	40,843598	96	1041A	-2,257118	43,296653
33	3129	-3,533151	40,446239	97	1050J	-2,416859	43,214356
34	3175	-3,479334	40,458777	98	1055B	-2,505997	43,363708
35	3195	-3,692726	40,415550	99	1057B	-3,015116	43,339374
36	3196	-3,787126	40,364164	100	1059X	-3,016825	43,358289
37	3200	-3,730268	40,308181	101	1078I	-3,094550	43,210451
38	3259	-4,023957	39,856068	102	1083L	-3,216258	43,384335
39	3338	-4,238100	40,500920	103	1111X	-3,809972	43,462041
40	3391	-4,582653	40,292032	104	1183X	-4,753084	43,421121
41	3469	-6,371676	39,474518	105	1207U	-5,662750	43,544942
42	4067	-3,535374	39,469720	106	1208A	-5,662680	43,543711
43	4121	-3,928514	38,985420	107	1208H	-5,662750	43,544942
44	4148	-3,562716	38,521734	108	1210X	-5,848531	43,655714
45	4452	-6,819001	38,894030	109	1212E	-6,030910	43,561619
46	4605	-6,948495	37,257587	110	1221D	-5,771959	42,979023
47	5192	-2,636367	38,487258	111	1249I	-5,845053	43,360422
48	5246	-3,539808	38,340235	112	1249X	-5,845053	43,360422
49	5270	-3,788329	37,772886	113	1283U	-6,469963	43,569948
50	5402	-4,846625	37,843339	114	1331A	-7,030051	43,527658
51	5514	-3,599534	37,173500	115	1387E	-8,202155	43,192036
52	5783	-5,893802	37,414289	116	1437O	-8,925636	42,728471
53	5796	-5,455958	37,121531	117	1473A	-8,629206	42,751015
54	5910	-6,359960	36,622864	118	1475X	-8,545861	42,880422
55	5960	-6,066446	36,751231	119	1484C	-8,643159	42,431888
56	5973	-6,292898	36,529744	120	1631E	-7,254783	42,340590
57	6001	-5,604887	36,012775	121	1690A	-7,867424	42,343642
58	6297	-2,462814	36,841420	122	1690B	-7,867424	42,343642
59	6381	-3,035054	35,939152	123	1700X	-8,078048	42,430005
60	7031	-0,798158	37,810972	124	1735X	-7,739208	42,035730
61	7209	-1,698805	37,671568	125	2117D	-3,685117	41,671507
62	7228	-1,214954	37,968034	126	2150H	-3,475048	41,197332
63	8019	-0,565753	38,284418	127	2235U	-4,497223	42,863551

128	2374X	-4,601713	42,338540	193	5972X	-6,198203	36,464393
129	2400E	-4,633470	41,991182	194	5995B	-5,967049	36,251937
130	2444C	-4,700217	40,656478	195	6032B	-5,166592	36,742134
131	2465A	-4,124149	40,950216	196	6058I	-5,146848	36,426807
132	2491C	-5,697209	40,409955	197	6084X	-4,623335	36,538778
133	2503X	-4,686690	41,287098	198	6106X	-4,559665	37,018365
134	2630X	-5,386428	43,065391	199	6155A	-4,499980	36,678761
135	2661B	-5,643068	42,599684	200	6156X	-4,421637	36,721303
136	2737E	-6,191656	42,381254	201	6172O	-4,474856	36,761519
137	2755X	-5,673860	42,003286	202	6205X	-3,952366	36,760744
138	2775X	-6,286283	41,941969	203	6268X	-3,520766	36,745089
139	2811A	-5,133123	40,361993	204	6277B	-3,020362	36,748834
140	2916A	-6,435380	41,008668	205	6293X	-2,611589	36,763020
141	2946X	-6,633437	40,669768	206	6302A	-2,779232	37,141693
142	3044X	-2,191314	40,518640	207	6325O	-2,372000	36,843994
143	3094B	-3,010224	40,008608	208	6332X	-1,894655	36,996870
144	3100B	-3,603960	40,032210	209	6367B	-1,943660	37,390544
145	3110C	-3,635050	40,995348	210	7002Y	-1,580492	37,409963
146	3111D	-3,581478	41,133207	211	7012C	-0,984115	37,601935
147	3130C	-2,640566	41,068032	212	7031X	-0,798158	37,810972
148	3168A	-3,164607	40,632698	213	7096B	-1,699514	38,510665
149	3168C	-3,202114	40,668866	214	7119B	-1,861118	38,104698
150	3168D	-3,164607	40,632698	215	7145D	-1,418875	38,239227
151	3191E	-3,766321	40,658790	216	7178I	-1,130543	37,992380
152	3194U	-3,703583	40,416705	217	7247X	-1,041617	38,402106
153	3260B	-4,023957	39,856068	218	7275C	-1,115737	38,613652
154	3266A	-4,089391	40,673445	219	8050X	0,163326	38,789391
155	3298X	-4,331672	39,540916	220	8058X	-0,120898	38,920244
156	3365A	-4,831172	39,960380	221	8177A	-1,726366	38,919603
157	3434X	-5,540120	39,892831	222	8178D	-1,855915	38,995092
158	3463X	-5,881663	39,460566	223	8293X	-0,519975	38,988075
159	3469A	-6,371676	39,474518	224	8309X	-1,205178	39,568084
160	3519X	-6,090168	40,029921	225	8325X	-0,369820	39,195794
161	3526X	-6,536680	39,983157	226	8368U	-1,108194	40,343672
162	3576X	-7,242137	39,413117	227	8414A	-0,481209	39,487865
163	4061X	-3,043053	39,590813	228	8416Y	-0,367805	39,480508
164	4090Y	-2,427405	39,403709	229	8489X	-0,257763	40,427049
165	4103X	-3,021485	39,158555	230	8500A	-0,063478	39,943574
166	4121C	-3,928514	38,985420	231	8523X	0,474608	40,470399
167	4147X	-3,384739	38,759457	232	9001D	-4,137836	43,001008
168	4220X	-4,616842	39,082312	233	9019B	-3,940630	42,805574
169	4244X	-5,050466	39,167611	234	9091O	-2,723370	42,898000
170	4267X	-5,148021	38,500428	235	9091R	-2,672403	42,846509
171	4358X	-5,861947	38,954027	236	9201K	-0,549372	42,569252
172	4386B	-6,014990	38,237898	237	9208E	-0,670873	42,706647
173	4410X	-6,344398	38,917467	238	9244X	-1,215063	42,496999
174	4511C	-6,771139	38,320199	239	9263D	-1,645621	42,771144
175	4549Y	-7,404739	37,214284	240	9263X	-1,574326	42,775803
176	4560Y	-6,665060	37,874614	241	9283X	-1,693044	42,218182
177	4642E	-6,948495	37,257587	242	9294E	-1,597006	42,175819
178	5038X	-3,003887	37,912893	243	9381I	-1,299434	40,919882
179	5047E	-2,770981	37,488864	244	9394X	-1,642298	41,352763
180	5051X	-2,539878	37,808627	245	9434P	-0,942217	41,618315
181	5181D	-2,893453	38,321792	246	9563X	-0,190204	40,501353
182	5270B	-3,788329	37,772886	247	9569A	-0,231164	40,939177
183	5298X	-4,050560	38,039236	248	9573X	-0,132957	41,050254
184	5390Y	-4,627966	38,323024	249	9576C	-0,151175	41,497909
185	5427X	-4,357367	37,554572	250	9698U	0,899531	42,186035
186	5530E	-3,777301	37,186799	251	9720X	1,140912	41,647276
187	5582A	-4,149637	37,166484	252	9771C	0,626784	41,614761
188	5612B	-4,777286	37,200368	253	9784P	0,218859	42,633555
189	5641X	-5,079589	37,540601	254	9814A	-0,657212	42,532566
190	5704B	-5,826398	37,929307	255	9981A	0,508664	40,796329
191	5860E	-6,734202	37,098476	256	9987P	0,718289	40,706285
192	5911A	-5,366074	36,758389	257	9990X	0,872070	42,700051

**ANEXO14.4. MAPA PENÍNSULAR CON LAS LOCALIZ. DE LAS ESTACIONES DE AEMET**

Mapa 0: Estaciones AEMET (258)



Mapa 1: Estaciones AEMET (240+33)



Mapa 2: Estaciones AEMET (149+91+33)



Mapa 3: Estaciones AEMET (143+6+91+33)



## Mapa Final: Estaciones AEMET (143) - MODELO



## ANEXO 14.5. TABLA DEF. ZONAS CLIMÁTICAS (ANEJO B, DOCUMENTO DB HE-CTE)

Documento Básico HE Ahorro de energía  
 Anejo B. Zonas Climáticas

### Anejo B Zonas climáticas

#### 1 Zonas climáticas

- 1 La tabla a-Anejo B permite obtener la zona *climática* (Z.C.) de un emplazamiento en función de su provincia y su altitud respecto al nivel del mar (h):

Tabla a-Anejo B. Zonas climáticas

Provincia	Altitud sobre el nivel del mar (h)																						
	≤ 50 m	51 - 100 m	101 - 150 m	111 - 200 m	201 - 250 m	251 - 300 m	301 - 350 m	351 - 400 m	401 - 450 m	451 - 500 m	501 - 550 m	551 - 600 m	601 - 650 m	651 - 700 m	701 - 750 m	751 - 800 m	801 - 850 m	851 - 900 m	901 - 950 m	951 - 1000 m	1001 - 1050 m	1051 - 1250 m	≥ 1301 m
Albacete																							
Alicante/Alacant																							
Almería	A4	B4	B4	B3	B3	E1																	
Araba/Álava																							
Asturias	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	E1	
Ávila																							
Badajoz																							
Baleares, Illes	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	E1	
Barcelona	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	E1	
Bizkaia	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	D1	
Burgos																							
Cáceres																							
Cádiz	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	E1	
Cantabria	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	E1	
Castellón/Castelló	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	E1	
Ceuta																							
Ciudad Real																							
Córdoba	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	D3	
Coruña, A	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	D1	
Cuenca																							
Gipuzkoa																							
Girona	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	E1	
Granada	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	E1	
Guadalajara																							
Huelva	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	A4	D3	
Huesca	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	E1	
Jaén																							
León																							
Lleida	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	E1	
Lugo																							
Madrid	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	E1	
Málaga	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	A3	D3	
Melilla																							
Murcia	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	D3	
Navarra	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	E1	
Ourense	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	E1	
Palencia																							
Palmas, Las	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	C2	
Pontevedra	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	C1	D1	
Rioja, La	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	C2	E1	
Salamanca																							
Santa Cruz de Tenerife	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	a3	C2	
Segovia																							
Sevilla	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	B4	C4	
Soria																							
Tarragona	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	D3	
Teruel	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	C3	E1	
Toledo																							
Valencia/València	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	B3	E1	
Valladolid																							
Zamora																							
Zaragoza																							
Provincia	≤ 50 m	51 - 100 m	101 - 150 m	111 - 200 m	201 - 250 m	251 - 300 m	301 - 350 m	351 - 400 m	401 - 450 m	451 - 500 m	501 - 550 m	551 - 600 m	601 - 650 m	651 - 700 m	701 - 750 m	751 - 800 m	801 - 850 m	851 - 900 m	901 - 950 m	951 - 1000 m	1001 - 1050 m	1051 - 1250 m	≥ 1301 m

**ANEXO 14.6. TABLA INFO. GENERAL ESTACIONES AEMET (POBL. Y ZONA CLIMÁTICA ASIGNADA)**

Ind_Aemet	Altitud	Provincia	Nombre	Ind_INE	No_penins	Req_error	Datos_incompl	Pobl_asig	PropPobl_asig	CTE_zona_clima
0	0076	4	BARCELONA	BARCELONA AEROPUERTO	09189	0	0	711455	0,018367	C2
1	0367	143	GIRONA	GIRONA AEROPUERTO	17002	0	0	681443	0,015677	D2
2	1014	4	GIPUZKOA	HONDARRIBIA, MALKARROA	20036	0	0	109661	0,002527	D1
3	1082	42	BIZKAIA	BILBAO AEROPUERTO	48904	0	0	1116703	0,02569	C1
4	1109	3	CANTABRIA	SANTANDER AEROPUERTO	39008	0	0	228164	0,005249	C1
5	1110	64	CANTABRIA	SANTANDER, CIUDAD	39075	0	1	1	0	C1
6	1111	52	CANTABRIA	SANTANDER	39075	0	0	245330	0,005844	C1
7	1159	38	CANTABRIA	SAN VICENTE DE LA BARQUERA	39080	0	0	42792	0,000994	C1
8	1208	3	ASTURIAS	GUION	33024	0	1	1	0	C1
9	1351	80	A CORUNA	ESTACA DE BARES	27068	0	0	109594	0,002521	C1
10	1387	58	A CORUNA	A CORUNA	15030	0	0	589291	0,013557	C1
11	1393	50	A CORUNA	CABO VILAN	15016	0	0	1	0	C1
12	1400	230	A CORUNA	FISTERA	15037	0	0	1	0	D1
13	1428	370	A CORUNA	SANTIAGO DE COMPOSTELA AEROPUERTO	15086	0	0	58783	0,001352	D1
14	1484	19	PONTEVEDRA	PONTEVEDRA, INSTITUTO	36038	0	1	1	0	C1
15	1495	261	PONTEVEDRA	VIGO AEROPUERTO	36033	0	0	590890	0,013589	C1
16	1505	445	LUGO	LUGO AEROPUERTO	27028	0	0	226390	0,005208	D1
17	1542	1530	ASTURIAS	PUERTO DE LEITARIEGOS	24202	0	0	1	0	E1
18	1549	534	LEON	PONFERRADA	24115	0	0	172013	0,003957	E1
19	2030	1082	SORIA	SORIA	42173	0	0	76037	0,001749	E1
20	2298	1080	BURGOS	PALACIOS DE LA SIERRA	09246	0	0	38289	0,000881	E1
21	2331	891	BURGOS	BURGOS AEROPUERTO	09074	0	0	231650	0,005329	E1
22	2401	750	PALENCIA	PALENCIA, OBSERVATORIO	34120	0	1	1	0	D1
23	2422	735	VALLADOLID	VALLADOLID	47186	0	0	483109	0,011114	D2
24	2444	1130	AVILA	AVILA	05019	0	0	261113	0,006007	E1
25	2482	1894	MADRID	PUERTO DE NAVACERRADA	28083	0	0	261718	0,006021	E1
26	2485	1005	SEGOVIA	SEGOVIA	40184	0	0	117035	0,002892	D2
27	2539	846	VALLADOLID	VALLADOLID AEROPUERTO	47217	0	0	36898	0,000849	E1
28	2614	656	ZAMORA	ZAMORA	49275	0	0	115883	0,002666	D2
29	2861	912	LEON	LEON, VIRGEN DEL CAMINO	24142	0	0	302094	0,006895	E1
30	2867	790	SALAMANCA	SALAMANCA AEROPUERTO	37175	0	0	61988	0,001426	D2
31	2870	775	SALAMANCA	SALAMANCA	37274	0	0	234014	0,005394	D2
32	3013	1082	GUADALAJARA	MOLINA DE ARAGON	19180	0	0	17320	0,000398	E1
33	3129	609	MADRID	MADRID AEROPUERTO	28130	0	0	315695	0,007263	D3
34	3175	607	MADRID	TORREJON DE ARDOZ	28148	0	0	565328	0,013006	D3
35	3195	687	MADRID	MADRID, RETIRO	28079	0	0	3016983	0,076309	D3
36	3198	690	MADRID	MADRID CUATRO VIENTOS	28074	0	0	800121	0,018497	D3
37	3200	620	MADRID	GETAFE	28065	0	0	1056585	0,024307	D3
38	3259	540	TOLEDO	TOLEDO, LORENZANA	45168	0	1	1	0	D3
39	3338	763	MADRID	ROBLEDO DE CHAVELA	28125	0	0	1	0	D3
40	3391	630	AVILA	SOTILLO DE LA ADRAADA	05240	0	0	1	0	D1
41	3489	459	CACERES	CACERES, CIUDAD	10037	0	1	1	0	C4
42	4067	690	TOLEDO	MADRIDREJOS	45087	0	0	1	0	D3
43	4121	628	CIUDAD REAL	CIUDAD REAL	13034	0	0	394444	0,009074	D3
44	4148	804	CIUDAD REAL	VISO DEL MARQUES	13098	0	0	1	0	D3
45	4452	185	BADAJOZ	BADAJOZ AEROPUERTO	06128	0	0	241202	0,005549	C4
46	4605	17	HUELVA	HUELVA	21041	0	1	1	0	A4
47	5192	862	JAEZ	VILLARRODRIGO	23101	0	0	1	0	D3
48	5248	770	JAEZ	SANTA ELENA	23076	0	0	1	0	D3
49	5270	510	JAEZ	JAEN, INSTITUTO	23050	0	0	1	0	C4
50	5402	90	CORDOBA	CORDOBA AEROPUERTO	14021	0	0	518704	0,011933	B4
51	5514	687	GRANADA	GRANADA BASE AEREA	18087	0	0	843324	0,0148	C3
52	5783	34	SEVILLA	SEVILLA AEROPUERTO	41004	0	0	1555011	0,035774	B4
53	5796	87	SEVILLA	MORON DE LA FRONTERA	41085	0	0	169832	0,003907	B4
54	5910	21	CADIZ	ROTA, BASE NAVAL	11030	0	0	115216	0,002651	A3
55	5960	27	CADIZ	JEREZ DE LA FRONTERA AEROPUERTO	11020	0	0	336071	0,007708	A3
56	5973	2	CADIZ	CADIZ	11012	0	0	213026	0,004901	A3
57	6001	32	CADIZ	TARIFA	11035	0	0	256943	0,005911	A3
58	6297	7	ALMERIA	ALMERIA	04013	0	1	1	0	A4
59	6381	15	ALMERIA	ALBORAN	04003	0	0	1	0	A4
60	7031	4	MURCIA	SAN JAVIER AEROPUERTO	30035	0	0	208497	0,004797	B3
61	7209	312	MURCIA	LORCA	30024	0	0	138128	0,003178	C3
62	7228	75	MURCIA	ALCANTARILLA, BASE AEREA	30005	0	0	204265	0,004699	B3
63	8019	43	ALICANTE	ALICANTE-ELCHE AEROPUERTO	03121	0	0	437402	0,010063	B4
64	8025	81	ALICANTE	ALICANTE/ALACANT	03014	0	0	555515	0,01278	B4
65	8096	948	CUENCA	CUENCA	16078	0	0	99620	0,002292	D2
66	8175	702	ALBACETE	ALBACETE BASE AEREA	02003	0	0	326872	0,00752	D3
67	8416	11	VALENCIA	VALENCIA	46250	0	0	1085643	0,024976	B3
68	8501	23	CASTELLON	CASTELLO DE LA PLANA	12040	0	0	1	0	B3
69	9051	580	BURGOS	MEDINA DE POMAR	09209	0	0	1	0	D1
70	9087	521	ARABA/ALAVA	VITORIA AERODROMO	01059	0	1	1	0	D1
71	9111	820	BURGOS	BELORADO	09048	0	0	1	0	E1
72	9170	353	LA RIOJA	LOGRONO, AEROPUERTO	26002	0	0	356314	0,008243	D2
73	9262	450	NAVARRA	PAMPLONA	31201	0	0	320926	0,007393	D1
74	9381	932	TERUEL	CALAMOCHA, AERODROMO	44050	0	1	1	0	D2
75	9390	779	ZARAGOZA	DAROCA	50094	0	0	14540	0,000334	E1
76	9434	249	ZARAGOZA	ZARAGOZA, AEROPUERTO	50272	0	0	149984	0,00345	D3
77	9585	1703	GIRONA	LA MOLINA	17006	0	0	144206	0,003318	E1
78	9619	677	LLEIDA	LA SEU D'URGELL	25203	0	0	1	0	E1
79	9771	199	LLEIDA	LLEIDA, OBSERVATORIO	25120	0	1	1	0	D3
80	9898	546	HUESCA	HUESCA, AEROPUERTO	22015	0	0	104477	0,002404	D2
81	00021	32	TARRAGONA	VANDELLOS	43162	0	0	1	0	B3
82	0016A	71	TARRAGONA	REUS AEROPUERTO	45907	0	0	841870	0,014766	B3
83	0149X	291	BARCELONA	MANRESA	08113	0	0	509191	0,011714	D2
84	0200E	408	BARCELONA	BARCELONA, FABRA	08077	0	0	3884497	0,089364	D2
85	0201D	6	BARCELONA	BARCELONA	08019	0	1	0	0	C2
86	02291	146	BARCELONA	SABADELL AEROPUERTO	08187	0	0	1	0	C2
87	0252D	74	BARCELONA	ARENYS DE MAR	08006	0	0	1	0	C2
88	0255B	40	BARCELONA	SANTA SUSANNA	08261	0	0	441129	0,010148	C2
89	0324A	675	GIRONA	RIPOLL	17147	0	0	1	0	E1
90	0370B	95	GIRONA	GIRONA, ANTIC INSTITUT	17079	0	1	1	0	C2
91	0372C	157	GIRONA	PORQUERES	17137	0	0	1	0	D2
92	1002Y	183	NAVARRA	BAZTAN, IRURITA	31050	0	0	1	0	D2
93	1014A	4	GIPUZKOA	SAN SEBASTIAN AEROPUERTO	20036	0	0	0	0	D1
94	1024E	251	GIPUZKOA	DONOSTIA/SAN SEBASTIAN, IGUELDO	20069	0	0	362237	0,008333	D1
95	5000C	87	CEUTA	CEUTA	0	1	0	0	0	B3
96	5000A	200	CEUTA	CEUTA, MONTE HACHO	0	1	0	0	0	B3
97	1037Y	420	GIPUZKOA	ZUMARRAGA	20080	0	0	149064	0,003429	E1
98	1041A	28	GIPUZKOA	ZUMIA	20081	0	0	52234	0,001216	D1
99	1050J	119	GIPUZKOA	ELGOIBAR	20022	0	0	182208	0,004422	D1
100	1055B	12	BIZKAIA	LEKEITIO	48057	0	0	1	0	C1
101	1057B	93	BIZKAIA	MACHICHACO	48017	0	0	1	0	C1
102	1058X	80	BIZKAIA	PUNTA GALEA	48044	0	0	1	0	C1
103	1078I	208	BIZKAIA	GUENES	48045	0	0	1	0	C1



209	5530E	567	GRANADA	GRANADA AEROPUERTO	18059	0	0	0	226945	0,005221	C4
210	5582A	760	GRANADA	LOJA	18122	0	0	1	0	0	C3
211	5612B	410	SEVILLA	LA RODA DE ANDALUCIA	41082	0	0	1	0	0	C4
212	5641X	130	SEVILLA	ECija	41039	0	0	1	0	0	B4
213	5704B	550	SEVILLA	CAZALLA DE LA SIERRA	41032	0	0	0	51825	0,001192	C4
214	5860E	41	HUELVA	MOCUER, EL ARENOSILLO	21050	0	0	0	87872	0,002022	A4
215	5911A	913	CADIZ	GRAZALEMA	11019	0	0	0	236344	0,005437	D2
216	5972X	28	CADIZ	SAN FERNANDO	11031	0	0	0	220948	0,005083	A3
217	5985B	186	CADIZ	VEJER DE LA FRONTERA	11038	0	0	0	87727	0,002018	B3
218	6032B	768	MALAGA	RONDA	29084	0	0	1	0	0	D3
219	6058I	19	MALAGA	ESTEPONA	29051	0	0	1	0	0	A3
220	6084X	8	MALAGA	FUENGIROLA	29054	0	0	1	0	0	A3
221	6108X	408	MALAGA	ANTEQUERA	29015	0	0	1	0	0	C3
222	6155A	5	MALAGA	MALAGA AEROPUERTO	29091	0	0	0	582998	0,013412	A3
223	6156X	54	MALAGA	MALAGA, CENTRO METEOROLOGICO	29067	0	0	0	794494	0,018278	A3
224	6172O	25	MALAGA	MALAGA, PUERTO	29067	0	0	1	0	0	A3
225	6205X	3	MALAGA	TORROX	29091	0	0	1	0	0	A3
226	6268X	12	GRANADA	MOTRIL	18140	0	0	1	0	0	A4
227	6277B	8	ALMERIA	ADRA	04003	0	0	1	0	0	A4
228	6293X	3	ALMERIA	ROQUETAS DE MAR	04079	0	0	1	0	0	A4
229	6302A	868	ALMERIA	ABA	04001	0	0	0	268379	0,006174	D3
230	6325O	21	ALMERIA	ALMERIA AEROPUERTO	04013	0	0	0	381365	0,009773	A4
231	6332X	16	ALMERIA	CARBONERAS	04032	0	0	1	0	0	A4
232	6367B	300	ALMERIA	HUERCAL-OVERA	04053	0	0	0	146683	0,003375	B3
233	7002Y	26	MURCIA	AGUILAS	30003	0	0	0	77509	0,001783	B3
234	7012C	17	MURCIA	CARTAGENA	30018	0	0	0	284258	0,006539	B3
235	7031X	4	MURCIA	SAN JAVIER AEROPUERTO	30035	0	0	0	0	0	B3
236	7096B	646	ALBACETE	HELIN	02037	0	0	0	53350	0,001227	D3
237	7119B	643	MURCIA	CARAVACA DE LA CRUZ	30015	0	0	0	105790	0,002434	D3
238	7145D	265	MURCIA	CIEZA	30019	0	0	0	106822	0,002457	C3
239	7178I	81	MURCIA	MURCIA	30030	0	0	0	597633	0,013749	B3
240	7247X	575	ALICANTE	PINOSO	03105	0	0	0	146941	0,00338	C3
241	7275C	640	MURCIA	YECLA	30043	0	0	0	123936	0,002851	D3
242	8050X	15	ALICANTE	JAVEA/XABIA	03082	0	0	0	356693	0,009275	B4
243	8058X	5	VALENCIA	OLIVA	46181	0	0	1	0	0	B3
244	8177A	880	ALBACETE	CHINCHILLA	02029	0	0	1	0	0	D3
245	8178D	676	ALBACETE	ALBACETE	02003	0	0	0	0	0	D3
246	8293X	88	VALENCIA	XATIVA	46145	0	0	0	624368	0,014364	C3
247	C439J	115	STA. CRUZ DE TENERIFE	GUIMAR	0	1	0	0	0	0	ALPHA3
248	C928I	32	STA. CRUZ DE TENERIFE	HIERRO AEROPUERTO	0	1	0	0	0	0	ALPHA3
249	C430E	2371	STA. CRUZ DE TENERIFE	IZANA	0	1	0	0	0	0	C2
250	C139E	33	STA. CRUZ DE TENERIFE	LA PALMA AEROPUERTO	0	1	0	0	0	0	ALPHA3
251	C459Z	25	STA. CRUZ DE TENERIFE	PUERTO DE LA CRUZ	0	1	0	0	0	0	ALPHA3
252	C329Z	15	STA. CRUZ DE TENERIFE	SAN SEBASTIAN DE LA GOMERA	0	1	0	0	0	0	ALPHA3
253	C449C	35	STA. CRUZ DE TENERIFE	STA.CRUZ DE TENERIFE	0	1	0	0	0	0	ALPHA3
254	C129Z	62	STA. CRUZ DE TENERIFE	TAZACORTE	0	1	0	0	0	0	ALPHA3
255	C447A	632	STA. CRUZ DE TENERIFE	TENERIFE NORTE AEROPUERTO	0	1	0	0	0	0	A2
256	C428I	64	STA. CRUZ DE TENERIFE	TENERIFE SUR AEROPUERTO	0	1	0	0	0	0	ALPHA3
257	8309X	758	VALENCIA	UTIEL	46248	0	0	0	85250	0,001981	D2
258	8325X	12	VALENCIA	POLINYA DE XUQUER	46197	0	0	1	0	0	B3
259	8368U	900	TERUEL	TERUEL	44216	0	0	0	59562	0,00137	D2
260	8414A	56	VALENCIA	VALENCIA AEROPUERTO	46158	0	0	0	550951	0,012875	C3
261	8418Y	11	VALENCIA	VALENCIA, VIVEROS	46250	0	0	0	314007	0,007224	B3
262	8489X	1131	CASTELLON	VILLAFRANCA DEL CID/VILLAFRANCA	12129	0	0	0	15053	0,000346	E1
263	8500A	43	CASTELLON	CASTELLON - ALMASSORA	12009	0	0	0	487377	0,010752	B3
264	8523X	111	CASTELLON	VINAROS	12138	0	0	1	0	0	C3
265	9001D	870	CANTABRIA	REINOSA	30059	0	0	0	49957	0,001126	E1
266	9019B	720	CANTABRIA	VALDERREDIBLE, POLIENTES	38094	0	0	0	23651	0,000551	E1
267	9091O	513	ARABA/AIAVA	FORONDA-TXOKIZA	01059	0	0	0	67518	0,001563	D1
268	9091R	513	ARABA/AIAVA	VITORIA GASTEIZ AEROPUERTO	01059	0	0	0	283096	0,008513	D1
269	9201K	823	HUESCA	JACA	22130	0	0	0	31686	0,000729	E1
270	9208E	1040	HUESCA	ARAGUES DEL PUERTO	22032	0	0	0	9432	0,000217	E1
271	9244X	626	ZARAGOZA	SOS DEL REY CATOLICO	50248	0	0	1	0	0	D3
272	9263D	459	NAVARRA	PAMPLONA, AEROPUERTO	31905	0	0	0	144989	0,003336	D1
273	9263X	572	NAVARRA	ARANGUREN, ILUNDAIN	31023	0	0	1	0	0	D1
274	9283X	268	NAVARRA	CADREITA	31064	0	0	1	0	0	D2
275	9294E	295	NAVARRA	BARDENAS REALES, BASE AEREA	31032	0	0	1	0	0	D2
276	9381I	890	TERUEL	CALAM OCHA	44050	0	0	0	22216	0,000511	D2
277	9394X	582	ZARAGOZA	CALATAYUD	50067	0	0	0	94236	0,002168	D3
278	9434P	254	ZARAGOZA	ZARAGOZA, VALDESPARTERA	50089	0	0	0	749871	0,017251	D3
279	9563X	1220	CASTELLON	CASTELLFORT	12038	0	0	0	22051	0,000507	E1
280	9569A	466	TERUEL	CALANDA	44051	0	0	0	31083	0,000715	C2
281	9573X	334	TERUEL	ALCANIZ	44013	0	0	0	47814	0,00111	C3
282	9576C	357	ZARAGOZA	BUJARALOZ	50059	0	0	1	0	0	D3
283	9698U	807	LLEIDA	TALARN	25215	0	0	0	59213	0,001362	E1
284	9720X	388	LLEIDA	TARREGA	25217	0	0	1	0	0	D3
285	9771C	185	LLEIDA	LLEIDA	25120	0	0	0	377150	0,008676	D3
286	9784P	992	HUESCA	BIELSA	22057	0	0	0	20709	0,000476	E1
287	9814A	1020	HUESCA	TORLA	22230	0	0	1	0	0	E1
288	9881A	50	TARRAGONA	ESTACION DE TORTOSA (ROQUETES)	43155	0	0	0	252238	0,005803	B3
289	9887P	1	TARRAGONA	SANT JAUME D'ENVEJA	43902	0	0	1	0	0	B3
290	9890X	1161	LLEIDA	NAUT ARAN, ARTIES	25025	0	0	1	0	0	E1

**ANEXO 14.7. TABLA RESULTADOS 50 REDES TIPO “MLP” ENTRENADAS**

	<b>Name</b>	<b>R2_train</b>	<b>RSME_train</b>	<b>MAPE_train</b>	<b>R2_test</b>	<b>RSME_test</b>	<b>MAPE_test</b>
<b>0</b>	MODEL_MLP - 16	0,99527	4700,61	0,00522	0,93834	15435,52	0,01824
<b>1</b>	MODEL_MLP - 25	0,99528	4693,59	0,00525	0,92789	16692,86	0,01966
<b>2</b>	MODEL_MLP - 33	0,99597	4336,65	0,00490	0,92488	17037,83	0,01982
<b>3</b>	MODEL_MLP - 37	0,99398	5302,55	0,00547	0,92457	17072,53	0,01986
<b>4</b>	MODEL_MLP - 27	0,99597	4340,32	0,00465	0,92176	17387,93	0,02067
<b>5</b>	MODEL_MLP - 35	0,99614	4248,60	0,00472	0,92161	17404,64	0,01962
<b>6</b>	MODEL_MLP - 24	0,99396	5309,69	0,00615	0,91766	17837,45	0,02097
<b>7</b>	MODEL_MLP - 28	0,99438	5124,22	0,00566	0,91724	17882,36	0,02069
<b>8</b>	MODEL_MLP - 39	0,98835	7378,54	0,00939	0,91680	17929,88	0,02140
<b>9</b>	MODEL_MLP - 48	0,99590	4374,17	0,00472	0,91488	18136,41	0,02118
<b>10</b>	MODEL_MLP - 18	0,99603	4306,47	0,00468	0,91285	18350,99	0,02081
<b>11</b>	MODEL_MLP - 29	0,99108	6453,28	0,00739	0,91282	18353,94	0,02182
<b>12</b>	MODEL_MLP - 41	0,99489	4887,02	0,00554	0,91274	18362,09	0,02180
<b>13</b>	MODEL_MLP - 32	0,99487	4893,25	0,00531	0,91245	18393,53	0,02077
<b>14</b>	MODEL_MLP - 15	0,99551	4579,10	0,00522	0,91207	18432,44	0,02185
<b>15</b>	MODEL_MLP - 47	0,99610	4269,03	0,00467	0,91148	18494,83	0,02190
<b>16</b>	MODEL_MLP - 49	0,99225	6015,35	0,00698	0,91124	18519,28	0,02150
<b>17</b>	MODEL_MLP - 50	0,99663	3968,57	0,00437	0,91051	18595,45	0,02243
<b>18</b>	MODEL_MLP - 26	0,99546	4602,87	0,00494	0,90833	18820,89	0,02136
<b>19</b>	MODEL_MLP - 31	0,99507	4798,88	0,00543	0,90727	18929,40	0,02236
<b>20</b>	MODEL_MLP - 36	0,99471	4970,10	0,00557	0,90711	18945,29	0,02149
<b>21</b>	MODEL_MLP - 5	0,99619	4216,65	0,00452	0,90652	19005,77	0,02276
<b>22</b>	MODEL_MLP - 44	0,99701	3734,98	0,00409	0,90558	19101,22	0,02270
<b>23</b>	MODEL_MLP - 7	0,99582	4419,21	0,00485	0,90505	19154,28	0,02212
<b>24</b>	MODEL_MLP - 19	0,99581	4423,61	0,00471	0,90504	19155,28	0,02231
<b>25</b>	MODEL_MLP - 11	0,99560	4535,88	0,00506	0,90497	19162,94	0,02272
<b>26</b>	MODEL_MLP - 13	0,99619	4216,43	0,00478	0,90483	19177,17	0,02269
<b>27</b>	MODEL_MLP - 1	0,99609	4275,04	0,00463	0,90374	19286,39	0,02277
<b>28</b>	MODEL_MLP - 12	0,99531	4682,06	0,00522	0,90334	19326,14	0,02295
<b>29</b>	MODEL_MLP - 10	0,99135	6356,99	0,00747	0,90298	19362,43	0,02219
<b>30</b>	MODEL_MLP - 38	0,99354	5491,74	0,00574	0,89993	19663,80	0,02320
<b>31</b>	MODEL_MLP - 4	0,99522	4724,93	0,00517	0,89987	19670,08	0,02302
<b>32</b>	MODEL_MLP - 23	0,99628	4168,93	0,00451	0,89916	19739,84	0,02317
<b>33</b>	MODEL_MLP - 22	0,99336	5569,21	0,00645	0,89846	19807,78	0,02382
<b>34</b>	MODEL_MLP - 40	0,99571	4478,35	0,00475	0,89834	19820,36	0,02273
<b>35</b>	MODEL_MLP - 42	0,99631	4150,97	0,00442	0,89753	19898,69	0,02312
<b>36</b>	MODEL_MLP - 34	0,99398	5301,57	0,00604	0,89677	19972,11	0,02301
<b>37</b>	MODEL_MLP - 21	0,99128	6383,72	0,00699	0,89624	20023,41	0,02414
<b>38</b>	MODEL_MLP - 9	0,99678	3877,41	0,00412	0,89493	20149,23	0,02370
<b>39</b>	MODEL_MLP - 46	0,99662	3973,65	0,00430	0,89362	20274,55	0,02443
<b>40</b>	MODEL_MLP - 45	0,99338	5559,14	0,00645	0,89360	20276,64	0,02362
<b>41</b>	MODEL_MLP - 2	0,99041	6692,58	0,00853	0,89099	20523,63	0,02440
<b>42</b>	MODEL_MLP - 17	0,99539	4638,40	0,00509	0,88972	20643,30	0,02402
<b>43</b>	MODEL_MLP - 43	0,98857	7307,55	0,00885	0,88942	20670,82	0,02421
<b>44</b>	MODEL_MLP - 6	0,99607	4283,35	0,00464	0,88780	20821,55	0,02343
<b>45</b>	MODEL_MLP - 3	0,99224	6019,37	0,00664	0,88270	21289,55	0,02512
<b>46</b>	MODEL_MLP - 8	0,99341	5547,44	0,00591	0,88125	21421,33	0,02519
<b>47</b>	MODEL_MLP - 30	0,99183	6178,62	0,00604	0,87278	22171,79	0,02572
<b>48</b>	MODEL_MLP - 20	0,99667	3943,43	0,00439	0,87128	22301,84	0,02613
<b>49</b>	MODEL_MLP - 14	0,99218	6045,51	0,00735	0,86585	22767,42	0,02592

**ANEXO 14.8. TABLA RESULTADOS 50 REDES TIPO “MLP” ENTRENADAS**

	Name	R2_train	RSME_train	MAPE_train	R2_test	RSME_test	MAPE_test
0	MODEL_LSTM - 39	0,97708	10346,67	0,01091	0,93883	15374,16	0,01769
1	MODEL_LSTM - 49	0,97641	10497,39	0,01112	0,93598	15728,64	0,01833
2	MODEL_LSTM - 11	0,97732	10292,30	0,01090	0,93598	15728,72	0,01845
3	MODEL_LSTM - 14	0,97584	10624,08	0,01138	0,93533	15808,14	0,01873
4	MODEL_LSTM - 8	0,97599	10589,92	0,01121	0,93451	15907,33	0,01875
5	MODEL_LSTM - 18	0,97648	10481,83	0,01098	0,93301	16089,01	0,01858
6	MODEL_LSTM - 12	0,97468	10876,51	0,01155	0,93247	16153,27	0,01879
7	MODEL_LSTM - 16	0,97708	10346,17	0,01086	0,93193	16217,81	0,01918
8	MODEL_LSTM - 17	0,97589	10612,46	0,01121	0,93102	16326,36	0,01927
9	MODEL_LSTM - 9	0,97579	10634,87	0,01128	0,93098	16330,62	0,01885
10	MODEL_LSTM - 4	0,97554	10689,74	0,01129	0,93080	16352,10	0,01892
11	MODEL_LSTM - 1	0,97737	10281,01	0,01074	0,93061	16374,50	0,01908
12	MODEL_LSTM - 33	0,97511	10781,96	0,01140	0,92984	16465,40	0,01889
13	MODEL_LSTM - 2	0,97520	10762,22	0,01133	0,92851	16620,86	0,01949
14	MODEL_LSTM - 7	0,97684	10401,42	0,01089	0,92827	16648,54	0,01940
15	MODEL_LSTM - 3	0,97630	10522,17	0,01094	0,92821	16655,88	0,01896
16	MODEL_LSTM - 46	0,97454	10904,66	0,01173	0,92757	16729,92	0,01917
17	MODEL_LSTM - 42	0,97684	10400,42	0,01109	0,92741	16748,55	0,02012
18	MODEL_LSTM - 44	0,97530	10741,80	0,01131	0,92729	16761,52	0,01967
19	MODEL_LSTM - 5	0,97549	10700,89	0,01137	0,92704	16790,35	0,01979
20	MODEL_LSTM - 38	0,97637	10505,70	0,01114	0,92664	16836,85	0,02017
21	MODEL_LSTM - 48	0,97436	10944,25	0,01150	0,92664	16837,22	0,01949
22	MODEL_LSTM - 20	0,97571	10652,89	0,01123	0,92595	16915,40	0,01953
23	MODEL_LSTM - 30	0,97536	10729,08	0,01144	0,92579	16934,25	0,01960
24	MODEL_LSTM - 21	0,97551	10696,19	0,01138	0,92508	17015,02	0,02020
25	MODEL_LSTM - 10	0,97522	10758,89	0,01143	0,92505	17018,65	0,02002
26	MODEL_LSTM - 28	0,97556	10685,46	0,01132	0,92494	17030,87	0,02005
27	MODEL_LSTM - 23	0,97413	10993,04	0,01166	0,92490	17035,62	0,01941
28	MODEL_LSTM - 15	0,97504	10798,12	0,01142	0,92484	17042,16	0,01947
29	MODEL_LSTM - 27	0,97643	10493,82	0,01114	0,92466	17062,66	0,01991
30	MODEL_LSTM - 34	0,97616	10553,68	0,01105	0,92316	17231,33	0,02045
31	MODEL_LSTM - 40	0,97576	10640,54	0,01127	0,92300	17248,89	0,02033
32	MODEL_LSTM - 19	0,97656	10463,02	0,01089	0,92291	17259,34	0,01971
33	MODEL_LSTM - 13	0,97463	10887,13	0,01139	0,92194	17367,25	0,01962
34	MODEL_LSTM - 25	0,97671	10430,68	0,01094	0,92192	17370,11	0,02046
35	MODEL_LSTM - 26	0,97414	10990,74	0,01181	0,92173	17391,51	0,02025
36	MODEL_LSTM - 47	0,97604	10579,40	0,01130	0,92035	17544,00	0,02058
37	MODEL_LSTM - 43	0,97546	10706,30	0,01141	0,92014	17566,51	0,02088
38	MODEL_LSTM - 36	0,97545	10709,24	0,01141	0,91990	17593,26	0,02060
39	MODEL_LSTM - 24	0,97612	10561,31	0,01121	0,91975	17609,76	0,02129
40	MODEL_LSTM - 37	0,97597	10594,33	0,01127	0,91794	17806,99	0,02036
41	MODEL_LSTM - 31	0,97498	10811,09	0,01145	0,91665	17946,92	0,02094
42	MODEL_LSTM - 22	0,97453	10907,45	0,01173	0,91640	17972,82	0,02112
43	MODEL_LSTM - 29	0,97431	10955,23	0,01173	0,91266	18370,55	0,02122
44	MODEL_LSTM - 35	0,97337	11152,47	0,01186	0,91115	18529,59	0,02130
45	MODEL_LSTM - 6	0,97480	10849,87	0,01143	0,90978	18671,47	0,02155
46	MODEL_LSTM - 45	0,97407	11006,06	0,01168	0,90933	18717,47	0,02188
47	MODEL_LSTM - 41	0,97544	10710,10	0,01134	0,90928	18723,30	0,02195
48	MODEL_LSTM - 32	0,97437	10942,87	0,01163	0,90521	19138,78	0,02241
49	MODEL_LSTM - 50	0,97408	11003,02	0,01180	0,90334	19325,97	0,02283

**ANEXO 14.9. TABLA IMPORTANCIA VARIABLES - MODELO ML “RANDOM FOREST”**

	vars_pred	feat_imp		
0	Dia_sem_SIN	0,399337	35	A3_Tmin
1	Clasif_dia	0,095228	36	Ind_Indust30
2	C1_Tmax	0,077459	37	Ind_Indust53
3	D3_Tmin	0,063506	38	Ind_Indust12
4	C3_Tmin	0,055292	39	Ind_Fabr1
5	N_semana_COS	0,040908	40	N_dia_mes_COS
6	Ind_Serv3	0,032718	41	B3_Tmin
7	D3_Tmax	0,021354	42	C2_Tmin
8	Ind_Indust22	0,018406	43	Ind_Indust40
9	D2_Tmin	0,015636	44	D1_Tmin
10	C2_Tmax	0,011199	45	Ind_Empleo2
11	N_mes_SIN	0,011085	46	Ind_Indust15
12	A4_Tmax	0,009757	47	N_mes_COS
13	E1_Tmin	0,009027	48	B3_Tmax
14	Ind_Fabr2	0,007541	49	Lab_post_fest
15	Ind_Empleo3	0,007337	50	Ind_Indust13
16	N_dia_mes_SIN	0,006783	51	A3_Tmax
17	Ind_Indust56	0,006547	52	Ind_Indust35
18	N_semana_SIN	0,005705	53	Lab_previo_fest
19	B4_Tmin	0,005441	54	Ind_Indust21
20	Ind_Indust19	0,005416	55	Ind_Indust41
21	C4_Tmax	0,005053	56	Dia_sem_COS
22	E1_Tmax	0,004514	57	Ind_Indust26
23	Ind_Indust16	0,004055	58	C1_Tmin
24	Ind_Indust24	0,004000	59	Ind_Indust11
25	Ind_Indust25	0,003847	60	Ind_Indust37
26	D2_Tmax	0,003478	61	D1_Tmax
27	Ind_Precios4	0,003114	62	Ind_Indust27
28	Ind_Indust9	0,003093	63	Ind_Indust8
29	C4_Tmin	0,003062	64	Ind_Indust17
30	B4_Tmax	0,003000	65	Ind_Serv10
31	Ind_Indust4	0,002986	66	Ind_Indust23
32	A4_Tmin	0,002794	67	Ind_Indust14
33	Ind_Indust5	0,002707	68	Ind_Serv8
34	C3_Tmax	0,002674	69	Ind_Cemento
			70	Huelga_General

**ANEXO 14.10. TABLA IMPORTANCIA VARIABLES - MODELO ML “GRADIENT BOOSTING”**

	<b>vars_pred</b>	<b>feat_imp</b>		
0	B4_Tmax	0,421129	35	Lab_post_fest
1	D2_Tmin	0,345568	36	Ind_Indust53
2	C4_Tmax	0,096349	37	Ind_Indust19
3	D2_Tmax	0,068450	38	A3_Tmax
4	Lab_previo_fest	0,049274	39	C3_Tmin
5	N_dia_mes_SIN	0,019231	40	A3_Tmin
6	Ind_Serv8	0,000000	41	Ind_Indust35
7	Ind_Indust9	0,000000	42	N_mes_COS
8	Ind_Fabr2	0,000000	43	Ind_Serv10
9	Ind_Indust27	0,000000	44	A4_Tmin
10	Ind_Indust26	0,000000	45	Ind_Indust13
11	B3_Tmax	0,000000	46	Huelga_General
12	Ind_Fabr1	0,000000	47	Dia_sem_SIN
13	Ind_Precios4	0,000000	48	Ind_Indust41
14	Ind_Indust21	0,000000	49	Ind_Empleo2
15	Ind_Indust40	0,000000	50	C1_Tmin
16	Ind_Indust8	0,000000	51	C2_Tmin
17	N_semana_SIN	0,000000	52	A4_Tmax
18	D3_Tmin	0,000000	53	D1_Tmax
19	Ind_Indust12	0,000000	54	Ind_Indust16
20	E1_Tmin	0,000000	55	Ind_Indust37
21	Ind_Indust23	0,000000	56	E1_Tmax
22	C1_Tmax	0,000000	57	Ind_Serv3
23	Ind_Indust14	0,000000	58	Dia_sem_COS
24	Ind_Indust4	0,000000	59	Ind_Empleo3
25	Ind_Indust25	0,000000	60	N_mes_SIN
26	D1_Tmin	0,000000	61	C3_Tmax
27	Ind_Cemento	0,000000	62	Ind_Indust5
28	Ind_Indust30	0,000000	63	Ind_Indust22
29	B4_Tmin	0,000000	64	B3_Tmin
30	D3_Tmax	0,000000	65	C4_Tmin
31	Ind_Indust17	0,000000	66	C2_Tmax
32	Ind_Indust11	0,000000	67	Ind_Indust24
33	Ind_Indust15	0,000000	68	N_dia_mes_COS
34	N_semana_COS	0,000000	69	Ind_Indust56
			70	Clasif dia

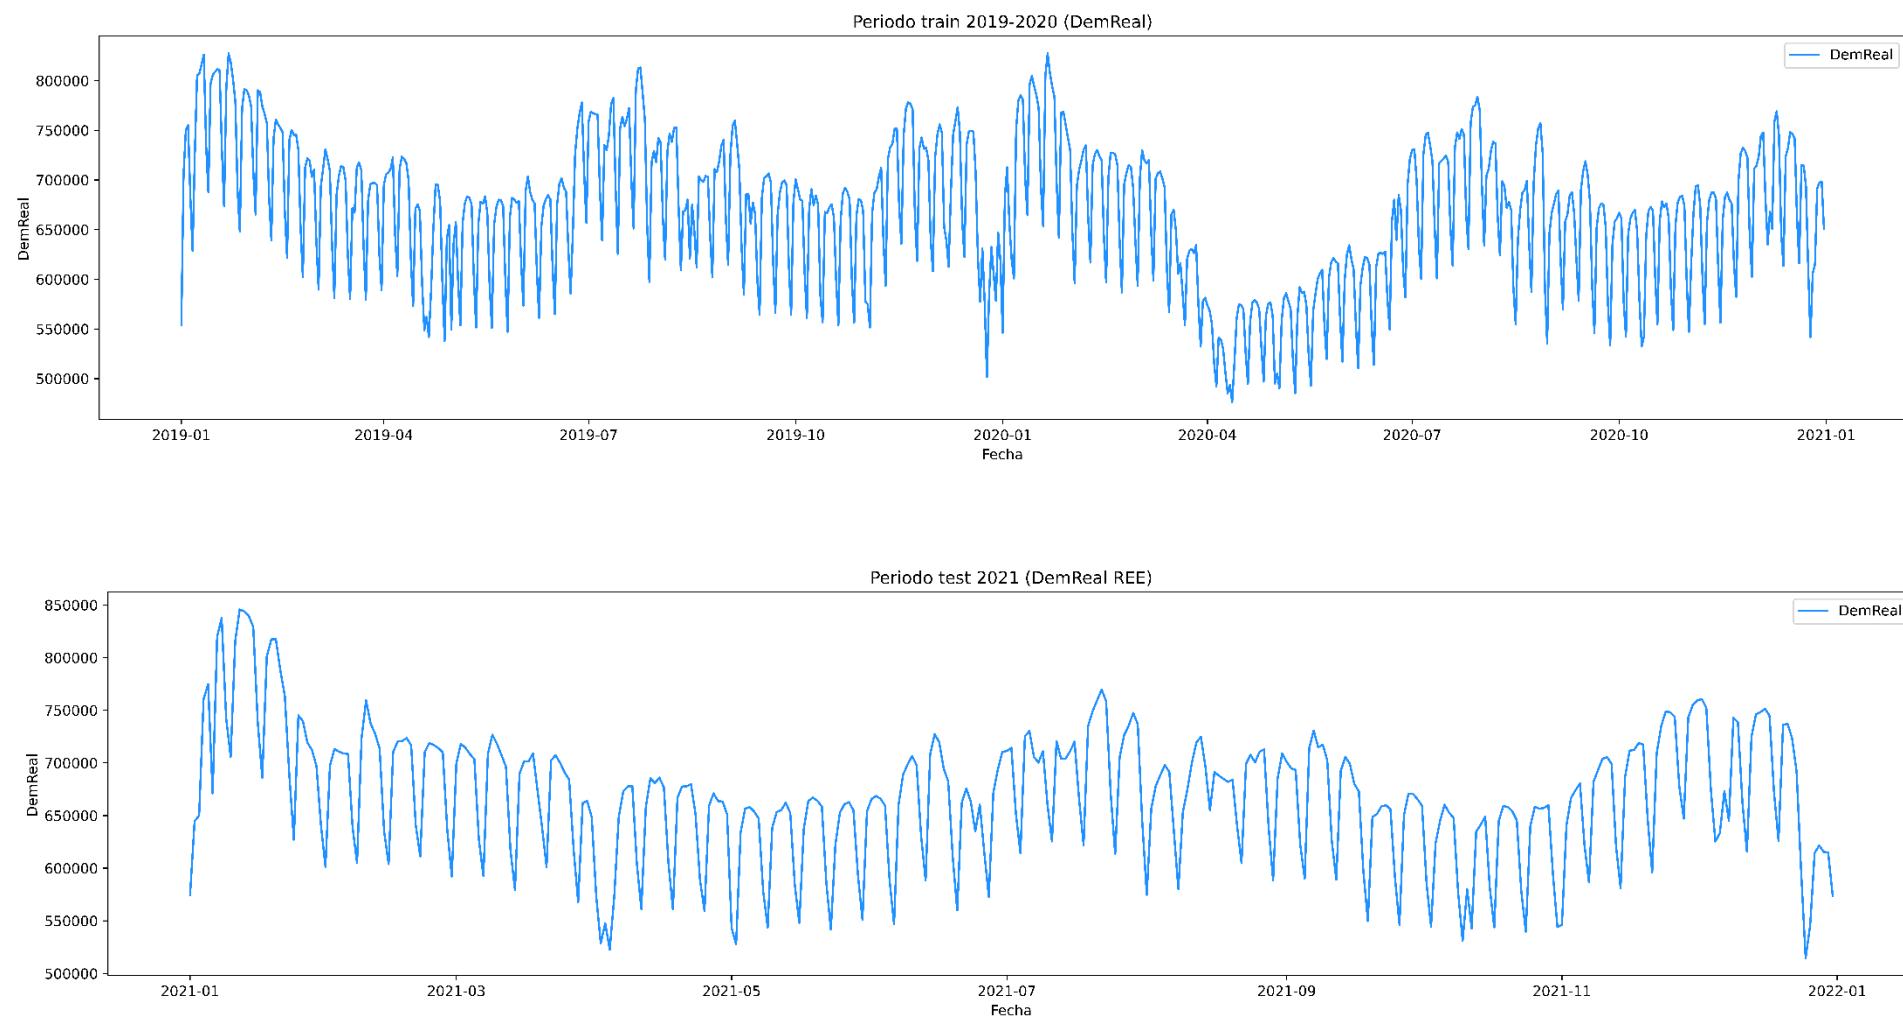
**ANEXO 14.11. TABLA IMPORTANCIA VARIABLES - MODELO ML “XGBOOST”**

	<b>vars_pred</b>	<b>feat_imp</b>			
0	Clasif_dia	0,063915	35	Ind_Indust22	0,009401
1	N_mes_SIN	0,061258	36	B3_Tmin	0,009190
2	Lab_post_fest	0,056345	37	Ind_Fabr1	0,009122
3	Dia_sem_SIN	0,054254	38	C1_Tmax	0,008943
4	N_semana_COS	0,047532	39	B4_Tmin	0,008925
5	Ind_Indust15	0,034030	40	Ind_Indust53	0,008863
6	D3_Tmin	0,030091	41	Ind_Indust19	0,008500
7	Lab_previo_fest	0,029304	42	D1_Tmin	0,008332
8	Ind_Indust4	0,028252	43	B3_Tmax	0,008244
9	D2_Tmin	0,026588	44	Ind_Indust9	0,008198
10	D3_Tmax	0,021879	45	Ind_Fabr2	0,008138
11	Ind_Indust17	0,019400	46	A3_Tmin	0,008106
12	Ind_Empleo3	0,018396	47	Ind_Serv3	0,008090
13	E1_Tmin	0,017375	48	A4_Tmax	0,008019
14	C4_Tmax	0,015538	49	A3_Tmax	0,007985
15	Ind_Indust8	0,015109	50	N_dia_mes_SIN	0,007609
16	Ind_Precios4	0,015029	51	C3_Tmax	0,006542
17	Ind_Indust24	0,014356	52	Ind_Indust26	0,006480
18	Ind_Empleo2	0,014327	53	C2_Tmin	0,006345
19	Ind_Indust21	0,014252	54	Ind_Indust37	0,006005
20	B4_Tmax	0,014231	55	N_dia_mes_COS	0,005871
21	Ind_Indust27	0,013572	56	Dia_sem_COS	0,005814
22	N_semana_SIN	0,013532	57	Ind_Indust16	0,005586
23	C3_Tmin	0,013301	58	D1_Tmax	0,005339
24	Ind_Indust23	0,013280	59	Ind_Indust13	0,005255
25	E1_Tmax	0,013277	60	Ind_Indust41	0,004389
26	Ind_Indust11	0,013015	61	A4_Tmin	0,003991
27	Ind_Indust25	0,011872	62	Ind_Serv10	0,003916
28	D2_Tmax	0,011848	63	Ind_Serv8	0,003681
29	Ind_Indust12	0,011428	64	C1_Tmin	0,003340
30	Ind_Indust5	0,011372	65	Ind_Indust35	0,003143
31	C2_Tmax	0,011037	66	Ind_Indust14	0,002488
32	Ind_Indust40	0,010733	67	C4_Tmin	0,002345
33	N_mes_COS	0,010495	68	Ind_Indust30	0,001430
34	Ind_Cemento	0,009809	69	Ind_Indust56	0,001227
			70	Huelga_General	0,001117

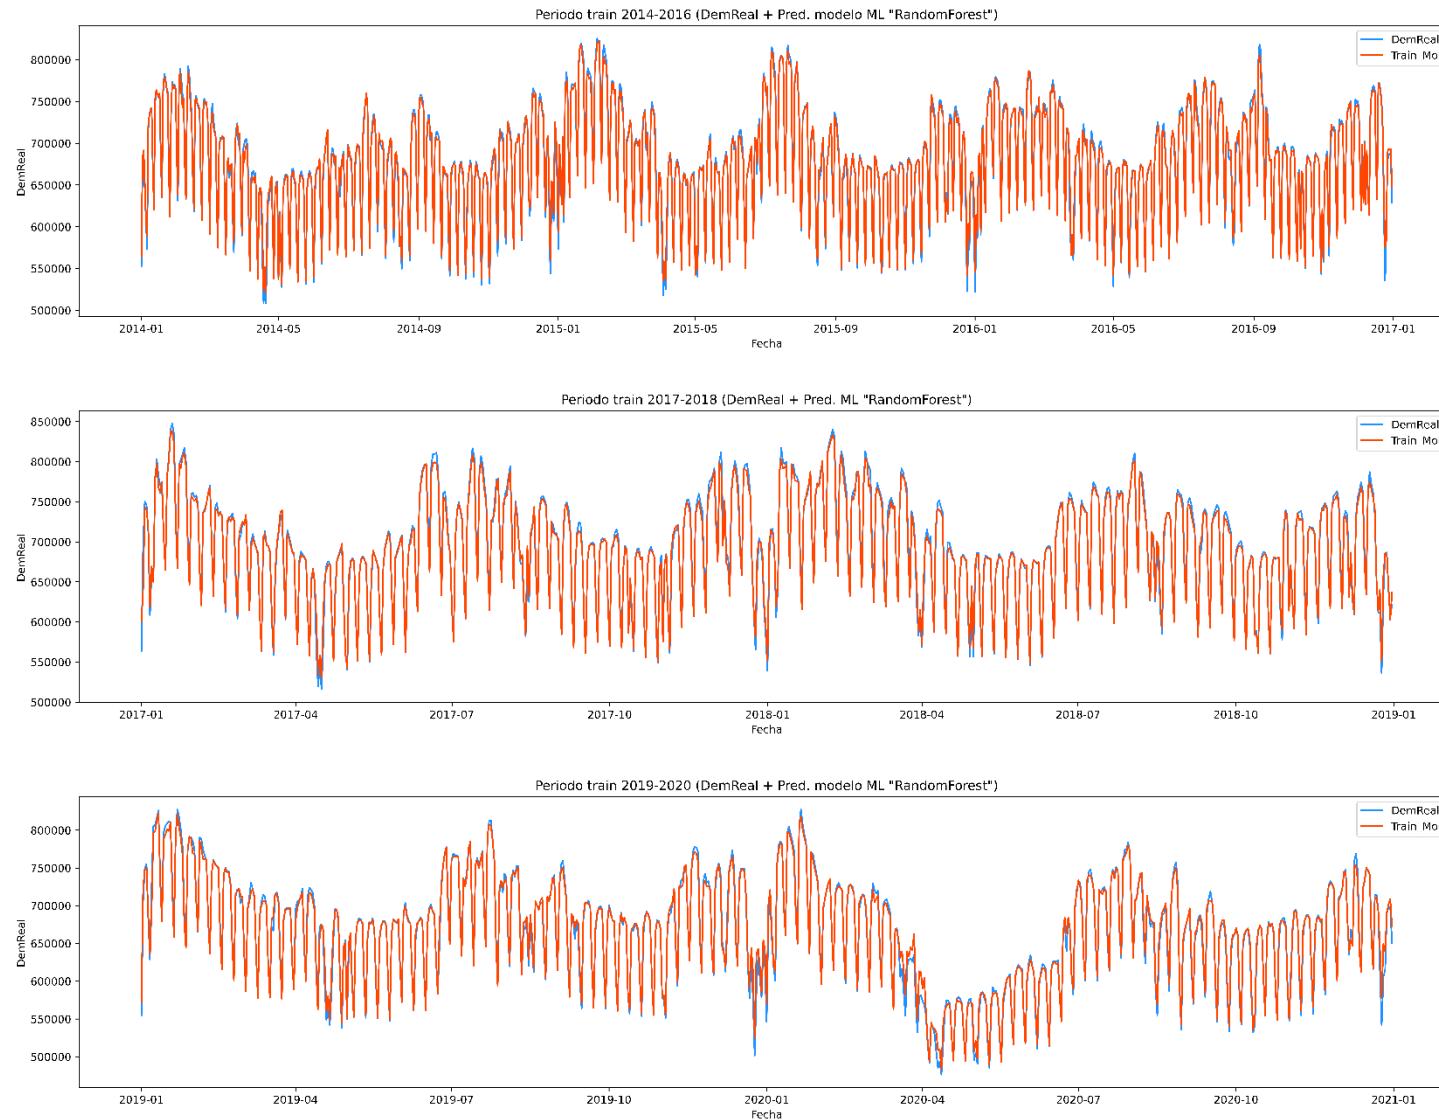
## ANEXO 14.12. VISUALIZACIÓN “DEMANDA REAL” MODELO REE (2014-2018)



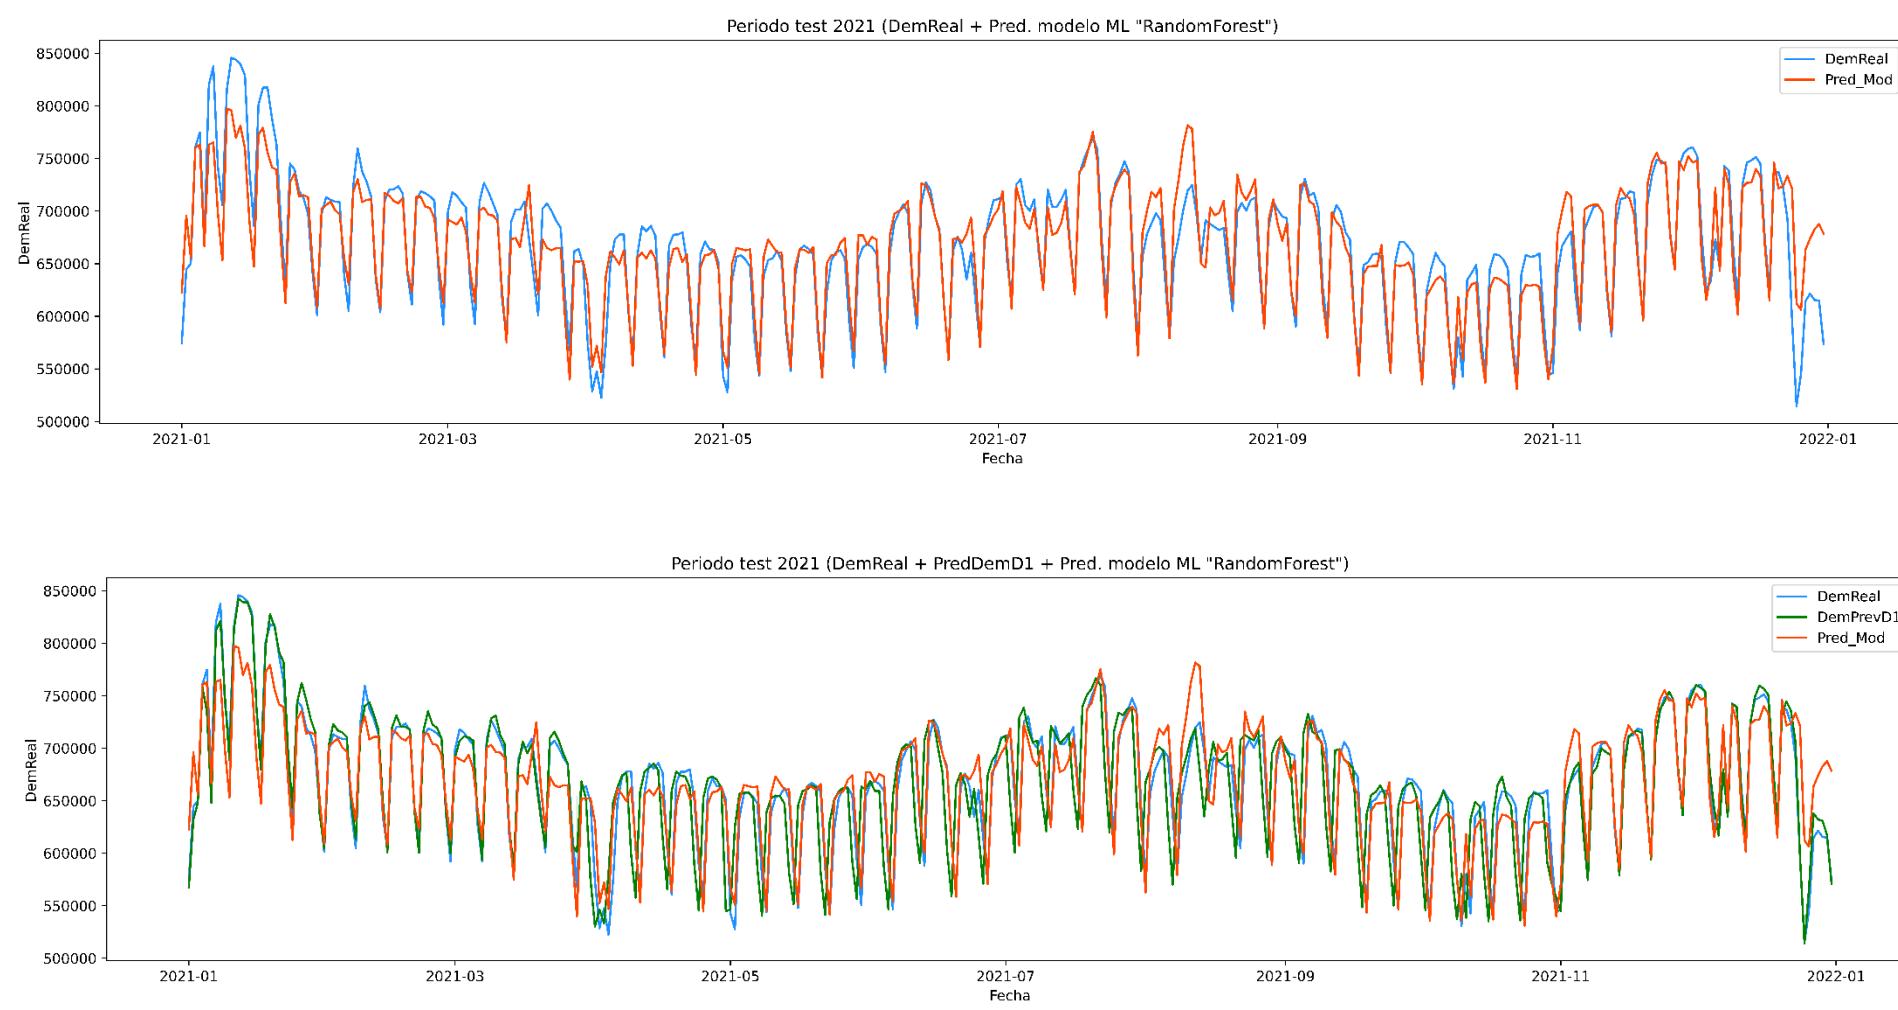
#### ANEXO 14.13. VISUALIZACIÓN LA “DEMANDA REAL” MODELO REE (2019-2021)



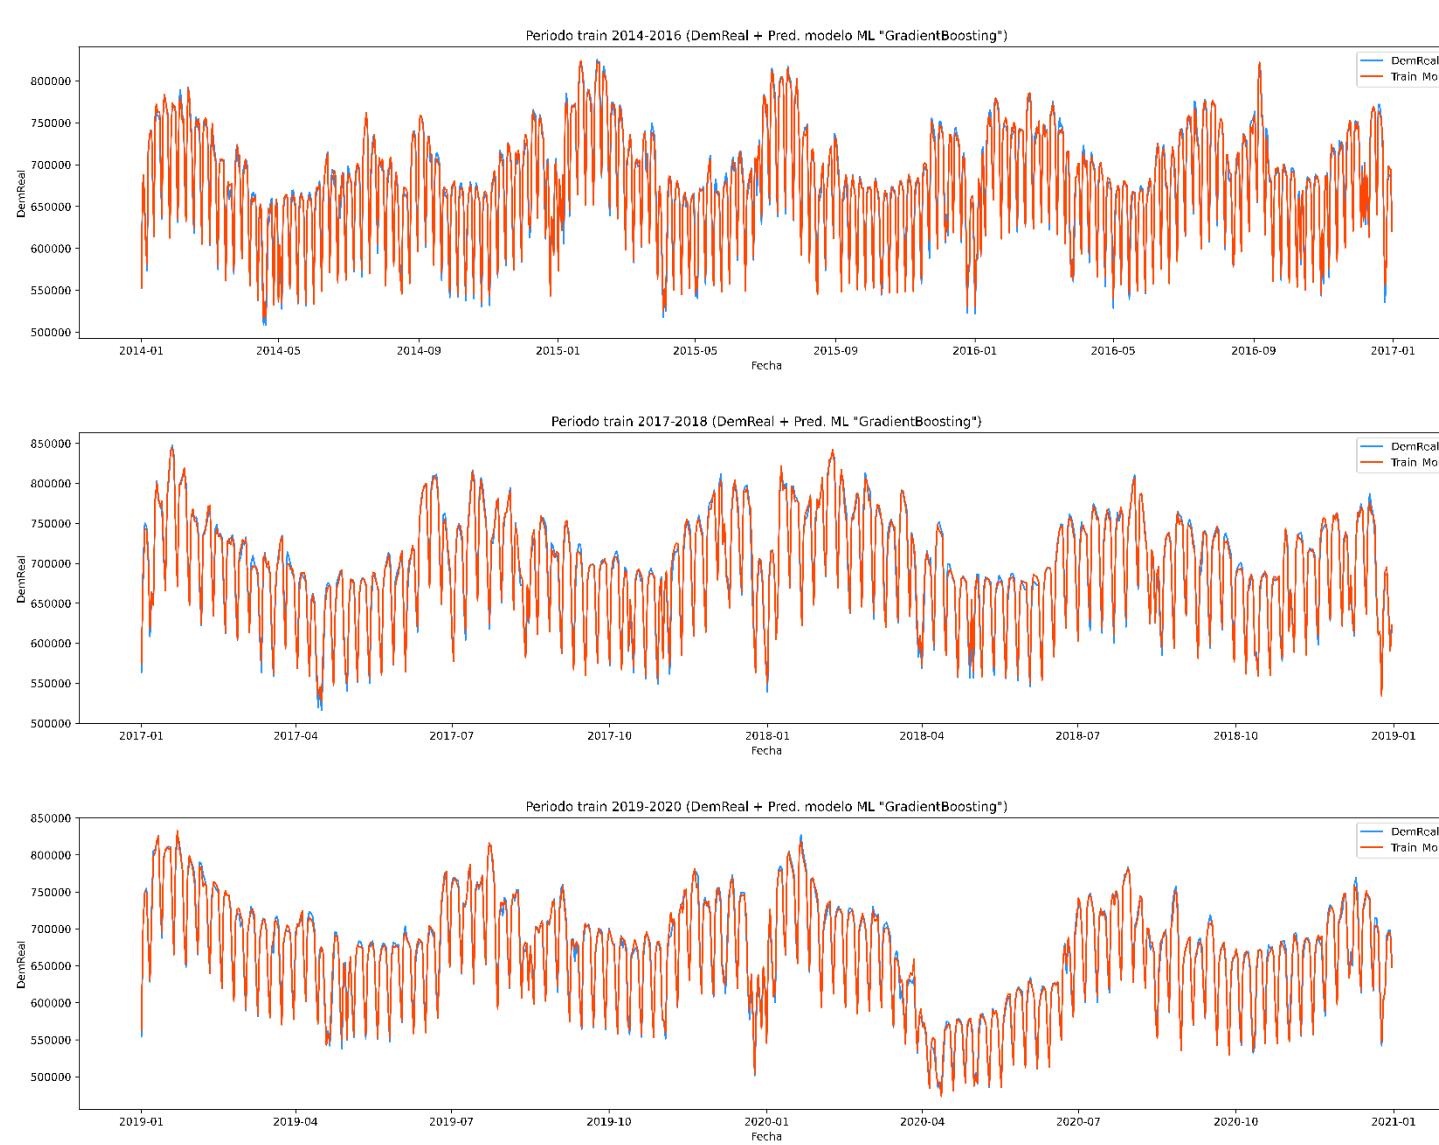
#### ANEXO 14.14. VISUALIZACIÓN “DEMANDA REAL” Y PREDICCIÓN DEL MODELO ML - “RANDOM FOREST” (2014-2020)



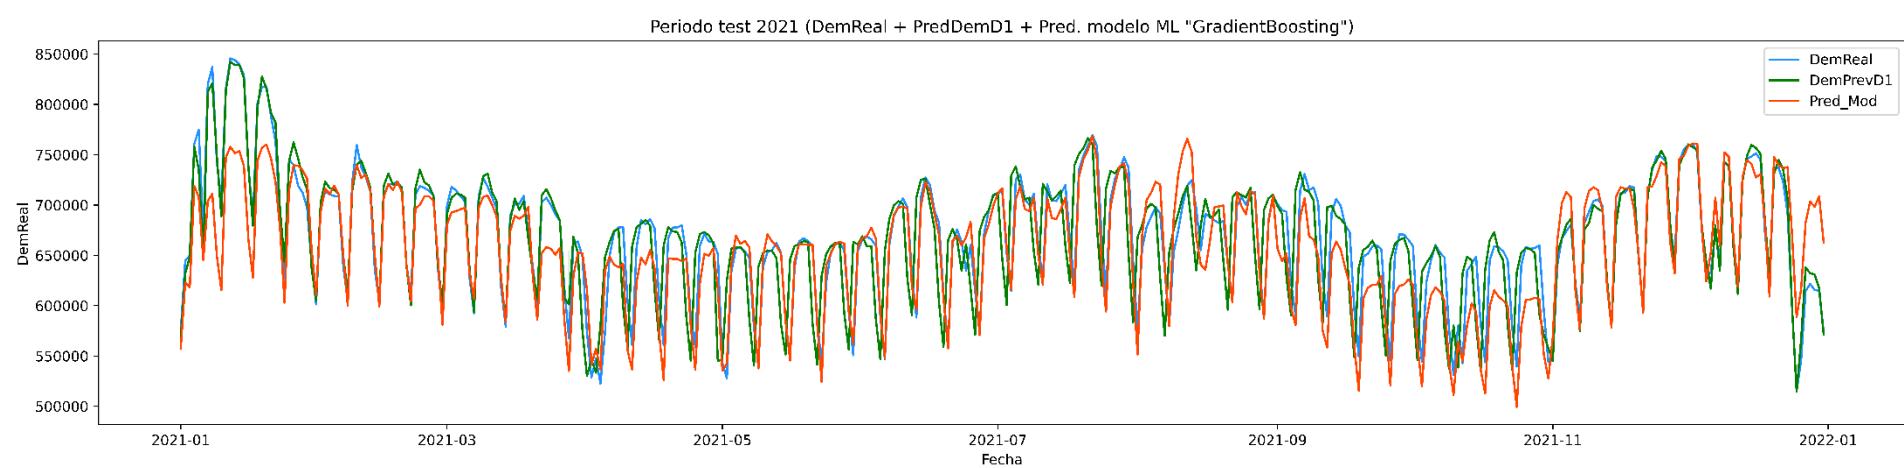
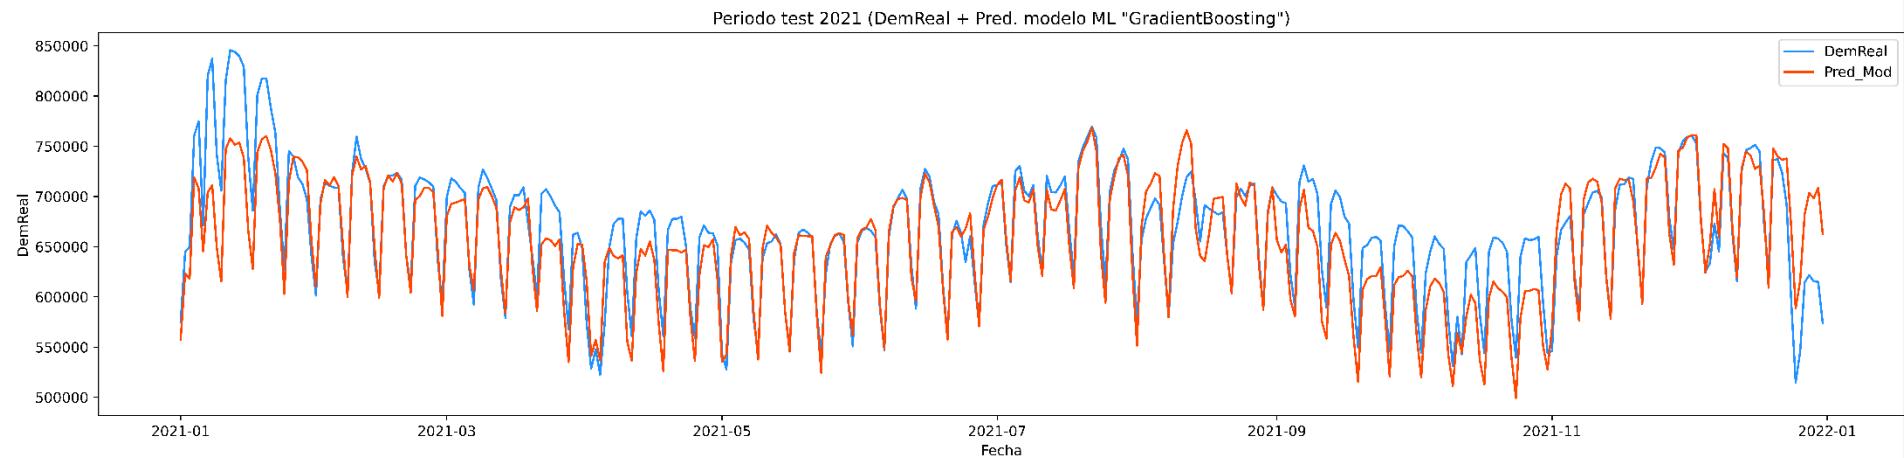
**ANEXO 14.15. VISUALIZACIÓN “DEMANDA REAL”, “PRED.DEMANDA D+1” Y PREDICCIÓN DEL MODELO ML - “RANDOM FOREST” (2021)**



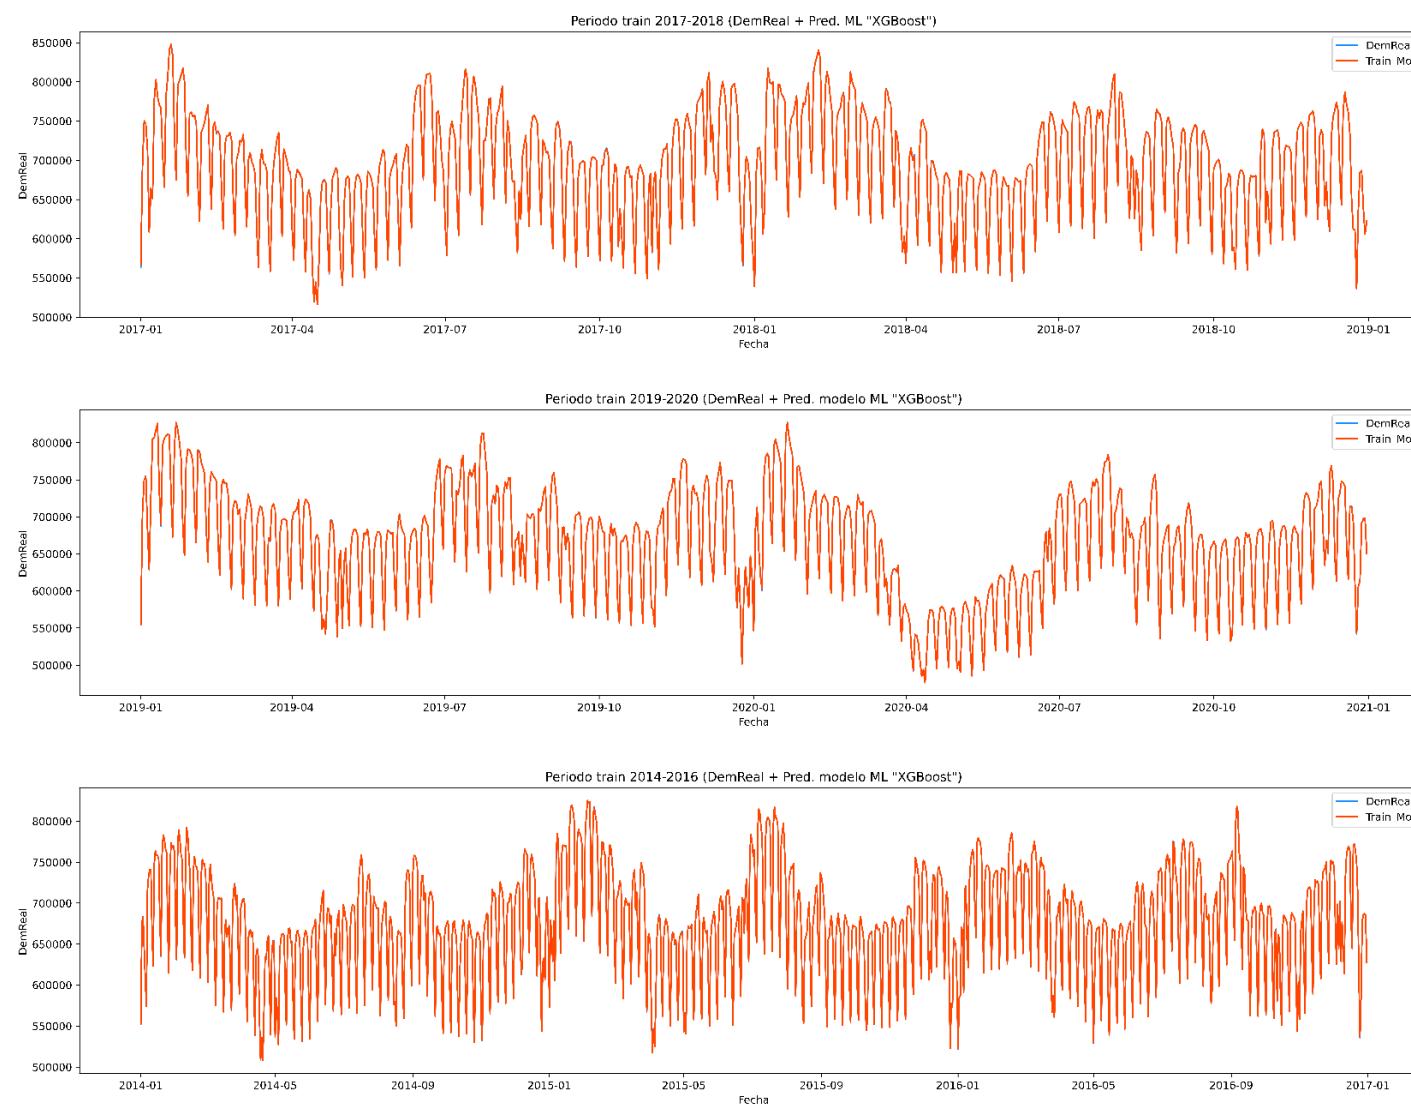
#### ANEXO 14.16. VISUALIZACIÓN “DEMANDA REAL” Y PREDICCIÓN DEL MODELO ML - “GRADIENT BOOSTING” (2014-2020)



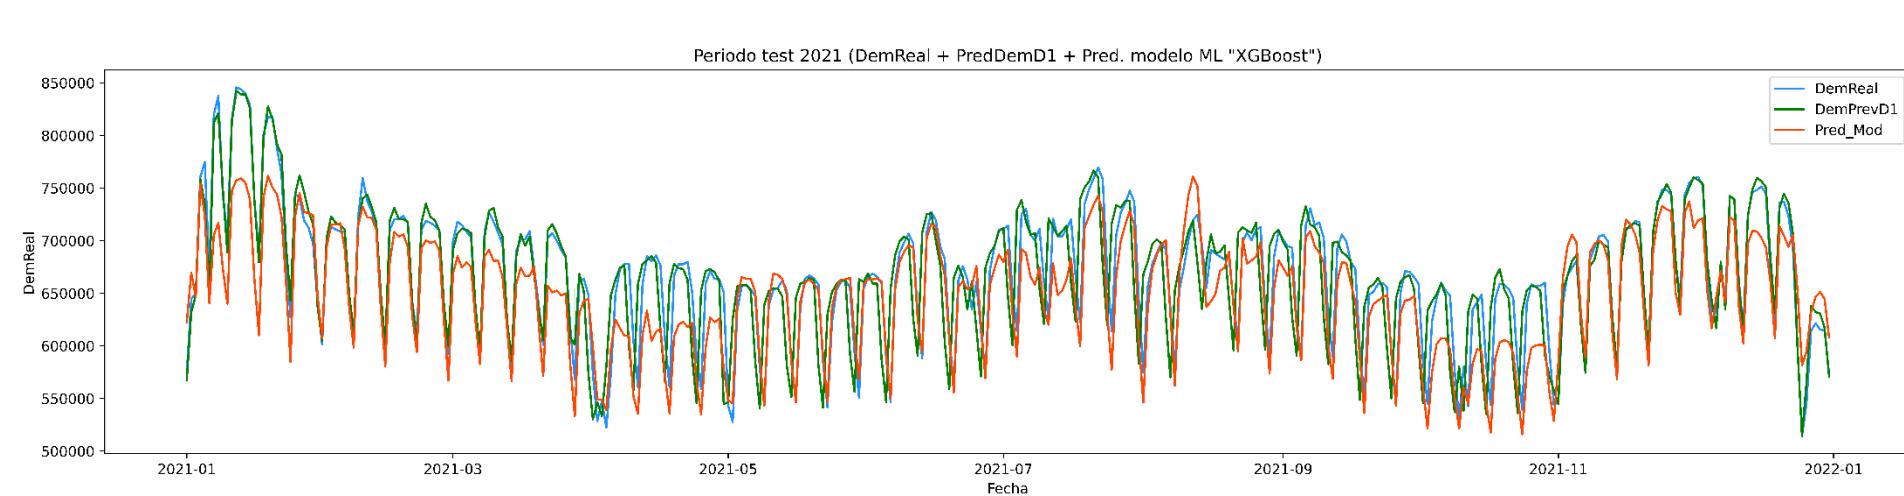
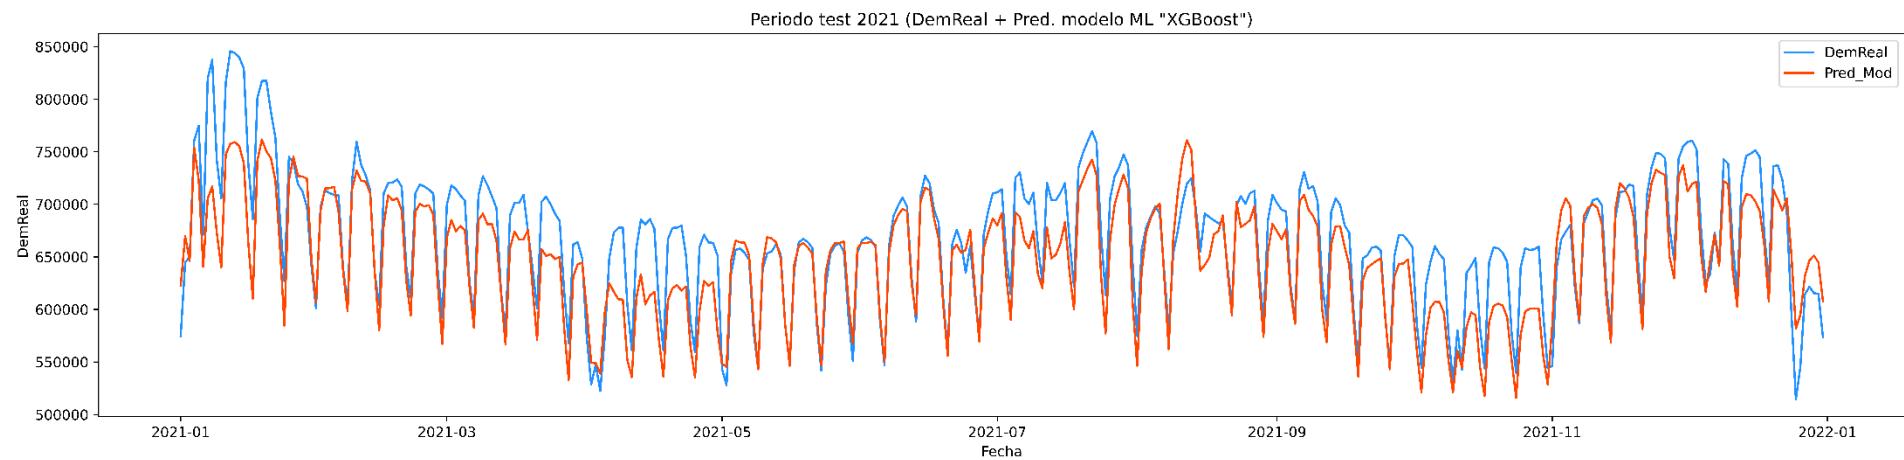
**ANEXO 14.17. VISUALIZACIÓN “DEMANDA REAL”, “PRED.DEMANDA D+1” Y PREDICCIÓN DEL MODELO ML - “GRADIENT BOOSTING” (2021)**



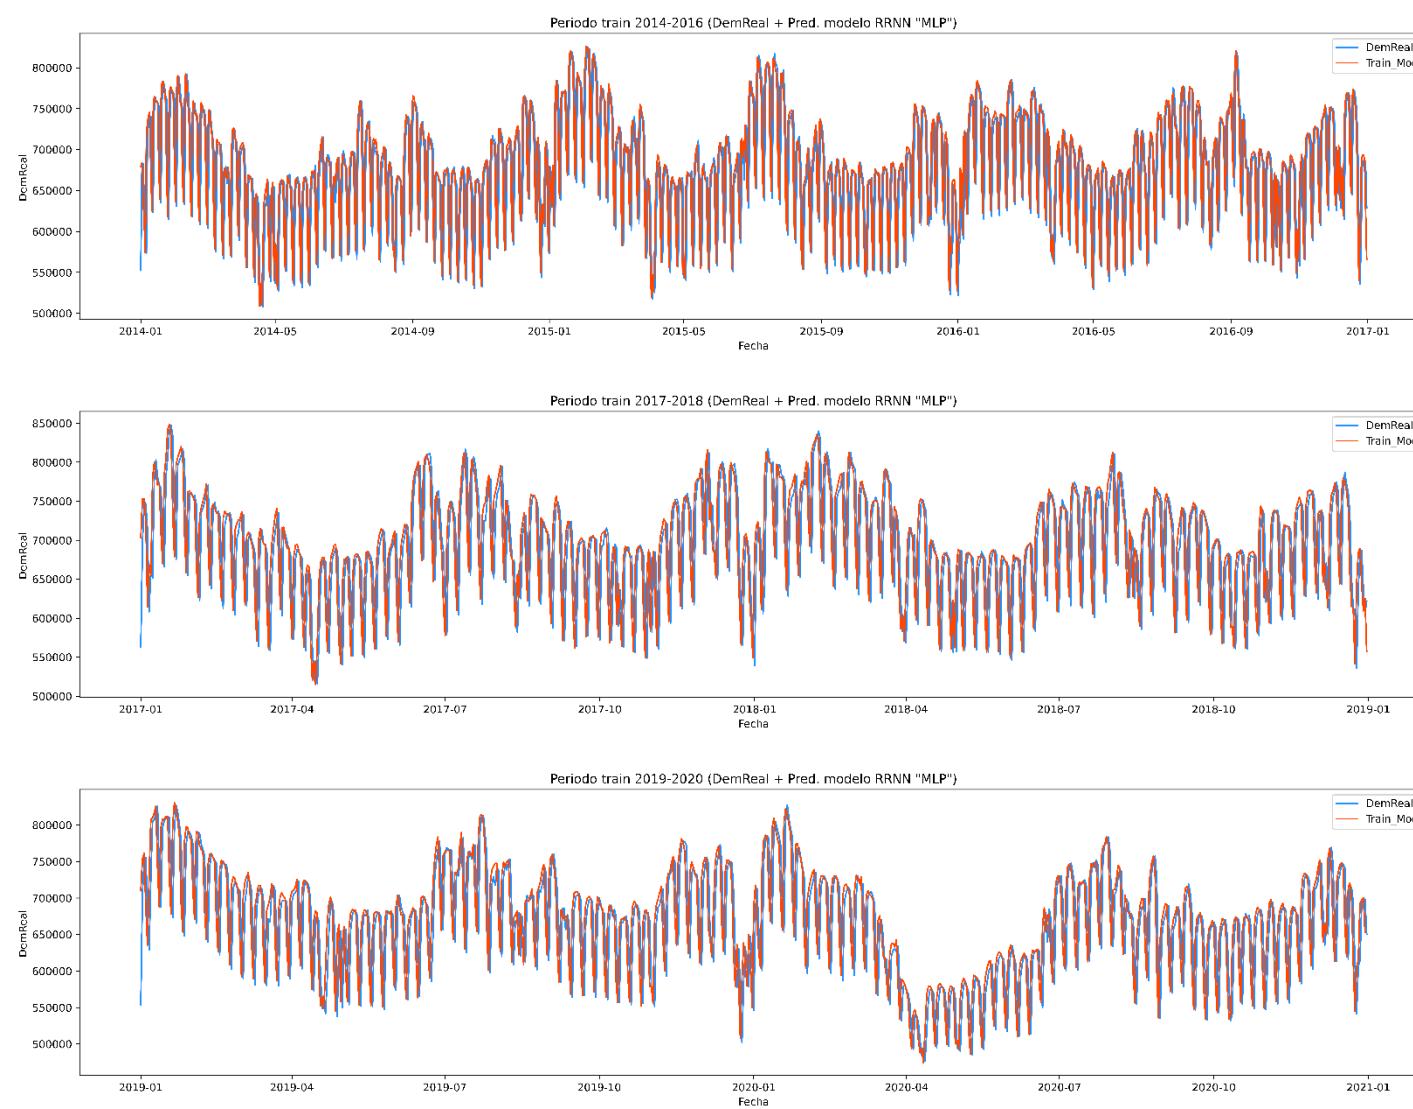
#### ANEXO 14.18. VISUALIZACIÓN “DEMANDA REAL” Y PREDICCIÓN DEL MODELO ML - “XGBOOST” (2014-2020)



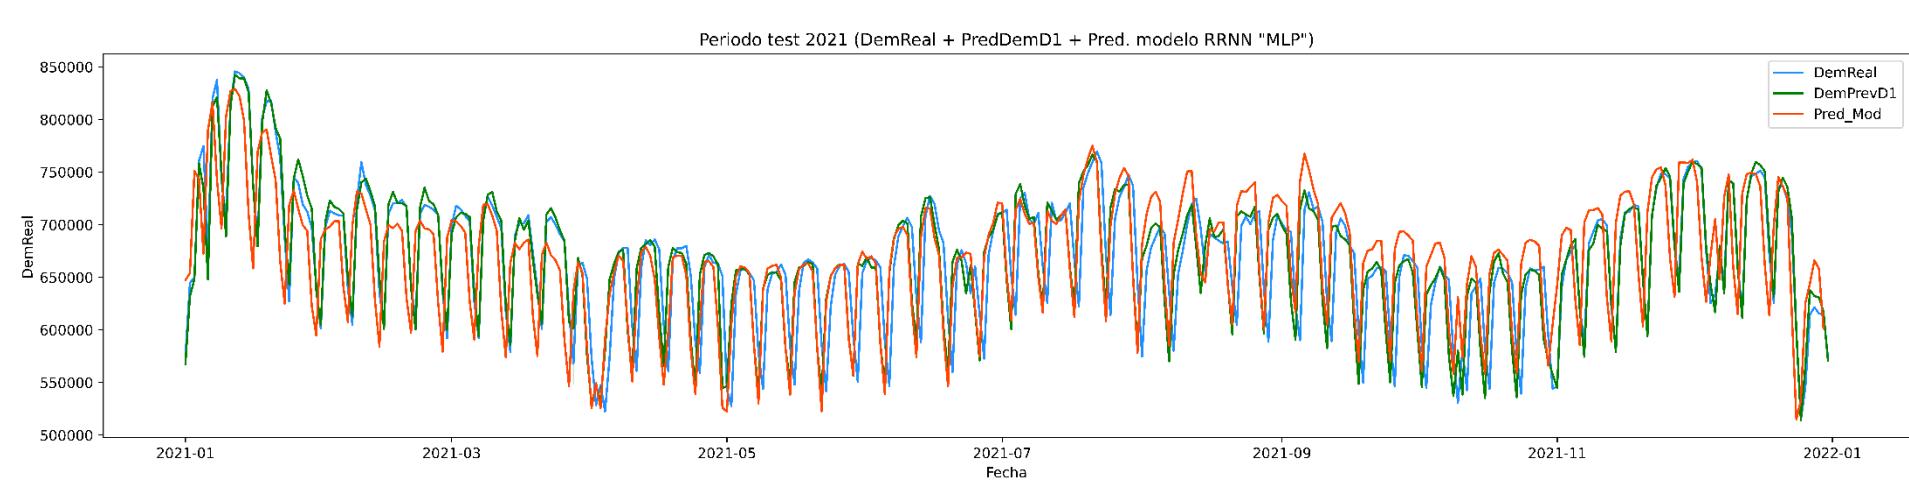
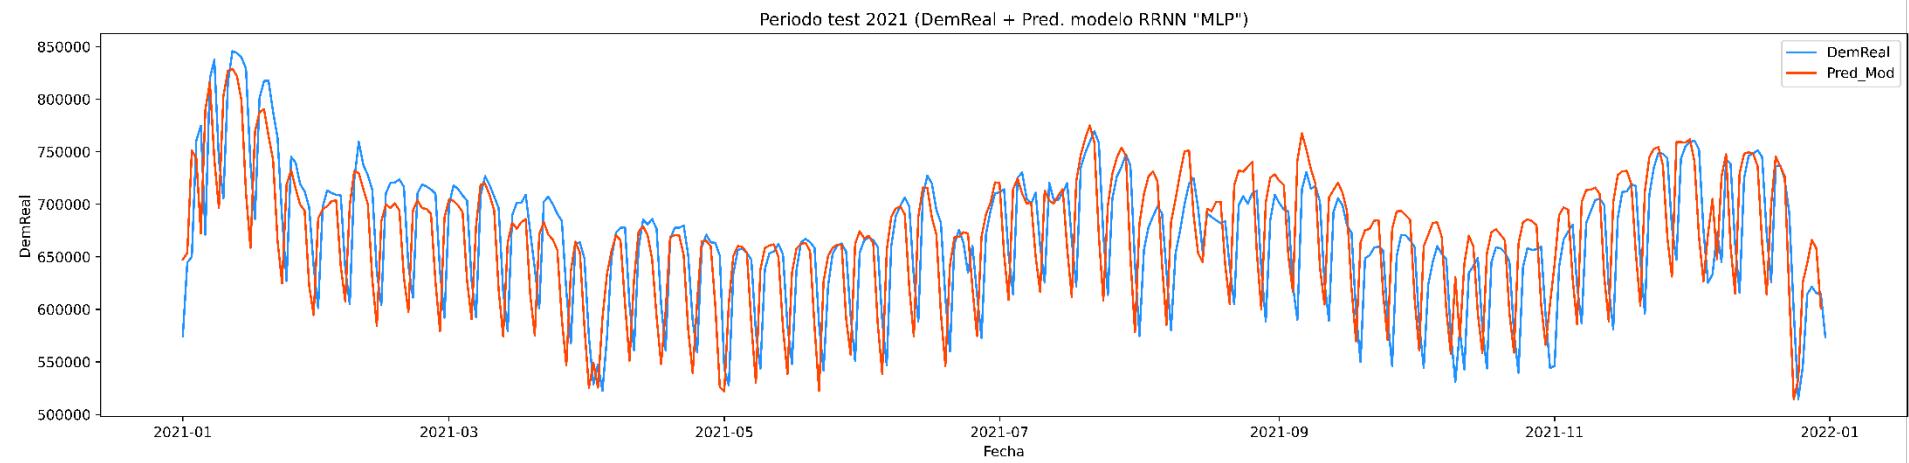
**ANEXO 14.19. VISUALIZACIÓN “DEMANDA REAL”, “PRED.DEMANDA D+1” Y PREDICCIÓN DEL MODELO ML - “XGBOOST” (2021)**



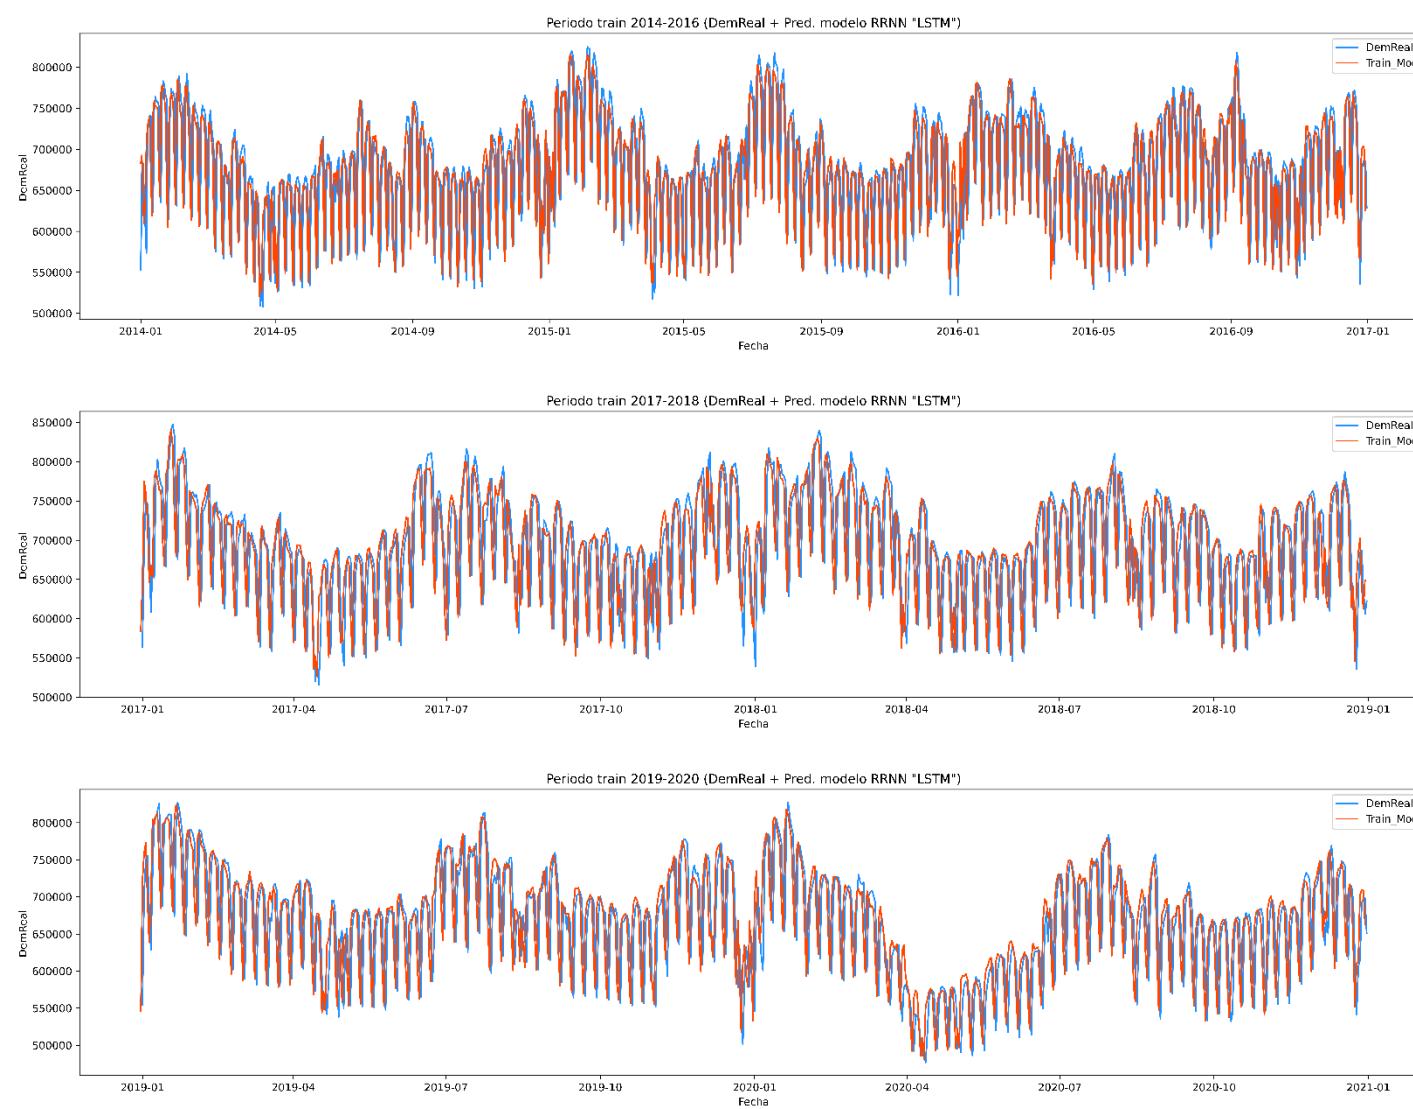
#### ANEXO 14.20. VISUALIZACIÓN “DEMANDA REAL” Y PREDICCIÓN DEL MODELO RRNN - “MLP” (2014-2020)



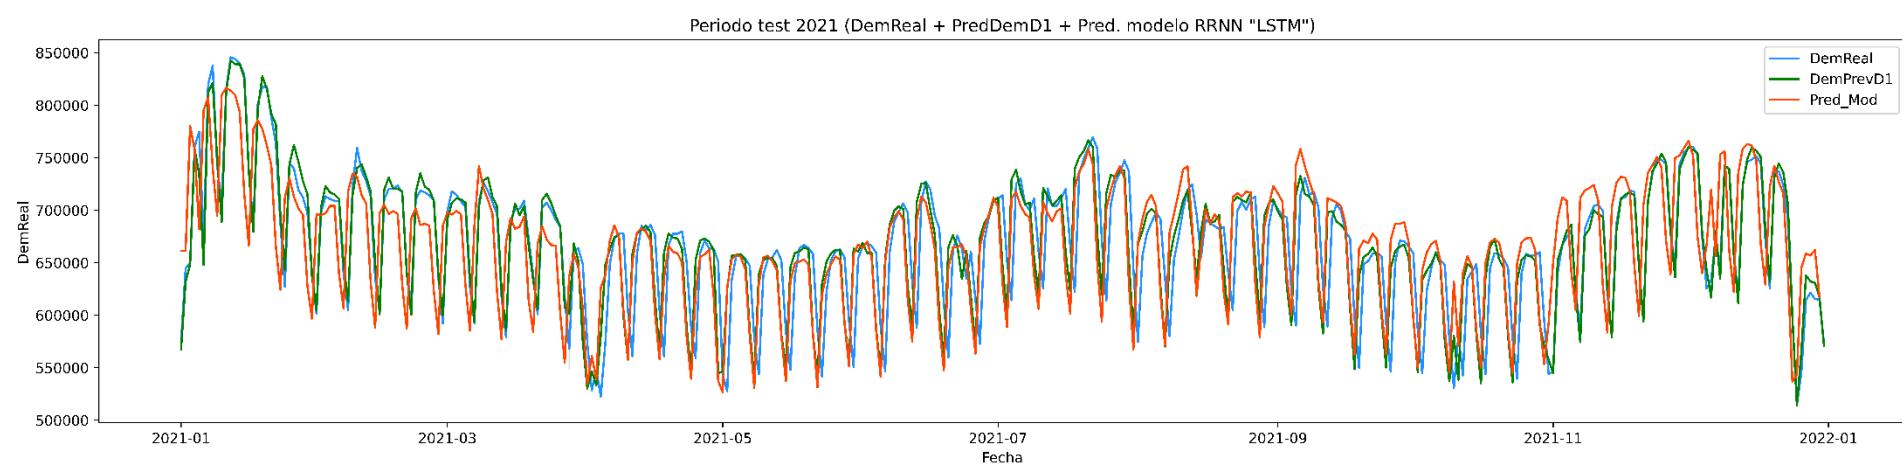
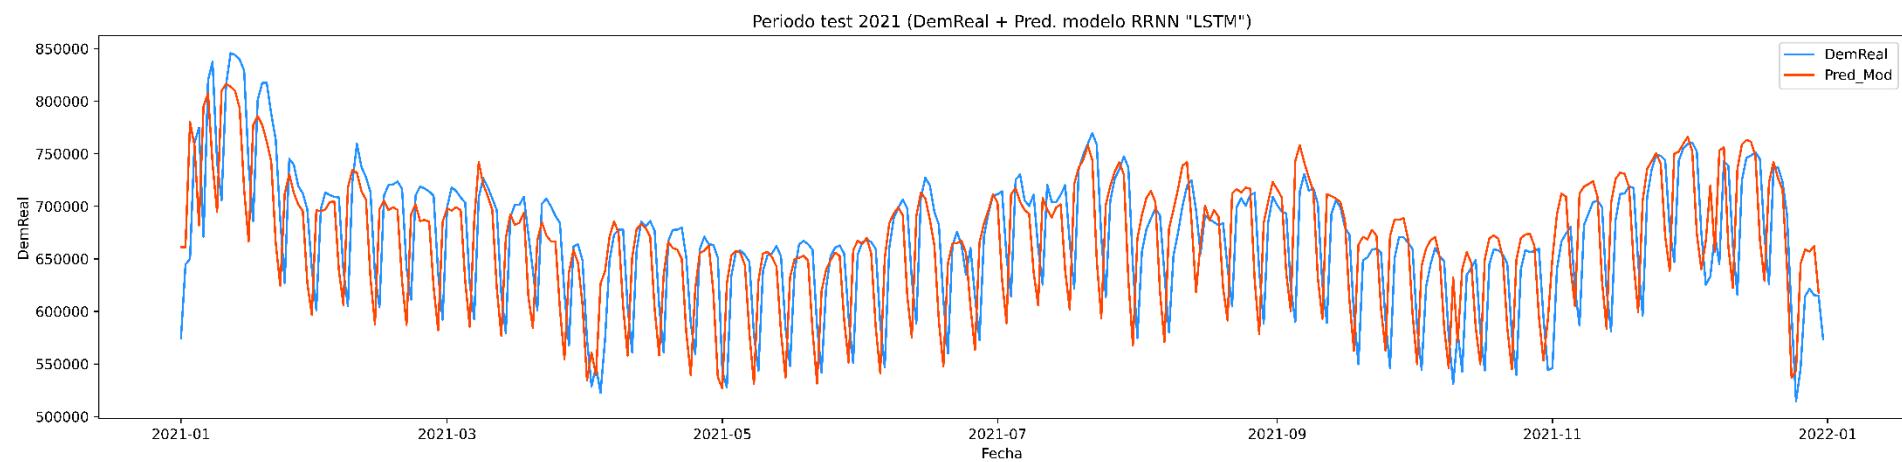
**ANEXO 14.21. VISUALIZACIÓN “DEMANDA REAL”, “PRED.DEMANDA D+1” Y PREDICCIÓN DEL MODELO RRNN - “MLP” (2021)**



#### ANEXO 14.22. VISUALIZACIÓN “DEMANDA REAL” Y PREDICCIÓN DEL MODELO RRNN - “LSTM” (2014-2020)



**ANEXO 14.23. VISUALIZACIÓN “DEMANDA REAL”, “PRED.DEMANDA D+1” Y PREDICCIÓN DEL MODELO RRNN - “LSTM” (2021)**



**ANEXO 14.24. VISUALIZACIÓN “DEMANDA REAL” Y “PRED. DEMANDA D+1” MODELO REE (2019-2021)**

